



دانشگاه صنعتی امیرکبیر

(پلی تکنیک تهران)

دانشکده مهندسی برق

پروژه کارشناسی

گرایش مخابرات

تشخیص بیماری‌های گیاهان با کمک پردازش تصویر

نگارش

علی سینا شاه‌محمدی مهرجودی

استاد راهنما

دکتر حسن آقائی‌نیا

آذر ۱۴۰۴

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: آذر ۱۴۰۴

اینجانب **علی سینا شاه محمدی مهرجردی** متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

علی سینا شاه محمدی مهرجردی

امضا

باسپاس و عشق بی پایان تقدیم به پدر و مادر عزیزم، که با محبت و حمایت های بی‌شماری شان راهنمای من در مسیر زندگی و علم بوده اند.

سپاسگزاری

با سپاس و قدردانی فراوان از استاد راهنمای گرامی، جناب آقای دکتر حسن آقائی‌نیا، که با راهنمایی‌ها، دقت نظر و حمایت‌های بی‌دریغ خود، مسیر پژوهش و نگارش این پایان‌نامه را هموار ساختند. دانش و تجربه ایشان بدون شک نقش تعیین‌کننده‌ای در پیشبرد این تحقیق داشته است. از استاد محترم داور، جناب آقای دکتر حمیدرضا امین‌داور، که با بررسی دقیق، نقد سازنده و راهنمایی‌های ارزشمندشان، کیفیت علمی این پژوهش را ارتقا دادند، صمیمانه سپاسگزارم.

علی سینا شاه‌محمدی مهرجودی

آذر ۱۴۰۴

چکیده

تشخیص خودکار بیماری‌های گیاهان نقش مهمی در کاهش خسارات کشاورزی و ارتقای بهره‌وری در سیستم‌های کشاورزی هوشمند دارد. هدف این پژوهش ارائه‌ی یک چارچوب مبتنی بر پردازش تصویر و یادگیری عمیق برای تشخیص بیماری‌های برگ گیاهان با قابلیت کاربرد در شرایط واقعی مزرعه است. در مرحله نخست، معماری‌های مطرح طبقه‌بندی تصویر شامل AlexNet، EfficientNet، MobileNet و ResNet با استفاده از دیتاست کنترل‌شده PlantVillage آموزش داده شدند. به منظور بهبود عملکرد سیستم، یک مدل Ensemble سه‌لایه مبتنی بر ترکیب ویژگی‌های استخراج‌شده از شبکه‌های عمیق منتخب طراحی گردید که از سه معماری معرفی‌شده در این مرحله بهره می‌برد و امکان استفاده‌ی هم‌زمان از قابلیت‌های مکمل هر شبکه را فراهم می‌سازد.

در مرحله‌ی دوم، به منظور انتقال مدل از شرایط آزمایشگاهی به محیط‌های واقعی و کنترل‌نشده، یک مدل تشخیص ناحیه‌ی بیماری مبتنی بر YOLOX توسعه داده شد. در این راستا، از معماری ConvNeXt به عنوان Backbone استفاده گردید و مکانیزم توجه CBAM به منظور تقویت فرآیند استخراج ویژگی‌های مکانی و کانالی به مدل افزوده شد. ارزیابی این مدل بر روی دیتاست PlantDoc انجام گرفت که شامل تصاویر در شرایط واقعی با تنوع نور، پس‌زمینه‌های پیچیده، نویز و زوایای مختلف تصویربرداری است. نتایج نشان می‌دهد مدل Ensemble پیشنهادی به دقتی در حدود ۹۹/۷۶ درصد دست یافته که بیانگر برتری مدل‌های ترکیبی نسبت به معماری‌های تکی در داده‌های کنترل‌شده می‌باشد. همچنین، مدل تشخیص ناحیه توانسته است نواحی بیمار برگ‌ها را با دقت و سرعت مناسب در تصاویر واقعی شناسایی کند که بیانگر کارایی، پایداری و قابلیت کاربرد این چارچوب در سامانه‌های کشاورزی هوشمند برای پایش سلامت گیاهان و کاهش هزینه‌های تشخیص انسانی است.

واژه‌های کلیدی:

تشخیص بیماری‌های گیاهان، پردازش تصویر، یادگیری عمیق، شبکه‌های عصبی کانولوشنی، مدل‌های Ensemble، YOLOX، کشاورزی هوشمند

فهرست مطالب

صفحه

عنوان

۱	مقدمات و کلیات	۱
۲	۱-۱ مقدمه کلی پروژه	۲
۳	۲-۱ بیان مسئله	۳
۴	۳-۱ اهداف پروژه	۴
۴	۴-۱ ضرورت و اهمیت استفاده از یادگیری عمیق در کشاورزی	۴
۵	۵-۱ معرفی داده‌ها و چالش‌های مرتبط	۵
۵	۱-۵-۱ مجموعه داده PlantVillage	۵
۷	۲-۵-۱ مجموعه داده PlantDoc	۷
۹	۳-۵-۱ تفاوت بنیادی داده آزمایشگاهی و واقعی	۹
۹	۶-۱ ساختار کلی پایان‌نامه	۹
۱۰	۷-۱ جمع‌بندی	۱۰
۱۱	۲ مبانی پردازش تصویر و شبکه‌های عصبی در تشخیص بیماری‌های گیاهی	۱۱
۱۲	۱-۲ مقدمه	۱۲
۱۳	۲-۲ پردازش تصویر و جایگاه آن در تشخیص بیماری گیاهان	۱۳
۱۳	۱-۲-۲ تاریخچه پردازش تصویر در کشاورزی	۱۳
۱۳	۲-۲-۲ ماهیت تصویر دیجیتال و اصول پایه	۱۳
۱۴	۳-۲-۲ نقش پیش‌پردازش در آماده‌سازی داده	۱۴
۱۴	۴-۲-۲ چالش‌های پردازش تصویر در تشخیص بیماری‌های گیاهی	۱۴
۱۴	۵-۲-۲ تفاوت داده‌های کنترل‌شده و واقعی	۱۴
۱۵	۳-۲ شبکه‌های عصبی کانولوشنی و یادگیری عمیق	۱۵
۱۵	۱-۳-۲ مقدمه‌ای بر شبکه‌های عصبی	۱۵
۱۵	۲-۳-۲ ساختار شبکه‌های عصبی کانولوشنی	۱۵
۱۶	۳-۳-۲ سلسله‌مراتب ویژگی‌ها در CNN و تشخیص بیماری	۱۶
۱۶	۴-۳-۲ معرفی معماری‌های CNN مورد استفاده در پروژه	۱۶

۱۷	۵-۳-۲ دلایل کاربرد CNN در تشخیص بیماری‌های گیاهان
۱۷	۴-۲ تشخیص ناحیه بیماری در تصاویر واقعی
۱۷	۱-۴-۲ ضرورت تشخیص ناحیه در مقابل طبقه‌بندی تصویر
۱۸	۲-۴-۲ معرفی روش‌های دو مرحله‌ای و تک‌مرحله‌ای
۱۸	۳-۴-۲ خانواده YOLO و تکامل YOLOX
۱۸	۴-۴-۲ چالش‌های تشخیص ناحیه در تصاویر واقعی گیاه
۱۸	۵-۴-۲ دلایل انتخاب YOLOX در پروژه
۱۹	۵-۲ مکانیزم‌های توجه و نقش آنها در تشخیص بیماری گیاهی
۱۹	۱-۵-۲ مفهوم توجه در یادگیری عمیق
۱۹	۲-۵-۲ توجه کانالی و مکانی
۱۹	۳-۵-۲ مکانیزم CBAM و نحوه استفاده آن در پروژه
۲۰	۴-۵-۲ اهمیت توجه در داده‌های گیاهی
۲۰	۶-۲ جمع‌بندی
۲۱	۳ مروری بر پژوهش‌ها و مدل‌های موجود در تشخیص بیماری‌های گیاهان
۲۲	۱-۳ مقدمه و تاریخچه روش‌های کلاسیک در تشخیص بیماری گیاهان
۲۲	۱-۱-۳ تاریخچه روش‌های کلاسیک در تشخیص بیماری گیاهان
۲۴	۲-۱-۳ گذار از روش‌های کلاسیک به یادگیری عمیق
۲۵	۲-۲-۳ Ensemble، CNN و Transfe Learning
۲۵	۱-۲-۳ شبکه‌های عصبی کانولوشنی (CNN)
۲۹	۲-۲-۳ Ensemble Learning
۳۰	۳-۲-۳ Transfer Learning
۳۱	۳-۳ مدل‌های YOLO و جایگاه YOLOX
۳۱	۱-۳-۳ مقدمه‌ای بر تشخیص ناحیه در بیماری گیاهان
۳۱	۲-۳-۳ نسل اول تشخیص ناحیه Faster R-CNN و SSD
۳۲	۳-۳-۳ ظهور YOLO و آغاز عصر جدید تشخیص بیماری گیاهان
۳۳	۴-۳-۳ نسل جدید YOLOX، دقیق و anchor-free

۳۳	۵-۳-۳ بکارگیری YOLOX در حوزه گیاهان
۳۴	۶-۳-۳ چالش‌های تشخیص بیماری در تصاویر واقعی و نقش YOLOX
۳۵	۷-۳-۳ ارتباط YOLOX با پژوهش انجام شده
۳۶	۴-۳ مکانیزم‌های توجه و مدل‌های هیبرید در تشخیص بیماری‌های گیاهان
۳۶	۱-۴-۳ مقدمه‌ای بر نقش توجه (Attention) در تشخیص بیماری‌های گیاهان
۳۶	۲-۴-۳ سازوکار توجه کانالی (Channel Attention)
۳۷	۳-۴-۳ توجه مکانی (Spatial Attention)
۳۷	۴-۴-۳ مکانیزم توجه CBAM
۳۸	۵-۴-۳ مدل‌های توجه سبک در تشخیص بیماری‌های گیاهان
۳۹	۶-۴-۳ مدل‌های هیبرید: ترکیب CNN، Attention و Transformer
۴۰	۷-۴-۳ ارتباط توجه و مدل‌های هیبرید با پژوهش انجام شده
۴۱	۵-۳ تحلیل مقایسه‌ای، شکاف‌های پژوهشی و جایگاه پژوهش انجام شده
۴۱	۱-۵-۳ تحلیل مقایسه‌ای پژوهش‌های موجود در تشخیص بیماری گیاهی
۴۳	۲-۵-۳ تحلیل شکاف‌های پژوهشی
۴۴	۳-۵-۳ جایگاه پژوهش انجام شده در ادبیات پژوهشی
۴۵	۶-۳ جمع‌بندی
۴۶	۴ پیاده‌سازی و ارزیابی مدل‌های تشخیص بیماری گیاهان
۴۷	۱-۴ ساختار سیستم و فرایند پیش‌پردازش پیشنهادی
۴۷	۱-۱-۴ مقدمه
۴۷	۲-۱-۴ ساختار کلی سیستم پیاده‌سازی شده
۴۸	۳-۱-۴ دلایل انتخاب دیتاست PlantVillage
۴۹	۴-۱-۴ دلایل انتخاب دیتاست PlantDoc
۴۹	۵-۱-۴ مراحل پیش‌پردازش داده‌های PlantVillage
۵۰	۶-۱-۴ مراحل پیش‌پردازش داده‌های PlantDoc
۵۱	۲-۴ معماری شبکه‌های CNN و مدل Ensemble سه‌لایه
۵۱	۱-۲-۴ مقدمه‌ای بر معماری‌های CNN مورد استفاده در مرحله اول

۵۱	۲-۲-۴ معماری EfficientNetB0 و نقش آن در استخراج ویژگی‌های چندمقیاسی .
۵۲	۳-۲-۴ معماری ResNet50 و قدرت یادگیری عمیق آن
۵۳	۴-۲-۴ معماری MobileNetV2 و استخراج ویژگی‌های سبک و مؤثر
۵۳	۵-۲-۴ چرایی ترکیب سه معماری و ضرورت استفاده از Ensemble
۵۴	۶-۲-۴ نحوه پیاده‌سازی Ensemble و منطق ادغام خروجی‌ها
۵۵	۷-۲-۴ تنظیمات آموزش و چالش‌های آموزشی
۵۵	۳-۴ معماری YOLOX، ConvNeXt Backbone و مکانیزم توجه CBAM در تشخیص ناحیه
۵۵	۱-۳-۴ مقدمه‌ای بر ضرورت تشخیص ناحیه در داده‌های واقعی
۵۶	۲-۳-۴ ساختار YOLOX و دلایل انتخاب آن
۵۶	۳-۳-۴ ConvNeXt Backbone و نقش آن در بهبود استخراج ویژگی‌ها
۵۷	۴-۳-۴ نقش مکانیزم CBAM در افزایش تمرکز مدل بر ناحیه‌های بیماری
۵۸	۵-۳-۴ فرایند آموزش مدل YOLOX-ConvNeXt-CBAM
۵۹	۴-۴ پیاده‌سازی عملی، تنظیمات آموزشی، محیط اجرا و بهینه‌سازی مدل‌ها
۵۹	۱-۴-۴ مقدمه‌ای بر پیاده‌سازی عملی مدل‌ها
۵۹	۲-۴-۴ محیط اجرای پروژه و زیرساخت محاسباتی
۶۰	۳-۴-۴ پیاده‌سازی مدل‌های طبقه‌بندی
۶۱	۴-۴-۴ پیاده‌سازی Ensemble دومدلی و سه‌مدلی
۶۱	۵-۴-۴ پیاده‌سازی YOLOX با ConvNeXt Backbone
۶۲	۶-۴-۴ ادغام CBAM در YOLOX و تنظیمات دقیق آن
۶۳	۷-۴-۴ مشکلات و چالش‌های عملی در فرایند آموزش
۶۳	۵-۴ نتایج، تحلیل عملکرد مدل‌ها و ارزیابی سیستمی
۶۳	۱-۵-۴ مقدمه‌ای بر ارزیابی عملکرد سیستم
۶۳	۲-۵-۴ نتایج مرحله طبقه‌بندی در دیتاست PlantVillage
۷۶	۳-۵-۴ نتایج مرحله تشخیص ناحیه در دیتاست PlantDoc
۸۳	۴-۵-۴ تحلیل خطاهای مدل در مرحله Detection
۸۳	۵-۵-۴ مقایسه عملکرد مرحله طبقه‌بندی و تشخیص ناحیه
۸۴	۶-۴ جمع‌بندی

۸۵		۵ نتیجه‌گیری و آینده‌پژوهی
۸۶		۱-۵ نتیجه‌گیری کلی پروژه
۸۶		۲-۵ نقاط قوت سیستم
۸۷		۳-۵ محدودیت‌های پروژه
۸۷		۴-۵ پیشنهادهای آینده پژوهش
۸۷		۵-۵ جمع‌بندی نهایی
۸۹		کتاب‌نامه

فهرست تصاویر

شکل

صفحه

۱-۱	نمونه تصاویر برگ‌ها از دیتاست PlantVillage	۵
۲-۱	پراکندگی تعداد نمونه‌های هر کلاس در دیتاست PlantVillage پیش از متوازن‌سازی	۷
۳-۱	پراکندگی تعداد نمونه‌های هر کلاس در دیتاست PlantVillage پس از متوازن‌سازی	۷
۴-۱	نمونه تصاویر برگ‌ها از دیتاست PlantDoc	۸
۱-۲	ساختار شبکه‌های CNN - اخذ شده از مرجع [۱۷]	۱۶
۲-۲	نمونه‌هایی از مکانیزم‌های توجه در پردازش تصویر - اخذ شده از مرجع [۳۷]	۱۹
۱-۴	نمودار Accuracy و Loss مدل EfficientNetB0	۶۹
۲-۴	نمودار Accuracy و Loss مدل MobileNetV2	۷۰
۳-۴	نمودار Accuracy و Loss مدل ResNet50	۷۱
۴-۴	ماتریس درهم‌ریختگی مدل EfficientNetB0	۷۲
۵-۴	ماتریس درهم‌ریختگی مدل MobileNetV2	۷۲
۶-۴	ماتریس درهم‌ریختگی مدل ResNet50	۷۳
۷-۴	ماتریس درهم‌ریختگی مدل Ensemble: EfficientNetB0 + MobileNetV2	۷۴
۸-۴	ماتریس درهم‌ریختگی مدل Ensemble: EfficientNetB0 + MobileNetV2 + ResNet50	۷۵
۹-۴	نمودار تغییرات توابع هزینه شامل box loss, classification loss و distribution	
۷۷	focal loss در طول فرآیند آموزش و اعتبارسنجی مدل	
۱۰-۴	روند تغییرات معیارهای ارزیابی شامل Precision, Recall و mAP در مراحل مختلف	
۷۷	آموزش که بیانگر بهبود تدریجی عملکرد مدل می‌باشد	
۱۱-۴	نمونه‌ای از خروجی مدل YOLOX+ConvNeXt+CBAM در تشخیص بیماری برگ؛ جعبه‌های سبز رنگ نشان‌دهنده برچسب واقعی (Ground Truth) و جعبه‌های قرمز رنگ بیانگر نواحی پیش‌بینی شده توسط مدل هستند	۷۸
۱۲-۴	نمونه‌ای از خروجی مدل YOLOX+ConvNeXt+CBAM در تشخیص بیماری برگ؛ جعبه‌های سبز رنگ نشان‌دهنده برچسب واقعی (Ground Truth) و جعبه‌های قرمز رنگ بیانگر نواحی پیش‌بینی شده توسط مدل هستند	۷۹

- ۱۳-۴ نقشه‌های حرارتی (Heatmap) استخراج‌شده از خروجی مدل که نواحی با بیشترین میزان تمرکز و اهمیت در فرآیند تصمیم‌گیری مدل را نمایش می‌دهند. ۸۰
- ۱۴-۴ نقشه‌های حرارتی (Heatmap) استخراج‌شده از خروجی مدل که نواحی با بیشترین میزان تمرکز و اهمیت در فرآیند تصمیم‌گیری مدل را نمایش می‌دهند. ۸۱
- ۱۵-۴ نمونه‌ای از ماسک استخراج‌شده برگ بر اساس پردازش تصویر، که به‌منظور تفکیک ناحیه برگ از پس‌زمینه و تحلیل دقیق‌تر ناحیه بیماری ارائه شده است. ۸۲

فهرست جداول

صفحه

جدول

۶	۱-۱ توزیع دسته‌های سالم و بیمار گونه‌های گیاهی دیتاست PlantVillage
۹	۲-۱ توزیع دسته‌های سالم و بیمار گونه‌های گیاهی دیتاست PlantDoc
۲۶	۱-۳ مقایسه‌ی معماری‌های CNN - برگرفته از مرجع [۳۳]
۲۷	۲-۳ دقت CNN‌های مختلف در تشخیص بیماری برگ گیاهان - برگرفته از مرجع [۱۷]
۴۰	۳-۳ مقایسه‌ی عملکرد مدل‌های پایه و مدل Ensemble - برگرفته از مرجع [۲۰]
۶۶	۱-۴ نتایج معیارهای ارزیابی هر کلاس برای EfficientNetB0
۶۷	۲-۴ نتایج معیارهای ارزیابی هر کلاس برای MobileNetV2
۶۸	۳-۴ نتایج معیارهای ارزیابی هر کلاس برای ResNet50

فهرست نمادها و اختصارات

مفهوم	نماد / اختصار
Convolutional Block Attention Module – ماژول توجه بلوکی کانولوشنی	<i>CBAM</i>
Convolutional Neural Network – شبکه‌های عصبی کانولوشنی	<i>CNN</i>
Convolutional Networks (Next Generation)	<i>ConvNeXt</i>
Food Quality Standards – استانداردهای کیفیت مواد غذایی	<i>FAQ</i>
Hue, Saturation, Value – مدل رنگی	<i>HSV</i>
L^*a^*b – مدل رنگی	<i>Lab</i>
mean Average Precision – میانگین دقت متوسط	<i>mAP</i>
Red, Green, Blue – مدل رنگی	<i>RGB</i>
You Only Look Once – Real Time الگوریتم شناسایی اشیا به صورت	<i>YOLO</i>

فصل ۱

مقدمات و کلیات

۱-۱ مقدمه کلی پروژه

کشاورزی به عنوان یکی از اصلی ترین ارکان تأمین امنیت غذایی، همواره نقشی حیاتی در پایداری اقتصادی و اجتماعی جوامع ایفا کرده است. یکی از مهم ترین چالش هایی که سال ها گریبان گیر بخش کشاورزی بوده، بروز و گسترش بیماری های گیاهی است. این بیماری ها می توانند به سرعت در سطح مزرعه منتشر شده و خسارت های قابل توجهی به بار آورند. بر اساس گزارش های سازمان خواربار و کشاورزی ملل متحد^۱ سالانه درصد قابل توجهی از محصولات کشاورزی جهان به دلیل بیماری های گیاهی دچار افت کیفیت یا کاهش عملکرد می شوند. این امر نشان می دهد که کنترل بیماری ها نه تنها یک موضوع تخصصی در گیاه پزشکی، بلکه جزئی جدایی ناپذیر از مدیریت پایدار محصول و امنیت غذایی محسوب می شود.

روش های سنتی تشخیص بیماری، مبتنی بر بررسی چشمی توسط کشاورزان یا متخصصان، دارای محدودیت هایی محسوس هستند. این روش ها غالباً نیازمند تجربه طولانی، حضور فیزیکی کارشناس، صرف زمان زیاد و هزینه های بالا هستند. علاوه بر این، برخی بیماری ها در مراحل ابتدایی بروز، علائم ظریف و تقریباً نامحسوسی ایجاد می کنند که تشخیص آنها حتی برای کارشناسان نیز دشوار است. پیچیدگی زیستی عوامل بیماری زا و تغییرات ظاهری برگ تحت تأثیر شرایط محیطی نیز چالش دیگری است که روش های سنتی را با خطاهای متعدد روبه رو می کند. از این رو، بهره گیری از روش های نوین و هوشمند برای شناسایی دقیق و سریع بیماری های گیاهی به ضرورتی اجتناب ناپذیر تبدیل شده است. با پیشرفت فناوری های محاسباتی و ظهور مدل های یادگیری عمیق، امکان تحلیل خودکار و هوشمند تصاویر در سطحی فراهم شده است که در گذشته قابل تصور نبود. امروزه شبکه های عصبی کانولوشنی با توان استخراج ویژگی های بصری پیچیده از تصاویر برگ می توانند بیماری ها را با دقتی فراتر از روش های سنتی تشخیص دهند. هم زمان، مدل های تشخیص شیء مانند YOLO^۲ امکان شناسایی ناحیه دقیق بیماری را فراهم می کنند؛ قابلیتی که برای استفاده عملی در مزرعه ضروری است. پردازش تصویر نیز به عنوان سنگ بنای تمامی این روش ها عمل کرده و کیفیت داده ورودی را تضمین می کند.

هدف پروژه حاضر توسعه یک سامانه هوشمند شناسایی بیماری های گیاهی است که ترکیبی از روش های طبقه بندی تصویر و تشخیص ناحیه را در دو سطح داده های کنترل شده و داده های واقعی به کار می گیرد. در مرحله نخست، مدل های مختلف شبکه های عصبی مانند AlexNet، EfficientNetB0، MobileNetV2

^۱FAQ

^۲You Only Look Once

و ResNet50 روی دیتاست^۳ استاندارد PlantVillage آموزش داده شده‌اند. در ادامه، با طراحی یک مدل Ensemble، دقت طبقه‌بندی به سطح بسیار بالایی رسیده است. گام دوم پروژه تمرکز بر استفاده از مدل YOLOX و ترکیب آن با ساختارهای ConvNeXt^۴ و مکانیزم توجه CBAM^۵ است تا بتوان بیماری را در تصاویر واقعی PlantDoc شناسایی کرد. این دو مرحله در کنار یکدیگر چارچوبی قدرتمند و قابل اعتماد برای پایش سلامت گیاهان ایجاد می‌کنند.

۱-۲ بیان مسئله

تشخیص بیماری‌ها یکی از فرآیندهای اساسی و حساس در مدیریت سلامت گیاهان به شمار می‌رود. نبود یک سیستم دقیق و سریع برای تشخیص به‌موقع بیماری‌ها می‌تواند موجب گسترش ناگهانی عوامل بیماری‌زا شده و پیامدهایی مانند کاهش کیفیت محصول، هزینه‌های درمان بالا و اتلاف منابع را به همراه داشته باشد. مسئله زمانی پیچیده‌تر می‌شود که بدانیم بسیاری از بیماری‌های گیاهی در مراحل اولیه به‌صورت لکه‌های کوچک، تغییرات جزئی رنگ، یا الگوهای خفیف روی برگ ظاهر می‌شوند. تشخیص این الگوهای ظریف، حتی برای افراد خبره، دشوار است.

از سوی دیگر، داده‌های گیاهی در محیط واقعی دارای پیچیدگی‌های قابل توجهی هستند. برگ‌ها در شرایط نوری متفاوت، زوایای مختلف، پس‌زمینه‌های شلوغ و در کنار سایر اجزاء گیاه قرار می‌گیرند. این عوامل باعث می‌شود که روش‌های ساده تحلیل تصویر قادر به شناسایی صحیح بیماری‌ها نباشند. بنابراین، مسئله اصلی این است که چگونه می‌توان سیستمی ایجاد کرد که هم در محیط آزمایشگاهی و هم در شرایط واقعی مزرعه عملکرد قابل اعتمادی داشته باشد.

پروژه حاضر تلاش می‌کند پاسخی جامع به این مسئله ارائه دهد. در مرحله اول، تصاویر کنترل‌شده و تمیز از مجموعه داده PlantVillage برای آموزش مدل‌های طبقه‌بندی استفاده شده‌اند. این مرحله امکان تحلیل ویژگی‌های بیماری در شرایط استاندارد را فراهم می‌کند. اما از آنجا که هدف نهایی کاربرد عملی است، مدل باید در برابر داده‌های واقعی نیز مقاوم باشد. بنابراین مرحله دوم شامل توسعه یک مدل تشخیص ناحیه با استفاده از YOLOX بر روی مجموعه پیچیده PlantDoc است. چالش اصلی پروژه، ایجاد یک سیستم دوگانه است که ترکیبی از دقت بالای طبقه‌بندی و انعطاف‌پذیری تشخیص ناحیه را

^۳ Dataset

^۴ Convolutional Neural Network Backbone

^۵ Convolutional Block Attention Module

ارائه دهد.

۳-۱ اهداف پروژه

هدف کلی این پروژه، طراحی و توسعه یک سامانه هوشمند برای شناسایی بیماری‌های گیاهان بر اساس پردازش تصویر و یادگیری عمیق است. این هدف کلی شامل چند هدف اختصاصی می‌شود. نخستین هدف، تحلیل و مقایسه معماری‌های مختلف شبکه‌های عصبی روی داده‌های کنترل‌شده است تا مناسب‌ترین مدل برای طبقه‌بندی بیماری‌ها شناسایی شود. در این راستا چهار معماری کلاسیک AlexNet، EfficientNetB0، MoblieNetV2 و ResNet50 مورد بررسی قرار گرفته‌اند. هدف دوم، طراحی یک مدل Ensemble و بهبود عملکرد طبقه‌بندی با ترکیب خروجی چند شبکه عمیق است. در مرحله سوم، توسعه یک مدل تشخیص ناحیه مبتنی بر YOLOX برای داده‌های واقعی PlantDoc مدنظر بوده است تا سامانه بتواند بیماری را در محیط پیچیده مزرعه تشخیص دهد. هدف دیگر، بررسی نقش مکانیزم‌های توجه به‌ویژه CBAM در بهبود دقت تشخیص ناحیه بوده است.

نهایتاً هدف کاربردی پروژه ارائه سیستمی است که بتواند در کشاورزی هوشمند مورد استفاده قرار گیرد. سیستمی که هم سریع باشد، هم دقیق، هم در شرایط واقعی مزرعه قابل استفاده باشد و هم به کشاورزان در تصمیم‌گیری‌های مدیریتی کمک کند. این سیستم می‌تواند به کاهش مصرف سموم، کاهش خسارت‌های ناشی از بیماری و افزایش بهره‌وری کمک کند.

۴-۱ ضرورت و اهمیت استفاده از یادگیری عمیق در کشاورزی

یادگیری عمیق به دلیل توانایی استخراج ویژگی‌های سطح بالا و تحلیل پیچیدگی‌های بصری، به ابزاری کلیدی در پردازش تصاویر تبدیل شده است. در سال‌های اخیر، استفاده از مدل‌های CNN^۶ و YOLO در حوزه تشخیص بیماری‌های گیاهی رشد چشمگیری داشته است. یادگیری عمیق برخلاف روش‌های کلاسیک که نیازمند مهندسی دستی ویژگی‌ها بودند، قادر است ویژگی‌ها را به‌طور خودکار از داده استخراج کند. این مزیت باعث می‌شود که مدل بتواند علائم اولیه بیماری را بهتر تشخیص دهد.

نکته مهم دیگر این است که یادگیری عمیق، امکان تحلیل داده‌های غیرساختاریافته و پیچیده مانند تصاویر گیاهی را فراهم می‌کند. داده‌های گیاهی دارای تنوع زیادی در شکل، رنگ، بافت و زاویه هستند


^۶ Convolutional Neural Network

و مدل‌های کلاسیک در برابر این تنوع آسیب‌پذیرند. مدل‌های عمیق می‌توانند این تنوع را فرا بگیرند و قابلیت تعمیم بالایی داشته باشند. از سوی دیگر، سرعت مدل‌هایی مانند YOLO به حدی است که امکان استفاده عملی در مزرعه و حتی استفاده بر روی گوشی‌های هوشمند را فراهم می‌کند. این ویژگی‌ها باعث شده است که مدل‌های عمیق به یکی از ستون‌های اصلی کشاورزی هوشمند تبدیل شوند.

۵-۱ معرفی داده‌ها و چالش‌های مرتبط

۱-۵-۱ مجموعه داده PlantVillage

PlantVillage یکی از مشهورترین و پراستفاده‌ترین دیتاست‌ها در حوزه تشخیص بیماری گیاهان است [۳۲]، [۲۲، ۳۰]. این مجموعه شامل تصاویر برگ‌های بیمار و سالم در محیط کنترل شده است. پس‌زمینه تصاویر یکدست بوده و نور یکنواختی بر روی برگ تابیده شده است. این دیتاست شامل ۱۴ محصول کشاورزی در وضعیت سالم و بیمار است که فهرست آنها در جدول ۱-۱ آمده است.




شکل ۱-۱: نمونه تصاویر برگ‌ها از دیتاست PlantVillage

جدول ۱-۱: توزیع دسته‌های سالم و بیمار گونه‌های گیاهی دیتاست PlantVillage


شماره	نام گیاه	تعداد دسته سالم	تعداد دسته بیمار	تعداد کل دسته‌ها
۱	سیب (Apple)	۱	۳	۴
۲	بلوبری (Blueberry)	۱	-	۱
۳	گیلاس (Cherry)	۱	۱	۲
۴	ذرت (Corn)	۱	۳	۴
۵	انگور (Grape)	۱	۳	۴
۶	پرتقال (Orange)	-	۱	۱
۷	گلابی (Peach)	۱	۱	۲
۸	فلفل (Pepper)	۱	۱	۲
۹	سیب‌زمینی (Potato)	۱	۲	۳
۱۰	تمشک (Raspberry)	۱	-	۱
۱۱	دانه سویا (Soybean)	۱	-	۱
۱۲	کدو (Squash)	-	۱	۱
۱۳	توت‌فرنگی (Strawberry)	۱	۱	۲
۱۴	گوجه‌فرنگی (Tomato)	۱	۹	۱۰

این ویژگی‌ها باعث می‌شود مدل‌های طبقه‌بندی در این مجموعه داده عملکرد بسیار خوبی ارائه دهند. در این پروژه از این مجموعه داده برای مرحله طبقه‌بندی استفاده شده و مدل‌ها توانسته‌اند به دقت‌های بسیار بالا دست یابند. این دیتاست در ابتدا شامل ۵۴،۳۰۵ تصویر بود که پس از توازن کلاس‌ها تعداد آن به ۲۰۹،۲۶۶ تصویر افزایش یافت. تصاویر در قالب RGB^۷ و با ابعاد ۲۵۶×۲۵۶ پیکسل می‌باشند.

^۷Red Green Blue



شکل ۱-۲: پراکندگی تعداد نمونه‌های هر کلاس در دیتاست PlantVillage پیش از متوازن سازی



شکل ۱-۳: پراکندگی تعداد نمونه‌های هر کلاس در دیتاست PlantVillage پس از متوازن سازی

۱-۵-۲ مجموعه داده PlantDoc

برخلاف PlantVillage، دیتاست PlantDoc در محیط واقعی ثبت شده است و یکی از چالش برانگیزترین مجموعه داده‌ها در حوزه تشخیص بیماری گیاهان محسوب می‌شود [۳۱، ۳۰]. تصاویر این مجموعه دارای تنوع گسترده‌ای در نور، زاویه دید، پس‌زمینه، شرایط محیطی و کیفیت ثبت هستند. این عوامل باعث می‌شود مدل‌های طبقه‌بندی که در شرایط کنترل‌شده عملکرد مطلوبی دارند، در این مجموعه با افت دقت مواجه شوند و بنابراین استفاده از مدل‌های تشخیص ناحیه مانند YOLOX ضرورت پیدا می‌کند. این دیتاست شامل تصاویر برگ ۱۳ محصول کشاورزی در وضعیت سالم و بیمار است که فهرست آن‌ها

در جدول ۲-۱ ارائه شده است. دیتاست PlantDoc شامل ۲۵۹۸ تصویر از برگ گیاهان بوده و تصاویر در ابعاد ۴۱۶×۴۱۶ پیکسل و در فضای رنگی RGB ثبت شده‌اند.



شکل ۴-۱: نمونه تصاویر برگ‌ها از دیتاست PlantDoc

جدول ۱-۲: توزیع دسته‌های سالم و بیمار گونه‌های گیاهی دیتاست PlantDoc

شماره	نام گیاه	تعداد دسته سالم	تعداد دسته بیمار	تعداد کل دسته‌ها
۱	سیب (Apple)	۱	۲	۳
۲	بلوبری (Blueberry)	۱	-	۱
۳	گیلاس (Cherry)	۱	-	۱
۴	ذرت (Corn)	-	۳	۳
۵	انگور (Grape)	۱	۱	۲
۶	فلفل دلمه‌ای (Bell Pepper)	۱	۱	۲
۷	هلو (Peach)	۱	-	۱
۸	سیب‌زمینی (Potato)	-	۲	۲
۹	تمشک (Raspberry)	۱	-	۱
۱۰	دانه سویا (Soybean)	۱	-	۱
۱۱	کدو (Squash)	-	۱	۱
۱۲	توت‌فرنگی (Strawberry)	۱	-	۱
۱۳	گوجه‌فرنگی (Tomato)	۱	۷	۸

۱-۵-۳ تفاوت بنیادی داده آزمایشگاهی و واقعی

این تفاوت دو دیتاست، یکی از اصلی‌ترین دلایلی است که پروژه حاضر از ساختار دو مرحله‌ای استفاده کرده است. داده‌های کنترل‌شده برای آموزش طبقه‌بندی مناسب هستند، اما داده‌های واقعی نیازمند مدل‌های مقاوم‌تری هستند. این موضوع در طراحی معماری پروژه نقش اساسی داشته است.

۱-۶ ساختار کلی پایان‌نامه

این پایان‌نامه از پنج فصل اصلی تشکیل شده است. در فصل اول به مقدمات و کلیات پایان‌نامه پرداخته شد. فصل دوم به مبانی پردازش تصویر و شبکه‌های عصبی در تشخیص بیماری‌های گیاهی اختصاص دارد. فصل سوم به مرور پژوهش‌های انجام‌شده در این حوزه و تحلیل روش‌های مختلف می‌پردازد.

در فصل چهارم، پیاده‌سازی، مدل‌ها، داده‌ها و نتایج ارائه شده است و فصل پنجم شامل نتیجه‌گیری و پیشنهادات برای پژوهش‌های آینده می‌باشد. این ساختار به خواننده کمک می‌کند تا با ترتیب منطقی مباحث، مسیر پژوهش را به صورت گام‌به‌گام دنبال کند.

۷-۱ جمع‌بندی

در این فصل تلاش شد ابعاد مختلف مسئله تشخیص بیماری‌های گیاهان معرفی شود و ضرورت استفاده از روش‌های مبتنی بر بینایی ماشین و یادگیری عمیق بیان گردد. همچنین ساختار پروژه و دلایل استفاده از دو رویکرد طبقه‌بندی و تشخیص ناحیه تشریح شد. مباحث مطرح‌شده در این فصل، زمینه ورود به فصل دوم را فراهم می‌کند؛ فصلی که در آن مبانی پردازش تصویر و یادگیری عمیق بررسی شده و چارچوب علمی لازم برای درک روش‌های به‌کاررفته در پروژه ارائه می‌شود.

فصل ۲

مبانی پردازش تصویر و شبکه‌های عصبی در تشخیص بیماری‌های گیاهی

۱-۲ مقدمه

تشخیص دقیق و سریع بیماری‌های گیاهی همواره یکی از دغدغه‌های اساسی در حوزه کشاورزی و تولید محصولات سالم و باکیفیت بوده است. بیماری‌ها می‌توانند تنها در مدت کوتاهی موجب آلودگی گسترده مزارع، کاهش شدید کیفیت محصولات و تحمیل هزینه‌های سنگین اقتصادی شوند. روش سنتی تشخیص بیماری‌ها که بر پایه مشاهده مستقیم توسط کشاورزان یا متخصصان گیاه‌پزشکی استوار است، علاوه بر آنکه نیازمند زمان و تجربه بالا است، در بسیاری از موارد نیز با خطای انسانی همراه می‌شود. از سوی دیگر، این روش‌ها نسبت به مرحله اولیه بروز بیماری حساسیت کافی ندارند و غالباً زمانی بیماری تشخیص داده می‌شود که آسیب قابل توجهی به محصول وارد شده است. در چنین شرایطی، بهره‌گیری از روش‌های نوین مبتنی بر پردازش تصویر و یادگیری عمیق می‌تواند راهکاری مؤثر برای ارتقای دقت، سرعت و قابلیت اطمینان تشخیص بیماری‌های گیاهی ارائه کند.

پیشرفت‌های وسیع در حوزه بینایی ماشین، شبکه‌های عصبی و سخت‌افزارهای پردازشی باعث شده است که سامانه‌های تشخیص خودکار بیماری‌های گیاهان نقش مهمی در توسعه کشاورزی هوشمند ایفا کنند. این سامانه‌ها قادرند از طریق تحلیل الگوهای ظریف موجود در تصاویر برگ، علائم بیماری را حتی در مراحل ابتدایی شناسایی کنند. پردازش تصویر، شبکه‌های عصبی کانولوشنی و مدل‌های پیشرفته تشخیص شیء همچون خانواده YOLO، توانسته‌اند قدرت قابل توجهی در تحلیل تصاویر پیچیده محیط واقعی از خود نشان دهند.

پروژه حاضر نیز در همین راستا تلاش کرده است تا از ترکیب دو رویکرد طبقه‌بندی تصویر^۱ و تشخیص شیء^۲ برای توسعه یک سامانه هوشمند تشخیص بیماری گیاهان استفاده کند. در این فصل، مبانی مرتبط با این دو حوزه بررسی می‌شود تا خواننده بتواند پایه‌های علمی مباحث پیاده‌سازی شده در فصل چهارم و تحلیل پژوهش‌های انجام شده در فصل سوم را به صورت یکپارچه درک کند. این فصل به چهار بخش اصلی تقسیم شده است: ابتدا پردازش تصویر و مفاهیم پایه‌ای آن معرفی می‌شود، سپس شبکه‌های عصبی کانولوشنی و ساختارهای مختلف آنها بررسی می‌گردد. در ادامه کاربرد یادگیری عمیق در تشخیص بیماری‌های گیاهی شرح داده می‌شود و سپس به صورت دقیق‌تر به معرفی روش‌های تشخیص شیء و نقش مکانیزم‌های توجه پرداخته خواهد شد. در پایان نیز جمع‌بندی مختصری ارائه می‌شود تا پیوندی مفهومی با فصل بعد برقرار گردد.

^۱ Classification

^۲ Object Detection

۲-۲ پردازش تصویر و جایگاه آن در تشخیص بیماری گیاهان

۱-۲-۲ تاریخچه پردازش تصویر در کشاورزی

پردازش تصویر از دهه‌های گذشته در علوم کشاورزی مورد استفاده قرار گرفته است. در ابتدا، این فناوری عمدتاً برای درجه‌بندی اندازه میوه‌ها، شناسایی لکه‌های خارجی و کنترل کیفیت محصولات به کار می‌رفت. این کاربردها غالباً با استفاده از روش‌های ساده استخراج ویژگی مانند تحلیل رنگ، بافت و لبه انجام می‌شد و محدودیت‌های فراوانی داشت. با رشد فناوری‌های تصویربرداری، سنسورهای قدرتمند و دوربین‌های دیجیتال پیشرفته، امکان ثبت تصاویر دقیق‌تر فراهم شد و پژوهشگران توانستند تحلیل‌های پیچیده‌تری بر روی داده‌های تصویر انجام دهند. به تدریج کاربرد پردازش تصویر از حوزه درجه‌بندی محصولات به حوزه تشخیص آفات، تشخیص بیماری، ارزیابی رشد، سنجش از دور و نظارت بر سلامت گیاهان گسترش یافت. اما نقطه تحول اصلی زمانی رخ داد که یادگیری عمیق وارد این حوزه شد و امکان استخراج خودکار ویژگی‌ها از تصاویر گیاهی فراهم گردید.

۲-۲-۲ ماهیت تصویر دیجیتال و اصول پایه

برای اینکه یک سیستم پردازش تصویر بتواند بیماری گیاه را شناسایی کند، لازم است تصویر دیجیتال به شکل صحیحی تحلیل شود. تصویر در ساده‌ترین تعریف خود، ماتریسی از پیکسل‌هاست که هر پیکسل یک مقدار روشنایی یا سه مقدار رنگی را در مدل RGB نشان می‌دهد. این ماتریس تصویری ممکن است تحت تأثیر عواملی مانند شدت نور، سایه‌ها، کنتراست، انعکاس، زاویه ثبت تصویر و کیفیت دوربین قرار گیرد. در تحلیل بیماری‌های گیاهی، بسیاری از ویژگی‌های مهم مانند رنگ لکه‌ها، شکستگی‌های بافت و تغییرات جزئی رگبرگ‌ها تنها زمانی به خوبی قابل تشخیص هستند که تصویر کیفیت مناسبی داشته باشد. بنابراین، فهم ماهیت تصویر دیجیتال و نحوه تشکیل آن، برای طراحی مراحل پردازش تصویر ضروری است.

فضاهای رنگی مختلف مانند HSV^۳ و Lab می‌توانند برای تحلیل رنگ برگ‌ها مناسب‌تر باشند، زیرا برخی از بیماری‌ها تغییرات رنگی بسیار ظریفی ایجاد می‌کنند که در فضای RGB به خوبی قابل تمایز نیستند. شناخت این فضاها و نحوه تبدیل آنها به یکدیگر، نقش مهمی در کیفیت استخراج ویژگی‌ها دارد.

^۳ Hue Saturation Value

۲-۲-۳ نقش پیش‌پردازش در آماده‌سازی داده

پیش‌پردازش مرحله‌ای اساسی است که پیش از ورود تصاویر به مدل یادگیری عمیق انجام می‌شود. هدف این مرحله یکسان‌سازی ویژگی‌های تصویری، حذف نویزها، تنظیم روشنایی و افزایش کیفیت داده‌ها برای بهبود دقت مدل است. در بسیاری از تصاویر برگ، نویز ناشی از حرکت دوربین، لرزش دست، تغییرات نور محیطی، سایه‌ها یا انعکاس نور در سطح برگ مشاهده می‌شود که می‌تواند عملکرد مدل را مختل کند. فیلترهای حذف نویز مانند Median یا Gaussian برای کاهش این مشکلات استفاده می‌شوند. الگوریتم‌های افزایش داده یا Data Augmentation نیز نقش مهمی در بهبود تعمیم مدل دارند. این عملیات شامل چرخش تصویر، جابه‌جایی، تغییر روشنایی، وارونگی، برش تصادفی و تغییرات مصنوعی رنگ است. این روش به‌ویژه در تصاویر واقعی مانند PlantDoc اهمیت دارد، زیرا در چنین داده‌هایی احتمال ثبت تصاویر در زوایا، نورها و شرایط متفاوت بسیار زیاد است. در صورتی که پیش‌پردازش انجام نشود، مدل ممکن است تنها بر اساس نمونه‌های خاص یاد بگیرد و در مواجهه با تصاویر جدید عملکرد ضعیفی نشان دهد.

۲-۲-۴ چالش‌های پردازش تصویر در تشخیص بیماری‌های گیاهی

تصاویر برگ‌ها در محیط واقعی پیچیدگی‌های فراوانی دارند. سایه‌های طبیعی، وجود شاخه‌ها، میوه‌ها و خاک در پس‌زمینه، تغییرات شدید نور در طول روز، حرکت برگ‌ها توسط باد و همپوشانی برگ‌ها با یکدیگر از جمله عواملی هستند که تشخیص بیماری را دشوار می‌سازند. علاوه بر این، بسیاری از بیماری‌ها الگوهای مشابهی دارند؛ به عنوان مثال، لکه‌های ناشی از بیماری‌های قارچی ممکن است در ظاهر شبیه علائم کمبود مواد غذایی باشند. این شباهت‌ها تشخیص بیماری را تنها بر اساس پردازش تصویر کلاسیک بسیار دشوار می‌کند. از سوی دیگر، تعداد کلاس‌های بیماری و تنوع ظاهری برگ‌ها موجب می‌شود که مدل نیازمند توانایی استخراج ویژگی‌های عمیق باشد. این چالش‌ها ضرورت استفاده از مدل‌های یادگیری عمیق را بیش از پیش آشکار می‌سازد.

۲-۲-۵ تفاوت داده‌های کنترل‌شده و واقعی

یکی از مهم‌ترین تفاوت‌های موجود در حوزه تشخیص بیماری گیاهی، تفاوت میان داده‌های کنترل‌شده و داده‌های واقعی است. دیتاست‌هایی مانند PlantVillage در محیط کنترل‌شده و با پس‌زمینه یکدست

ثبت شده‌اند. نور ثابت و کیفیت مناسب تصاویر باعث می‌شود مدل‌های طبقه‌بندی مانند CNN عملکرد فوق‌العاده‌ای داشته باشند. اما در مقابل، دیتاست‌هایی مانند PlantDoc در محیط واقعی و با نور و پس‌زمینه کاملاً متنوع ثبت شده‌اند. در این شرایط، مدل‌های طبقه‌بندی کارایی مطلوبی ندارند و نیاز به مدل‌های تشخیص ناحیه احساس می‌شود.


۲-۳ شبکه‌های عصبی کانولوشنی و یادگیری عمیق

۲-۳-۱ مقدمه‌ای بر شبکه‌های عصبی

شبکه‌های عصبی مصنوعی ساختاری الهام‌گرفته از مغز انسان هستند که از مجموعه‌ای از نورون‌ها تشکیل شده‌اند. هر نورون قادر است مجموعه‌ای از ورودی‌ها را دریافت کرده و با اعمال وزن‌های مختلف بر آنها، یک خروجی تولید کند. لایه‌های مختلف این نورون‌ها تشکیل‌دهنده شبکه‌های چندلایه هستند که می‌توانند روابط پیچیده را مدل‌سازی کنند. یادگیری در شبکه‌های عصبی از طریق بهینه‌سازی وزن‌ها انجام می‌شود و هدف آن کاهش خطای پیش‌بینی است. یادگیری عمیق زمانی محقق می‌شود که این شبکه‌ها دارای تعداد زیادی لایه باشند و بتوانند الگوهای پیچیده را از داده‌ها استخراج کنند.

۲-۳-۲ ساختار شبکه‌های عصبی کانولوشنی

شبکه‌های کانولوشنی معماری ویژه‌ای از شبکه‌های عصبی هستند که برای تحلیل داده‌های تصویری طراحی شده‌اند. این شبکه‌ها با استفاده از لایه‌های کانولوشن قادرند ویژگی‌های خاصی مانند مرزها، بافت‌ها و اشکال را از تصویر استخراج کنند. لایه‌های کانولوشن فیلترهایی را به صورت اسلاید بر روی تصویر اعمال می‌کنند و از طریق این فیلترها ویژگی‌ها استخراج می‌شود. لایه‌های Pooling نیز برای کاهش ابعاد تصویر و جلوگیری از بیش‌برازش استفاده می‌شوند. در ادامه، لایه‌های Dense یا Fully Connected قرار دارند که هر نود آن‌ها به تمام نودهای لایه قبلی متصل است. این لایه‌ها وظیفه ترکیب ویژگی‌های استخراج‌شده و تصمیم‌گیری نهایی درباره کلاس تصویر را بر عهده دارند. لایه‌های Dense به شبکه امکان می‌دهند تا روابط پیچیده بین ویژگی‌ها را یاد بگیرد و به پیش‌بینی دقیق‌تر کلاس‌ها دست یابد. کل این فرایند موجب می‌شود که CNN‌ها ابزارهایی قدرتمند برای تحلیل تصاویر برگ و تشخیص بیماری‌های گیاهی باشند.



شکل ۲-۱: ساختار شبکه‌های CNN - اخذ شده از مرجع [۱۷]

۲-۳-۳ سلسله‌مراتب ویژگی‌ها در CNN و تشخیص بیماری

یکی از مهم‌ترین ویژگی‌های CNN، قابلیت استخراج سلسله‌مراتبی ویژگی‌ها از تصویر است. لایه‌های اولیه، ویژگی‌های سطح پایین مانند لبه‌ها، زوایا و تغییرات ساده رنگ را استخراج می‌کنند. در مقابل، لایه‌های میانی بافت‌ها، الگوهای نقطه‌ای و ساختارهای پیچیده‌تر را می‌آموزند. و در نهایت لایه‌های عمیق‌تر، نمایشی انتزاعی از تصویر تولید می‌کنند که می‌تواند برای طبقه‌بندی بیماری بسیار مؤثر باشد. برای مثال، در تصاویر متعلق به بیماری قارچی، ممکن است الگوی مشخصی از نقاط تیره و تغییرات سطحی وجود داشته باشد که تنها توسط لایه‌های عمیق CNN قابل شناسایی است.

۲-۳-۴ معرفی معماری‌های CNN مورد استفاده در پروژه

در این پروژه از چند معماری مطرح CNN استفاده شده است که هر یک نقش مهمی در تکامل روش‌های بینایی ماشین ایفا کرده‌اند. AlexNet به عنوان نخستین معماری موفق در رقابت ImageNet نشان داد که شبکه‌های عمیق قادرند ویژگی‌های پیچیده را از تصاویر استخراج کنند و نقطه عطفی در گسترش یادگیری عمیق به شمار می‌رود.

EfficientNet با معرفی مفهوم مقیاس‌گذاری متوازن^۴ میان عمق شبکه، عرض لایه‌ها و وضوح تصویر، توانست در عین حفظ دقت بالا، کارایی محاسباتی بسیار مناسبی ارائه دهد. این معماری نشان داد که افزایش صرف عمق یا تعداد پارامترها لزوماً به بهبود عملکرد منجر نمی‌شود و طراحی بهینه شبکه نقش

^۴Balanced Scaling

کلیدی در دستیابی به نتایج برتر دارد.

MobileNet با بهره‌گیری از کانولوشن‌های عمق‌جدا سازی شده^۵ مدلی سبک و کم‌حجم ارائه می‌دهد که برای کاربردهای عملی و محیط‌های دارای محدودیت محاسباتی بسیار مناسب است. این معماری امکان استقرار مدل‌های یادگیری عمیق را روی دستگاه‌هایی مانند تلفن‌های همراه و سامانه‌های تعبیه‌شده فراهم می‌کند، بدون آن‌که افت قابل توجهی در دقت طبقه‌بندی تصاویر ایجاد شود. در نهایت، ResNet با معرفی اتصالات میان‌بر^۶ مشکل محوشدن گرادیان^۷ در شبکه‌های عمیق را به‌طور مؤثری برطرف کرد و امکان آموزش شبکه‌هایی با عمق بسیار زیاد را فراهم ساخت. این معماری به‌عنوان یکی از تأثیرگذارترین دستاوردهای یادگیری عمیق شناخته می‌شود و پایه بسیاری از مدل‌های پیشرفته امروزی، از جمله ساختارهای مورد استفاده در این پروژه، را تشکیل می‌دهد.

۲-۳-۵ دلایل کاربرد CNN در تشخیص بیماری‌های گیاهان

CNNها به دلیل ساختار سلسله‌مراتبی خود که شباهت زیادی به نحوه پردازش بینایی انسان دارد، برای تشخیص بیماری‌های گیاهی بسیار مناسب هستند. این مدل‌ها قادرند تغییرات ظاهری پیچیده در برگ‌ها را یاد بگیرند و نسبت به روش‌های سنتی دقت به مراتب بالاتری ارائه دهند. از سوی دیگر، این شبکه‌ها نسبت به تغییرات نور، زاویه و موقعیت اجسام مقاومت بیشتری دارند، که این ویژگی برای تصاویر واقعی برگ‌ها بسیار ارزشمند است.

۲-۴ تشخیص ناحیه بیماری در تصاویر واقعی

۲-۴-۱ ضرورت تشخیص ناحیه در مقابل طبقه‌بندی تصویر

طبقه‌بندی تصویر تنها مشخص می‌کند که برگ بیمار است یا نه، اما در کاربردهای عملی این کافی نیست. در بسیاری از موارد، تنها بخشی از برگ دچار بیماری شده است و تشخیص این ناحیه دقیق برای اقدامات بعدی مانند سم‌پاشی یا هرس ضروری است. بنابراین، مدل‌های تشخیص ناحیه نقش مهمی در تشخیص بیماری‌ها دارند.

^۵Depthwise Separable Convolutions

^۶Skip Connections

^۷Vanishing Gradient

۲-۴-۲ معرفی روش‌های دو مرحله‌ای و تک‌مرحله‌ای

روش‌های دو مرحله‌ای مانند ⁸Faster R-CNN ابتدا نواحی پیشنهادی را شناسایی کرده و سپس این نواحی را تحلیل می‌کنند. اگرچه این روش‌ها دقت بسیار بالایی دارند، اما سرعت آنها برای کاربردهای real-time کافی نیست. روش‌های تک‌مرحله‌ای مانند YOLO تمام مراحل را در یک مرحله انجام می‌دهند و قادرند با سرعت بالا و دقت قابل قبول تشخیص ناحیه را انجام دهند.

۳-۴-۲ خانواده YOLO و تکامل YOLOX

خانواده YOLO یکی از موفق‌ترین معماری‌های تشخیص شیء است که از YOLOv1 تا نسخه‌های جدید مانند YOLOv8 و YOLOX تکامل یافته است. YOLOX با معرفی معماری anchor-free head، تفکیک‌شده و الگوریتم تخصیص نمونه SimOTA، عملکرد بسیار خوبی در تشخیص اشیاء کوچک مانند لکه‌های بیماری نشان داده است. این ویژگی‌ها باعث شده‌اند YOLOX برای تحلیل تصاویر گیاهی با چالش‌های فراوان مناسب باشد.

۴-۴-۲ چالش‌های تشخیص ناحیه در تصاویر واقعی گیاه

در تصاویر واقعی برگ‌ها، ناهنجاری‌های بصری و نویزهای فراوانی وجود دارد. ممکن است برگ در کنار شاخه‌ها، خاک یا میوه‌ها قرار داشته باشد یا نور خورشید باعث ایجاد بازتاب شده باشد. این عوامل باعث می‌شوند که مدل‌های ساده تشخیص ناحیه عملکرد مناسبی نداشته باشند. YOLOX و مدل‌های مشابه با استفاده از معماری‌های پیچیده‌تر قادر به مقابله با این چالش‌ها هستند.

۵-۴-۲ دلایل انتخاب YOLOX در پروژه


در پروژه حاضر YOLOX به دلیل قابلیت‌های بالا در تشخیص ناحیه و مقاومت در برابر داده‌های متنوع PlantDoc انتخاب شده است. بازدهی بالا، سرعت مناسب و توانایی در شناسایی ناحیه بیماری حتی در تصاویر پیچیده از دلایل انتخاب این مدل بوده‌اند.

⁸Region-Based Convolutional Neural Network

۵-۲ مکانیزم‌های توجه و نقش آنها در تشخیص بیماری گیاهی

۱-۵-۲ مفهوم توجه در یادگیری عمیق

مکانیزم‌های توجه به شبکه‌ها کمک می‌کنند تا بخش‌های مهم‌تر تصویر را برجسته‌تر کرده و بخش‌های غیرمرتبط را بی‌اهمیت کنند. این روش شباهت زیادی به نحوه تمرکز چشم انسان بر روی نواحی مهم دارد.



شکل ۲-۲: نمونه‌هایی از مکانیزم‌های توجه در پردازش تصویر - اخذ شده از مرجع [۳۷]

۲-۵-۲ توجه کانالی و مکانی

توجه کانالی اهمیت هر کانال ویژگی را مشخص می‌کند، در حالی که توجه مکانی تعیین می‌کند که مدل باید بر کدام ناحیه از تصویر تمرکز بیشتری داشته باشد.

۳-۵-۲ مکانیزم CBAM و نحوه استفاده آن در پروژه

CBAM یک مکانیزم توجه ترکیبی است که هم توجه کانالی و هم توجه مکانی را در خود دارد. این مکانیزم هنگامی که در YOLOX به کار گرفته می‌شود کمک می‌کند مدل بتواند لکه‌های بیماری را بهتر تشخیص دهد و نسبت به نواحی غیرمفید تصویر بی‌تفاوت باشد.

۲-۵-۴ اهمیت توجه در داده‌های گیاهی

داده‌های گیاهی دارای عناصر مزاحم زیادی در پس‌زمینه هستند و استفاده از مکانیزم‌های توجه باعث می‌شود مدل بتواند روی ناحیه اصلی بیماری تمرکز کند. این موضوع به دقت مدل کمک زیادی می‌کند.

۲-۶ جمع‌بندی

در این فصل مبانی مورد نیاز برای تحلیل و درک فرایند تشخیص بیماری‌های گیاهان مبتنی بر پردازش تصویر و یادگیری عمیق ارائه شد. ابتدا به معرفی مفاهیم پایه‌ای پردازش تصویر پرداخته شد و اهمیت مراحل پیش‌پردازش و استخراج ویژگی‌ها بیان گردید. سپس ساختار شبکه‌های عصبی کانولوشنی توضیح داده شد و معماری‌های مهمی که در پروژه حاضر مورد استفاده قرار گرفته‌اند تشریح شد. در ادامه ضرورت استفاده از مدل‌های تشخیص ناحیه در محیط‌های واقعی بیان شد و مدل YOLOX به عنوان یکی از دقیق‌ترین و سریع‌ترین روش‌های مناسب برای این حوزه معرفی شد. در نهایت نقش مکانیزم‌های توجه و اهمیت آن در بهبود عملکرد مدل در تصاویر گیاهی بررسی شد. این مباحث پایه و زیربنای علمی فصل‌های بعدی هستند. در فصل سوم به بررسی پژوهش‌های مرتبط پرداخته خواهد شد تا جایگاه پروژه حاضر در میان مطالعات پیشین مشخص گردد.

فصل ۳

مروری بر پژوهش‌ها و مدل‌های موجود در تشخیص بیماری‌های گیاهان

۳-۱ مقدمه و تاریخچه روش‌های کلاسیک در تشخیص بیماری

گیاهان

مطالعه پژوهش‌های مرتبط با تشخیص بیماری‌های گیاهی نشان می‌دهد که این حوزه طی دو دهه اخیر تحولی عمیق را تجربه کرده است. اگر در دهه ۲۰۰۰ تشخیص بیماری‌ها صرفاً به مشاهده چشمی کشاورزان و متخصصان وابسته بود، امروزه فناوری‌های بینایی ماشین و یادگیری عمیق امکان تحلیل خودکار و دقیق تصاویر برگ را فراهم کرده‌اند. این تحول نه تنها به دلیل پیشرفت الگوریتم‌ها بلکه به دلیل گسترش حجم داده‌های تصویری، استفاده از دوربین‌های با کیفیت در تلفن‌های همراه و توسعه سخت‌افزارهای پردازشی مانند GPU امکان‌پذیر شد.

ضرورت پژوهش در این حوزه از آنجا نشأت می‌گیرد که بیماری‌های گیاهی می‌توانند اثرات مخربی بر تولیدات کشاورزی داشته باشند. در بسیاری از کشورها، کشاورزان به دلیل گستردگی مزارع، کمبود نیروهای متخصص و تأخیر در تشخیص، خسارت‌های اقتصادی سنگینی متحمل می‌شوند. این واقعیت موجب شد پژوهشگران به سمت روش‌هایی حرکت کنند که بتوانند فرایند تشخیص را خودکار کرده و سرعت و دقت آن را افزایش دهند. بررسی پژوهش‌های انجام‌شده در جهان نشان می‌دهد که مسیر تحول این حوزه را می‌توان به سه دوره اصلی تقسیم کرد: دوره نخست شامل روش‌های کلاسیک و مبتنی بر استخراج ویژگی دستی است؛ دوره دوم با ظهور شبکه‌های عصبی کانولوشنی آغاز می‌شود؛ و دوره سوم به مدل‌های ترکیبی پیشرفته، تشخیص ناحیه و توجه اختصاص دارد.

در این فصل، ابتدا به بررسی دقیق روش‌های کلاسیک پردازش تصویر پرداخته می‌شود، سپس پژوهش‌های مبتنی بر CNN و روش‌های یادگیری عمیق طبقه‌بندی می‌گردند، و در ادامه مدل‌های Ensemble، انتقال یادگیری، تشخیص ناحیه، مدل‌های هیبرید و توجه تحلیل خواهند شد. این فصل نه تنها ارائه تاریخی و تحلیلی از پژوهش‌هاست، بلکه با تکیه بر مقالات متعدد ارسال‌شده توسط تو، ارتباط مستقیم آنها با پروژه حاضر نیز تشریح خواهد شد.

۳-۱-۱ تاریخچه روش‌های کلاسیک در تشخیص بیماری گیاهان

پیش از ظهور شبکه‌های عصبی و یادگیری عمیق، رایج‌ترین روش‌های پردازش تصویر در تشخیص بیماری گیاه مبتنی بر استخراج ویژگی‌های سطحی بودند. تصاویر برگ به‌عنوان ورودی سیستم در نظر گرفته می‌شدند و پژوهشگران تلاش می‌کردند با استفاده از روش‌های مبتنی بر رنگ، بافت، لبه و شکل، الگوهای

بصری مرتبط با بیماری را شناسایی کنند. این دوره که می‌توان آن را «دوره استخراج دستی ویژگی» نامید، از اوایل دهه ۱۹۹۰ آغاز شد و تا حدود سال‌های ۲۰۱۰ ادامه یافت.

در این روش‌ها معمولاً ابتدا تصویر به فضای رنگی مناسبی تبدیل می‌شد تا بتوان الگوهای رنگی مرتبط با بیماری را دقیق‌تر تحلیل کرد. فضای RGB، اگرچه رایج بود، اما برای تحلیل رنگ بیماری‌ها چندان مناسب نبود؛ بنابراین پژوهشگران اغلب از فضاهاى HSV یا Lab استفاده می‌کردند تا تفاوت‌های ظریف میان رنگ‌های سبز سالم و لکه‌های بیمار را ثبت کنند. برای مثال، در برخی بیماری‌ها مانند لکه‌های قارچی، تغییر رنگ از سبز به زرد یا قهوه‌ای رخ می‌دهد و این تغییرات در مؤلفه Hue در فضای HSV بهتر قابل تفکیک است.

روش‌های مبتنی بر بافت نیز نقش مهمی در این دوره داشتند. یکی از معروف‌ترین روش‌ها، استفاده از ماتریس هم‌وقوعی سطوح خاکستری^۱ بود که ویژگی‌هایی مانند همگنی، کنتراست، زبری و انرژی سطح را استخراج می‌کرد. بیماری‌هایی که منجر به تخریب بافت برگ می‌شدند معمولاً الگوهای متفاوتی در این ویژگی‌ها ایجاد می‌کردند. پژوهش انجام شده توسط Al-Hiary و همکاران، دقیقاً از همین رویکرد استفاده می‌کرد[۲]. در این پژوهش، ویژگی‌های بافتی و رنگی به‌صورت دستی استخراج و سپس وارد یک Classifier مانند SVM^۲ یا Random Forest می‌شدند.

یکی دیگر از رویکردهای رایج در این دوره، تحلیل شکل یا Morphological Analysis بود. بیماری‌هایی که منجر به تغییر شکل لکه‌های برگ می‌شدند، مانند آفات گاززننده، با تحلیل شکل و لبه قابل شناسایی بودند. پژوهش‌های قدیمی‌تر حتی از روش‌های مبتنی بر شمارش پیکسل‌های آسیب‌دیده برای تعیین شدت بیماری استفاده می‌کردند.

اما محدودیت‌های این دوره بسیار قابل توجه بود. نخست آنکه فرایند استخراج ویژگی دستی بسیار زمان‌بر و وابسته به تجربه پژوهشگر بود، بنابراین قابلیت تعمیم کمی داشت. دوم اینکه این روش‌ها در برابر تغییرات نور، زاویه تصویر، کیفیت دوربین و پس‌زمینه بسیار حساس بودند. کوچک‌ترین تغییر در شرایط تصویربرداری باعث می‌شد ویژگی‌های استخراج‌شده دچار خطا شوند. سوم اینکه روش‌های کلاسیک نمی‌توانستند روابط غیرخطی و پیچیده موجود در تصویر را درک کنند. این موضوع باعث می‌شد که بیماری‌هایی با الگوهای مشابه به سختی از یکدیگر تفکیک شوند. چهارم اینکه روش‌های کلاسیک توانایی تحلیل داده‌های حجیم و پیچیده را نداشتند و با افزایش تنوع داده، عملکرد آنها کاهش می‌یافت.

^۱ Gray-Level Co-occurrence Matrix

^۲ Support Vector Machine

همه این ضعف‌ها زمینه ورود روش‌های جدید را فراهم کرد. جامعه پژوهشی در ابتدای دهه ۲۰۱۰ به این نتیجه رسید که تشخیص بیماری گیاهی نیازمند مدل‌هایی است که بتوانند ویژگی‌های پیچیده و چندلایه را مستقیماً از تصویر بیاموزند. این نیاز تاریخی با ظهور شبکه‌های عصبی کانولوشنی برآورده شد.

۳-۱-۲ گذار از روش‌های کلاسیک به یادگیری عمیق

ظهور شبکه‌های عصبی کانولوشنی (CNN) در سال ۲۰۱۲ با موفقیت بی‌سابقه AlexNet در رقابت ImageNet، نقطه عطفی در تمام حوزه‌های بینایی ماشین بود. AlexNet برای نخستین بار نشان داد که شبکه‌های عمیق قادرند بدون نیاز به استخراج دستی ویژگی، الگوهای پیچیده تصویر را بیاموزند. این موفقیت، نگاه پژوهشگران حوزه کشاورزی را نیز به خود جلب کرد و زمینه ورود CNN به تشخیص بیماری گیاه فراهم شد.

CNN‌ها با استفاده از لایه‌های کانولوشن، polling و fully connected، قادرند از سطوح پایین تا سطوح بالای تصویر ویژگی استخراج کنند. یکی از مهم‌ترین دلایل موفقیت CNN این است که می‌تواند ویژگی‌هایی که انسان قادر به تشخیص آنها نیست، مانند الگوهای بافتی بسیار ظریف یا تغییرات تدریجی رنگ، را شناسایی کند. همچنین CNN نسبت به تغییرات نور و زاویه مقاوم‌تر از روش‌های کلاسیک است. یکی از اولین کارهای جدی که CNN را در تشخیص بیماری گیاه بررسی کرد مقاله نوشته شده توسط Militante بود [۱۹]. در این پژوهش سه معماری AlexNet، VGG16 و GoogLeNet بر روی مجموعه داده PlantVillage آزمایش شدند. نویسندگان نشان دادند که CNN‌ها توانایی فوق‌العاده‌ای در شناسایی بیماری‌ها در داده‌های کنترل‌شده دارند. برای مثال، مدل VGG16 به دقتی بالای ۹۸٪ رسید و ResNet در پژوهش‌های بعدی توانست حتی از این مقدار نیز فراتر برود.

اما آنچه این پژوهش را ارزشمند می‌کرد این بود که ضعف CNN در داده‌های واقعی نیز مطرح شد. هرچند عملکرد CNN در داده‌های آزمایشگاهی بی‌نقص بود، اما هنگامی که داده‌ها از محیط واقعی مزرعه انتخاب می‌شدند، دقت مدل افت می‌کرد. این نکته باعث شد پژوهشگران به دنبال مدل‌هایی باشند که بتوانند علاوه بر طبقه‌بندی، ناحیه بیماری را نیز تشخیص دهند.

پژوهش انجام‌شده توسط Picon و همکاران نیز نقش مهمی در توسعه CNN در کشاورزی داشت. این مقاله نشان داد که CNN می‌تواند داده‌های چند محصولی را نیز تحلیل کند و در نتیجه برای پروژه‌هایی که چند نوع گیاه دارند نیز مناسب است [۲۵]. در این پژوهش، شبکه‌های عمیق برای تحلیل چندین نوع

برگ با بیماری‌های متفاوت آموزش داده شدند و نتایج بسیار امیدوارکننده بود. با این حال، پژوهش‌ها به تدریج نشان دادند که حتی CNN‌های بسیار قوی نیز در محیط واقعی محدودیت‌هایی دارند. همین موضوع باعث شد مسیر پژوهشی به سمت مدل‌های ترکیبی، Transfer Learning و نهایتاً Object Detection تغییر کند، که در بخش‌های بعدی فصل به‌طور مفصل بررسی خواهند شد.

۲-۳ CNN، Ensemble و Transfe Learning

۱-۲-۳ شبکه‌های عصبی کانولوشنی (CNN)

ظهور شبکه‌های عصبی کانولوشنی نقطه عطفی در حوزه تشخیص بیماری‌های گیاهی ایجاد کرد. CNN‌ها برخلاف روش‌های کلاسیک که متکی بر استخراج دستی ویژگی بودند، قادرند ویژگی‌های بصری را به‌صورت خودکار و سلسله‌مراتبی بیاموزند. این تحول باعث شد پژوهشگرانی که پیش‌تر با محدودیت‌های روش‌های کلاسیک مواجه بودند، بتوانند ساختارهای پیچیده‌تر و الگوهای بیماری را با دقت بیشتری تحلیل کنند. مجموعه داده PlantVillage نقش اساسی در تسهیل این روند داشت، زیرا برای اولین بار مجموعه‌ای نسبتاً بزرگ، تمیز و استاندارد از تصاویر برگ گیاهان در اختیار پژوهشگران قرار گرفت. یکی از نخستین پژوهش‌های تأثیرگذار، مقاله انجام‌شده توسط Ullah و همکاران بود که نویسندگان در آن سه معماری مشهور AlexNet، VGGNet و GoogLeNet را روی PlantVillage آزمایش کردند [۳۳]. نتایج این مطالعه نشان داد که CNN‌ها می‌توانند در داده‌های کنترل‌شده دقت‌هایی نزدیک به ۹۸ تا ۹۹ درصد ارائه دهند. از میان مدل‌ها، VGG16 و GoogLeNet عملکرد بهتری داشتند و نشان دادند که افزایش عمق و استفاده از ساختارهای چندمسیره در شبکه، قدرت تشخیص بیماری‌ها را افزایش می‌دهد. اما مهم‌تر از همه این بود که نویسندگان اشاره کردند این مدل‌ها در داده‌های واقعی افت دقت محسوسی دارند؛ نکته‌ای که بسیاری از پژوهش‌های بعدی نیز آن را تأیید کرده‌اند.

به‌منظور جمع‌بندی ساختاریافته‌ی نتایج این مطالعه، جدول ۱-۳ مقایسه‌ای میان معماری‌های AlexNet، VGGNet و GoogLeNet ارائه می‌دهد. این جدول نشان می‌دهد که معماری‌های عمیق‌تر و دارای ساختارهای چندمسیره، نظیر VGG16 و GoogLeNet، در داده‌های کنترل‌شده‌ی PlantVillage عملکرد بهتری نسبت به AlexNet دارند. در عین حال، همان‌گونه که در متن نیز اشاره شد، این مقایسه به‌خوبی

محدودیت مشترک این مدل‌ها را آشکار می‌سازد؛ به‌طوری که با وجود دقت بالا در داده‌های آزمایشگاهی، افت عملکرد در داده‌های واقعی به‌عنوان یک چالش اساسی باقی می‌ماند.

جدول ۳-۱: مقایسه‌ی معماری‌های CNN - برگرفته از مرجع [۳۳]

GoogLeNet	VGGNet (VGG16)	AlexNet	مولفه
CNN چندمسیره (Inception)	CNN عمیق	CNN کلاسیک	نوع معماری
متوسط با شاخه‌های موازی	عمیق	کم‌عمق	عمق شبکه
مسیرهای موازی با فیلترهای چندمقیاسی	افزایش عمق و تعداد پارامترها	لایه‌های متوالی ساده	ساختار ویژه
PlantVillage	PlantVillage	PlantVillage	مجموعه داده
حدود ۹۸-۹۹٪	حدود ۹۸-۹۹٪	حدود ۹۸٪	دقت گزارش شده
بهتر	بهتر	ضعیف‌تر از دو مدل دیگر	عملکرد نسبی
استخراج ویژگی‌های چندمقیاسی	قدرت تشخیص بالاتر	ساده و سریع	نکته‌ی کلیدی
افت دقت در داده‌های واقعی	افت دقت در داده‌های واقعی	افت دقت در داده‌های واقعی	محدودیت مهم

پژوهش انجام شده توسط Lu و همکاران یکی از مرورهای جامع در حوزه به‌کارگیری CNN‌ها برای تشخیص بیماری‌های برگ گیاهان به شمار می‌رود [۱۷]. در این مطالعه، نویسندگان تلاش کرده‌اند چارچوبی منسجم از نحوه عملکرد مدل‌های CNN، قابلیت‌های آن‌ها در استخراج ویژگی‌های بصری و نقاط ضعف معماری‌های مختلف ارائه دهند. این مرور نشان می‌دهد که CNN‌ها در تشخیص الگوهای پیچیده بیماری‌ها، حتی در شرایطی که داده‌ها شامل نویز، تغییرات نور، و تنوع شدید ظاهری برگ‌ها باشند، عملکرد قابل توجهی دارند.

این مقاله تأکید می‌کند که اگرچه CNN‌ها در محیط‌های کنترل‌شده به دقت‌های بسیار بالا دست پیدا می‌کنند، اما چالش‌هایی مانند کمبود داده‌های واقعی، عدم یکنواختی تصویربرداری و تفاوت شرایط اقلیمی، همچنان بر قابلیت تعمیم‌پذیری مدل‌ها اثر می‌گذارند. علاوه بر این، این پژوهش بر اهمیت استفاده از معماری‌های بهینه‌تر، تنظیمات دقیق پارامترها، و بهره‌گیری از تکنیک‌های افزایش داده‌ها برای بهبود عملکرد مدل‌ها در شرایط واقعی مزرعه تأکید دارد. این مطالعه همچنین نقش مهمی برای ترکیب CNN با روش‌های جدیدتر مانند Transfer Learning و شبکه‌های سبک‌وزن قائل است و نشان می‌دهد که این رویکردها می‌توانند محدودیت‌های مدل‌های سنتی‌تر را در کاربردهای عملی برطرف کنند. پژوهش انجام‌شده توسط Picon و همکاران یکی از مهم‌ترین مطالعاتی بود که تلاش کرد CNN را در

زمینه چندگیاهی آزمایش کند [۲۵]. در این مطالعه، شبکه‌های عمیق به گونه‌ای آموزش داده شدند که نه تنها نوع بیماری بلکه نوع گیاه نیز شناسایی شود. نتیجه این پژوهش نشان داد که CNNها حتی با وجود تنوع گونه‌ای، همچنان توانایی یادگیری ویژگی‌های مناسب را دارند و در شرایط کنترل‌شده بسیار پایدار عمل می‌کنند. این پژوهش بر نقش معماری‌های عمیق در تعمیم‌پذیری تأکید داشت، اما مانند پژوهش قبلی بر این نکته نیز دست گذاشت که مدل‌های CNN ممکن است در شرایط واقعی مزرعه با چالش‌هایی مواجه شوند.

به‌منظور ارائه‌ی یک جمع‌بندی عددی از نتایج مطالعات مرور شده، جدول ۲-۳ بازه‌ی دقت گزارش‌شده برای مدل‌های مختلف CNN را در شرایط آزمایشگاهی و داده‌های واقعی نشان می‌دهد. همان‌طور که مشاهده می‌شود، اگرچه CNNها در داده‌های کنترل‌شده به دقت‌های بسیار بالا دست می‌یابند، اما در تصاویر واقعی مزرعه با افت عملکرد مواجه می‌شوند؛ موضوعی که بر اهمیت روش‌هایی مانند انتقال یادگیری و افزایش داده‌ها برای بهبود تعمیم‌پذیری مدل‌ها تأکید دارد.

جدول ۲-۳: دقت CNNهای مختلف در تشخیص بیماری برگ گیاهان - برگرفته از مرجع [۱۷]

نوع رویکرد / معماری	نوع داده	بازه‌ی دقت گزارش‌شده (%)
CNNهای کلاسیک (GoogLeNet, VGG, AlexNet)	داده‌های کنترل‌شده (PlantVillage و مشابه)	۹۷ - ۹۹
CNNهای عمیق‌تر (DenseNet, ResNet, VGG16)	داده‌های کنترل‌شده	۹۸ - ۹۹/۵
Transfer Learning + CNN	داده‌های کنترل‌شده	۹۸ - ۹۹/۷
CNN در داده‌های واقعی مزرعه	تصاویر Real-world / Field	۷۰ - ۹۰
Data Augmentation + CNN	داده‌های واقعی	۸۰ - ۹۲

از میان پژوهش‌هایی که بررسی کرده‌ای، مقاله نوشته شده توسط Zubair یکی از نمونه‌های برجسته بود که تلاش کرد قدرت CNNها را از طریق ترکیب چندشبکه‌ای افزایش دهد [۴۲]. نویسندگان این مقاله چندین شبکه CNN را به‌صورت موازی آموزش دادند و خروجی آن‌ها را با روش‌های وزن‌دهی مختلف ترکیب کردند. نتیجه این پژوهش، افزایش قابل توجه دقت و کاهش نوسان مدل بود؛ موضوعی که اهمیت Ensemble را در سیستم‌های تشخیص بیماری نشان می‌دهد. این مطالعه نشان داد که شبکه‌های مختلف، ویژگی‌های متفاوتی از تصویر را استخراج می‌کنند و ترکیب آن‌ها می‌تواند دید جامع‌تری از ساختار بیماری ایجاد کند.

در مطالعه انجام شده توسط Nader، مدل‌های متنوعی مانند VGG19، InceptionV3 و ResNet50 مورد

استفاده قرار گرفت و پژوهشگران نشان دادند که مدل‌های Ensemble نه تنها دقت را بهبود می‌بخشند، بلکه پایداری سیستم را نیز افزایش می‌دهند [۲۱]. این مقاله بر این نکته تأکید داشت که در داده‌هایی با تنوع ظاهری گسترده، استفاده از یک مدل تکی می‌تواند منجر به Overfit یا Underfit شود، اما مدل‌های ترکیبی قادرند این ضعف‌ها را جبران کنند. این پژوهش‌ها به‌طور مستقیم با طراحی در مرحله اول پروژه ارتباط دارند، زیرا در این پروژه نیز با طراحی یک Ensemble سه‌مدلی، توانستیم دقت نهایی را در داده PlantVillage از مدل‌های تکی فراتر ببریم.

یکی دیگر از پژوهش‌های مهم در زمینه CNN، مقاله نوشته شده توسط Pai بود [۲۳]. نویسندگان در این مقاله چند شبکه CNN متفاوت را با ساختارهای ترکیبی مختلف مورد آزمایش قرار دادند و نشان دادند که Ensemble CNN می‌تواند در طبقه‌بندی بیماری‌های برگ برنج عملکرد بسیار دقیقی داشته باشد. نکته مهم این پژوهش استفاده از استراتژی‌های Voting و Softmax Fusion برای ترکیب خروجی شبکه‌ها بود. این روش‌ها به‌طور مؤثری دقت نهایی را افزایش دادند. چنین یافته‌هایی اهمیت روش‌های Ensemble را در کاربردهای کشاورزی تقویت می‌کنند.

پژوهش دیگری توسط Aderinwale نشان داد که ترکیب CNN با معماری‌های جدیدتر مبتنی بر توجه مانند Vision Transformer می‌تواند عملکرد سیستم را از مدل‌های CNN صرف فراتر ببرد [۱]. CNN‌ها توانایی استخراج ویژگی‌های محلی و ساختارهای بافتی را دارند، در حالی که Transformer قادرند روابط بلندبرد بین بخش‌های مختلف تصویر را مدل کنند. ترکیب این دو باعث شد سیستم توانایی بیشتری در تفکیک بیماری‌های مشابه پیدا کند. این مطالعه نه تنها ارزش ترکیب مدل‌ها را نشان می‌دهد، بلکه بر نقش توجه در تقویت عملکرد مدل‌های بصری تأکید می‌کند؛ مفهومی که در این پروژه نیز در بخش YOLOX + CBAM مورد استفاده قرار گرفته است.

این مجموعه گسترده از پژوهش‌ها نشان می‌دهد که CNN‌ها به دلیل قدرت فوق‌العاده در یادگیری ویژگی‌ها، بهترین ابزار برای داده‌های کنترل‌شده هستند. اما در داده‌های واقعی که شامل نور نامنظم، پس‌زمینه پیچیده و تنوع ظاهری بالاست، عملکرد آنها افت می‌کند. همین موضوع باعث شد رویکرد پژوهشگران به سمت مدل‌های تشخیص ناحیه مانند YOLO حرکت کند. اما پیش از رسیدن به تشخیص ناحیه، بسیاری از پژوهش‌ها از روش‌های Ensemble و Transfer Learning برای تقویت CNN‌ها استفاده کردند که در بخش‌های بعدی بررسی خواهد شد.

شایان ذکر است که پژوهش‌های بیشتری در حوزه شبکه‌های کانولوشنی برای تشخیص بیماری‌های گیاهی وجود دارد که به منظور اختصار متن، فهرست آن‌ها در بخش منابع آمده است [۹، ۲۷، ۱۵، ۲۶، ۱۱، ۲۴].

۳-۲-۲ Ensemble Learning

مدل‌های Ensemble در سال‌های اخیر به‌عنوان یکی از مؤثرترین روش‌ها برای افزایش دقت و کاهش نوسان خروجی در سیستم‌های تشخیص بیماری گیاهان مطرح شده‌اند. دلیل این امر روشن است، معماری‌های مختلف CNN الگوهای متفاوتی از تصویر را استخراج می‌کنند و نقاط قوت و ضعف خاص خود را دارند. بنابراین، ترکیب چند معماری می‌تواند بینشی عمیق‌تر از تصویر ایجاد کند و دقت نهایی را افزایش دهد.

یکی از مطالعات مهم در این حوزه، مقاله‌ای از Zubair است [۴۲]. در این پژوهش، چند شبکه CNN با معماری‌های متفاوت آموزش داده شده و خروجی آنها با روش‌های مختلفی مانند Weighted Averaging و Softmax Fusion ترکیب شد. نویسندگان نشان دادند که این ترکیب نه تنها دقت را افزایش می‌دهد بلکه پایداری مدل در برابر نویز و تغییرات ظاهری را نیز بیشتر می‌شود. اهمیت این پژوهش در آن است که نشان می‌دهد هیچ معماری CNN به تنهایی قادر نیست به‌طور کامل تمام الگوهای بیماری را تشخیص دهد و استفاده از Ensemble یک انتخاب استراتژیک برای تحلیل داده‌های پیچیده گیاهان است.

در پژوهش انجام شده توسط Zubair، نویسندگان معماری‌های VGG19، InceptionV3، ResNet50 و EfficientNet را ترکیب کردند [۲۱]. نتیجه این مطالعه نشان داد که استفاده از معماری‌های مختلف در یک Ensemble، دقت را بالاتر از هر مدل منفرد افزایش می‌دهد. به‌ویژه زمانی که بیماری‌ها الگوهای ظاهری بسیار مشابه دارند، Ensemble کمک می‌کند اختلافات ظریف در ویژگی‌ها بهتر شناسایی شوند. این مطالعه همان ایده‌ای است که در طراحی تو نیز به شکل Ensemble سه‌مدلی اجرا شد.

پژوهش انجام شده توسط Vo نیز ترکیب چند شبکه عمیق را بر روی مجموعه داده چندگیاهی آزمایش کرد و نشان داد که Ensemble می‌تواند در مجموعه داده‌هایی با تنوع زیاد نیز عملکرد بالایی ارائه دهد [۳۵]. نویسندگان اشاره کردند که حتی اگر یک مدل در برخی بیماری‌ها عملکرد ضعیف‌تری داشته باشد، مدل‌های دیگر این ضعف را جبران می‌کنند و سیستم نهایی پایداری بیشتری دارد. چنین یافته‌هایی نشان می‌دهد که Ensemble نه تنها دقت را افزایش می‌دهد بلکه ایمنی مدل را در برابر خطاهای مدل‌های منفرد بالا می‌برد.

ارتباط مستقیم این مطالعات با پروژه کاملاً واضح است. در پروژه در فاز اول با استفاده از سه مدل EfficientNetB0، ResNet50 و MobileNetV2 یک Ensemble طراحی کردیم و توانستیم به دقت ۹۹/۷۶٪ دست یابیم؛ نتیجه‌ای که نشان می‌دهد این انتخاب دقیقاً مطابق با ادبیات معتبر پژوهشی انجام

شده است.

۳-۲-۳ Transfer Learning

Transfer Learning در تشخیص بیماری‌های گیاهی به یکی از مهم‌ترین رویکردها تبدیل شده است، زیرا مجموعه داده‌های کشاورزی معمولاً کوچک، نامتوازن و محدود هستند. مدل‌هایی مانند VGG، ResNet و EfficientNet که بر روی مجموعه بزرگ ImageNet آموزش دیده‌اند، توانایی اولیه عالی برای استخراج ویژگی‌های عمومی تصویر دارند. پژوهش‌ها نشان داده‌اند که این مدل‌ها پس از اعمال Fine-Tuning روی داده‌های گیاهی می‌توانند عملکرد بسیار مطلوبی ارائه دهند.

در مقاله نوشته شده توسط Anduyan، مدل‌های ازپیش‌آموزش‌یافته VGG19 و ResNet50 برای تشخیص بیماری‌های کاکائو استفاده شدند [۳]. نویسندگان گزارش کردند که انتقال یادگیری باعث افزایش چشمگیر دقت و کاهش زمان آموزش شده است. دلیل موفقیت این رویکرد در آن است که بسیاری از ویژگی‌های اولیه مورد نیاز برای تشخیص بیماری‌ها مانند مرزها، الگوهای رنگی، تغییرات بافتی و لبه‌های مشخص در مرحله آموزش ImageNet از پیش آموخته شده‌اند.

پژوهش دیگری توسط Vallabhajosyula نیز نشان داد که ترکیب Transfer Learning با Ensemble می‌تواند نتایج بسیار قدرتمندی ایجاد کند [۳۴]. این مقاله بیان می‌کند که مدل‌های ازپیش‌آموزش‌یافته دارای بینش بصری غنی هستند و ترکیب آنها با هم باعث می‌شود سیستم بتواند تنوع ظاهری برگ‌ها را بهتر درک کند.

در این پروژه نیز دقیقاً از همین رویکرد استفاده شد. CNN‌هایی که به‌طور اولیه بر ImageNet آموزش دیده بودند، برای PlantVillage، Fine-Tune شدند و سپس در قالب یک Ensemble قرار گرفتند.

قابل ذکر است که علاوه بر پژوهش‌های مطرح‌شده در این فصل، مطالعات دیگری نیز پیرامون Transfer Learning و تشخیص بیماری‌های گیاهی انجام شده‌اند که برای جلوگیری از طولانی شدن متن، فهرست کامل آن‌ها در بخش منابع ارائه شده است [۶، ۷، ۱۴، ۲۸، ۲۰].

۳-۳ مدل‌های YOLO و جایگاه YOLOX

۳-۳-۱ مقدمه‌ای بر تشخیص ناحیه در بیماری گیاهان

با افزایش نیاز به سیستم‌های عملیاتی در کشاورزی هوشمند، پژوهشگران به این نتیجه رسیدند که طبقه‌بندی تصاویر حتی با دقت بسیار بالا برای کاربردهای واقعی کافی نیست. اگرچه یک مدل طبقه‌بندی قادر است تشخیص دهد که برگ بیمار است یا نه، اما در تصمیم‌گیری عملی، دانستن محل دقیق بیماری اهمیت حیاتی دارد. کشاورزان نیاز دارند بدانند کدام بخش برگ آلوده است، آیا لکه کوچک است یا گسترده، آیا چند ناحیه بیمار وجود دارد یا تنها یک بخش کوچک آسیب دیده است. از این رو، توجه پژوهش‌ها به سمت تشخیص ناحیه (Object Detection) معطوف شد.

تشخیص ناحیه، بر خلاف طبقه‌بندی، دو وظیفه را هم‌زمان انجام می‌دهد: تعیین کلاس بیماری و تعیین مختصات ناحیه بیماری. این دو خروجی باعث می‌شود مدل نه تنها بگوید برگ آلوده است، بلکه بتواند بخش دقیق آلودگی را نیز مشخص کند. همین قابلیت، تشخیص ناحیه را به ابزار ضروری برای داده‌های واقعی مانند PlantDoc تبدیل می‌کند؛ زیرا این داده‌ها برخلاف PlantVillage دارای پس‌زمینه‌های شلوغ، نورهای متغیر، زاویه‌های متعدد و کیفیت‌های نامتوازن هستند.

در سال‌های اخیر، تحول تشخیص ناحیه از مدل‌های دو مرحله‌ای به مدل‌های تک مرحله‌ای، سرعت و دقت این سیستم‌ها را به‌طور چشمگیری افزایش داده است. مدل‌هایی مانند Faster R-CNN آغازگر این مسیر بودند، اما مدل YOLO و سپس YOLOX انقلابی واقعی در این حوزه ایجاد کردند. این پروژه نیز بر پایه آخرین نسل این رویکردها بنا شده است.

۳-۳-۲ نسل اول تشخیص ناحیه Faster R-CNN و SSD

نخستین موج مدل‌های تشخیص بیماری‌های گیاهی از روش‌های دو مرحله‌ای مانند Faster R-CNN استفاده کردند. این مدل‌ها ابتدا نواحی احتمالی (Region Proposals) را پیشنهاد می‌دادند و سپس هر ناحیه را طبقه‌بندی می‌کردند. دقت این روش‌ها بالا بود، اما سرعت آنها برای استفاده عملی در مزرعه مناسب نبود. پژوهش‌هایی در تشخیص بیماری انگور، سیب، برنج و گوجه‌فرنگی نشان دادند که Faster R-CNN می‌تواند لکه‌های بیماری را با دقت قابل قبول تشخیص دهد، اما پردازش هر تصویر چند صد میلی‌ثانیه یا حتی چند ثانیه زمان می‌برد.

روش SSD^۳ تلاش کرد سرعت را افزایش دهد، اما در تشخیص لکه‌های کوچک، مانند بیماری‌های قارچی نقطه‌ای، دقت آن کاهش می‌یافت. همین مسئله موجب شد پژوهشگران به دنبال مدل‌هایی باشند که تعادل بهتری میان سرعت و دقت برقرار کنند. کاستی‌های این نسل:

۱. سرعت پایین (غیرقابل استفاده در مزرعه)

۲. ناتوانی در تشخیص لکه‌های کوچک

۳. حساسیت زیاد به تفاوت‌های پس‌زمینه

۴. نیاز به داده‌های بسیار زیاد برای پایداری

این نکات زمینه‌ساز ظهور YOLO شد.

۳-۳-۳ ظهور YOLO و آغاز عصر جدید تشخیص بیماری گیاهان

YOLO (You Only Look Once) اولین معماری تک‌مرحله‌ای بود که توانست تشخیص ناحیه را با سرعت و دقت بالا ترکیب کند. در YOLO، کل تصویر تنها یک‌بار از شبکه عبور می‌کرد و مدل به‌طور هم‌زمان مختصات و کلاس را پیش‌بینی می‌کرد. این معماری باعث شد YOLO به یکی از محبوب‌ترین مدل‌ها برای تصاویر کشاورزی تبدیل شود.

پژوهش‌های بسیاری که در سال‌های ۲۰۱۸ تا ۲۰۲۵ انجام شدند، YOLOv3 و YOLOv5 را برای تشخیص بیماری‌های موز، سیب‌زمینی، ذرت و انگور بررسی کردند. نتایج نشان داد YOLO به دلیل سرعت بالا، قابلیت اجرای عملی روی گوشی یا درون مزرعه را دارد. با این حال، YOLOv3 و حتی YOLOv5 در تشخیص لکه‌های بسیار کوچک و نواحی جزئی بیماری ضعف‌هایی داشتند. مشکل اصلی این نسخه‌ها anchor-bases بودن آنها بود؛ یعنی مدل متکی بر anchor boxes^۴ از پیش تعیین‌شده بود. این ساختار باعث می‌شد برخی نواحی کوچک یا غیرمعمول به‌درستی تشخیص داده نشوند.

علیرغم این محدودیت‌ها، YOLO نقشه راه جدیدی را برای پژوهش‌ها گشود. بسیاری از مقالات، سرعت

^۳ Single Shot Detector

^۴ جعبه‌ای از پیش تعریف‌شده با اندازه و نسبت مشخص که در مدل‌های تشخیص شیء به‌عنوان مرجع اولیه برای پیش‌بینی موقعیت اشیا استفاده می‌شود.

بالای YOLO را تحسین کرده و سپس با افزودن ماژول‌هایی مانند CBAM یا SE^۵ در لایه‌ها، تلاش کردند تمرکز مدل را افزایش دهند. با این حال، مشکل وابستگی به anchor همچنان پابرجا بود و همین ضعف، انگیزه‌ای برای توسعه YOLOX شد.

۴-۳-۳ نسل جدید YOLOX، دقیق و anchor-free

YOLOX یکی از تحول‌آفرین‌ترین مدل‌های تشخیص ناحیه است. این نسخه نه تنها ساختار YOLOv5 را بازطراحی کرد، بلکه مفاهیم کاملاً جدیدی را ارائه داد:

۱. Anchor-Free Prediction: YOLOX برخلاف نسخه‌های قبلی، برای تشخیص نیاز به anchor box ندارد. این موضوع باعث می‌شود مدل قدرت بسیار بیشتری در تشخیص ناحیه‌های کوچک یا شکل‌های نامعمول داشته باشد.

۲. Decoupled Head: در YOLOX، بخش Classification و Localization از هم جدا شده‌اند. این جداسازی باعث می‌شود مدل تمرکز بهتری داشته باشد و در پیش‌بینی حدودی باکس‌ها دقیق‌تر عمل کند.

۳. الگوریتم SimOTA^۶: YOLOX از الگوریتم تخصیص نمونه پویا استفاده می‌کند تا anchorهای بهینه برای هر تصویر انتخاب شوند. این مکانیزم باعث افزایش پایداری مدل در داده‌های پیچیده می‌شود.

۴. سرعت بالا: YOLOX سرعتی معادل YOLOv5 دارد ولی دقت آن در بسیاری از سناریوها بیشتر است.

۵-۳-۳ بکارگیری YOLOX در حوزه گیاهان

در این بخش، پژوهش‌هایی بررسی می‌شوند که به‌طور مستقیم با YOLOX مرتبط هستند و نقش مهمی در توسعه‌ی روش‌های جدید تشخیص بیماری گیاهان داشته‌اند. نخست، مقاله نوشته شده توسط Lu

^۵Squeeze-and-Excitation

^۶Simplified Optimal Transport Assignment

نشان داد که ترکیب YOLOX با مکانیزم توجه CBAM می‌تواند تمرکز شبکه را بر نواحی بیماری به‌طور چشمگیری افزایش دهد [۱۸]. در بیماری‌هایی که لکه‌های کوچک و پراکنده دارند، این ترکیب عملکرد بسیار بهتری ارائه می‌دهد و مطابق گزارش نویسندگان، حساسیت مدل در بیماری‌های نقطه‌ای تا حدود ۱۲ درصد افزایش یافته است.

در مطالعه‌ای دیگر از Chen، تشخیص بیماری در بوته‌های توت‌فرنگی مورد بررسی قرار گرفت. چالش اصلی این داده‌ها وجود بافت‌های بسیار ظریف و نقاط سفید یا قهوه‌ای کوچک روی برگ‌ها بود [۸]. نتایج نشان داد که YOLOX، زمانی که با یک Backbone تقویت‌شده ترکیب شود، توانایی بالایی در استخراج ویژگی‌های ریزدانه دارد و در تشخیص نواحی کوچک، عملکردی بهتر از YOLOv5 به دست می‌آورد. مطالعه‌ی انجام شده توسط Shen نیز بیان کرد که YOLOX در داده‌های طبیعی شامل نور واقعی، پس‌زمینه‌های شلوغ و انواع مختلف برگ‌ها، پایداری بیشتری نسبت به مدل‌هایی مانند YOLOv5، EfficientNet و Faster R-CNN دارد [۲۹]. نویسندگان دلیل اصلی این پایداری را ماهیت anchor-free بودن YOLOX عنوان کرده‌اند؛ ویژگی‌ای که باعث می‌شود مدل در مواجهه با شرایط متغیر محیطی انعطاف‌پذیرتر باشد.

در پژوهشی مرتبط با تشخیص بیماری برگ‌های انگور نیز مشخص شد که اضافه کردن ماژول CBAM به YOLOX موجب می‌شود لکه‌های بسیار ظریف با دقت بیشتری شناسایی شوند [۱۲]. این مقاله تأکید می‌کند که YOLOX بدون استفاده از ماژول‌های توجه در شرایط واقعی افت دقت قابل‌ملاحظه‌ای دارد، اما افزودن CBAM این مشکل را تا حد زیادی برطرف می‌کند.

در نهایت، مطالعه انجام شده توسط Zheng نشان داد ترکیب YOLOX با معماری ConvNeXt می‌تواند حتی از YOLOv8 نیز عملکرد بهتری ارائه دهد [۴۱]. این نتایج نشان‌دهنده‌ی ظرفیت بالای YOLOX برای ترکیب با ساختارهای مدرن‌تر و مکانیزم‌های توجه است و مسیر پژوهش‌های مبتنی بر آن را تقویت می‌کند.

شایان ذکر است که افزون بر مطالعات بررسی‌شده در این بخش، پژوهش‌های دیگری نیز در زمینه‌ی بهبود YOLOX و تشخیص بیماری‌های گیاهی انجام شده است که به‌منظور جلوگیری از اطاله‌ی کلام، فهرست کامل آن‌ها در بخش کتابنامه آمده است [۱۰، ۱۳، ۳۶، ۳۸، ۴۰، ۴، ۱۶، ۴۰].

۳-۳-۶ چالش‌های تشخیص بیماری در تصاویر واقعی و نقش YOLOX

تشخیص بیماری گیاهان در داده‌های واقعی مانند PlantDoc با چالش‌های فراوانی همراه است:

۱. وجود پس‌زمینه شلوغ: خاک، چوب، آسمان، سیم، پلاستیک و حتی دست انسان.
۲. نور غیر یکنواخت: سایه برگ، نور شدید آفتاب، انعکاس نور روی سطح برگ.
۳. زاویه‌های متفاوت: برگ از بالا، از کنار یا در حالت پیچ‌خورده.
۴. لکه‌های کوچک و ظریف: بیماری‌های قارچی نقطه‌ای.
۵. همپوشانی برگ‌ها با هم.
۶. تفاوت‌های بین دوربین‌ها و کیفیت تصاویر.

پژوهش‌ها نشان داده‌اند که YOLOX به دلیل ساختار anchor-free و الگوریتم تخصیص پویا، توانایی بسیار بالایی در تشخیص ناحیه‌های کوچک دارد. این ویژگی برای بیماری‌های گیاهی حیاتی است؛ چون بسیاری از بیماری‌ها در مراحل اولیه تنها لکه‌هایی بسیار کوچک ایجاد می‌کنند. در چنین شرایطی، YOLOv5 ممکن است این لکه‌ها را نادیده بگیرد، اما YOLOX دارای حساسیت بیشتری نسبت به تغییرات بافتی کوچک است.

۷-۳-۳ ارتباط YOLOX با پژوهش انجام شده

در این پژوهش، معماری YOLOX با دو بهبود کلیدی ترکیب شده است که نقش مهمی در ارتقای عملکرد مدل ایفا می‌کنند. نخست، به‌کارگیری ConvNeXt Backbone - مطابق با نتایج گزارش‌شده در مقاله‌ی Zheng - موجب شد مدل توانایی بیشتری در استخراج ویژگی‌های پیچیده و ساختارهای ظریف موجود در تصاویر واقعی به دست آورد. این معماری به‌دلیل طراحی مدرن و بهره‌گیری از مفاهیم به‌روزشده‌ی شبکه‌های کانولوشنی، قدرت مدل را در درک الگوهای بصری به‌صورت قابل‌توجهی افزایش می‌دهد [۴۱].

بهبود مهم دیگر، استفاده از مکانیزم توجه CBAM است که باعث می‌شود YOLOX تمرکز بیشتری بر نواحی کلیدی آسیب‌دیده داشته باشد. این مکانیزم با تقویت انتخاب ویژگی‌های مهم و کاهش توجه مدل به نواحی غیرمرتبط، عملکرد شبکه را در تشخیص لکه‌های کوچک و پراکنده به‌طور محسوسی بهبود می‌بخشد.

در مجموع، انتخاب ترکیب YOLOX-ConvNeXt-CBAM کاملاً مطابق با ادبیات پژوهشی معتبر و به‌روز بوده و هم‌راستا با جریان فعلی تحقیقات در حوزه‌ی تشخیص بیماری‌های گیاهی و شبکه‌های شناسایی شیء قرار می‌گیرد.

۴-۳ مکانیزم‌های توجه و مدل‌های هیبرید در تشخیص بیماری‌های گیاهان

۳-۴-۱ مقدمه‌ای بر نقش توجه (Attention) در تشخیص بیماری‌های گیاهان

با پیچیده‌تر شدن داده‌های تصویری در حوزه‌ی کشاورزی هوشمند، پژوهشگران دریافتند که مدل‌های عمیق - حتی مدل‌هایی با میلیون‌ها پارامتر - ممکن است در مواجهه با تصاویر واقعی، تمرکز خود را از نواحی حیاتی از دست بدهند. این چالش در مجموعه‌داده‌هایی مانند PlantDoc به‌مراتب جدی‌تر است؛ زیرا تصاویر برگ‌ها معمولاً با پس‌زمینه‌های شلوغ، لکه‌های بسیار کوچک بیماری، مناطق آسیب‌دیده‌ی پراکنده و تغییرات نوری شدید همراه‌اند. هرچند مدل‌های عمیق توانایی بالایی در استخراج ویژگی‌های پیچیده دارند، اما در شناسایی ناحیه‌های ظریف و نشانه‌های ریز بیماری همواره موفق عمل نمی‌کنند. این مسئله باعث شد از سال ۲۰۱۸ به بعد، مفهوم «مکانیزم توجه» به‌عنوان رویکردی مؤثر وارد پژوهش‌های بینایی ماشین شود. مکانیزم توجه به مدل کمک می‌کند بخش‌های مهم تصویر را برجسته و نواحی کم‌اهمیت را تضعیف کند. در کاربرد تشخیص بیماری‌های گیاهی، این نواحی مهم معمولاً شامل لکه‌های اولیه‌ی بیماری، تغییرات رنگی کوچک، بافت‌های تخریب‌شده یا مرزهای نامنظم برگ هستند. نتایج پژوهش‌های متعدد نشان می‌دهد که افزودن لایه‌های توجه به مدل‌های طبقه‌بندی یا تشخیص ناحیه می‌تواند عملکرد آن‌ها را در داده‌های واقعی به‌طور قابل‌توجهی بهبود بخشد. در ادامه، سازوکارهای مختلف توجه، مطالعات مرتبط و نقش هر یک در پیشبرد پژوهش حاضر مورد بررسی قرار می‌گیرد.

۳-۴-۲ سازوکار توجه کانالی (Channel Attention)

توجه کانالی یکی از نخستین انواع توجه بود که در شبکه‌های عمیق مورد استفاده قرار گرفت. این نوع توجه تلاش می‌کند تعیین کند کدام کانال‌های ویژگی برای مدل مهم‌تر هستند. در شبکه‌های عمیق، هر

کانال مسئول استخراج یک نوع ویژگی است؛ مثلاً برخی کانال‌ها خطوط عمودی را تشخیص می‌دهند، برخی لکه‌ها را، برخی تغییرات رنگی را و برخی الگوهای بافتی را. اما در یک تصویر واقعی، همه کانال‌ها به یک میزان مهم نیستند. توجه کانالی با تخصیص وزن‌های متفاوت به کانال‌ها باعث می‌شود مدل توجه بیشتری روی کانال‌هایی بگذارد که اطلاعات مهم‌تری درباره بیماری دارند.

یکی از مهم‌ترین مدل‌هایی که از این مفهوم بهره می‌برد Squeeze-and-Excitation (SE) است. SE با فشرده‌سازی کانال‌ها و سپس تحریک آنها، وزن‌دهی به کانال‌ها را یاد می‌گیرد. پژوهش‌ها نشان داده‌اند که SE در تشخیص بیماری‌های گیاهی عملکرد خوبی دارد، زیرا برخی بیماری‌ها الگوهای رنگی بسیار خاصی تولید می‌کنند و SE این تغییرات را خوب برجسته می‌کند. با این حال، SE فقط به کانال‌ها توجه می‌کند و موقعیت مکانی ویژگی‌های مهم را در نظر نمی‌گیرد. همین کمبود باعث توسعه مدل‌های پیشرفته‌تر مانند CBAM شد.

۳-۴-۳ توجه مکانی (Spatial Attention)

در مقابل توجه کانالی، توجه مکانی تمرکز خود را روی موقعیت‌های خاص تصویر می‌گذارد. در بسیاری از بیماری‌های گیاهی، لکه‌ها در بخش‌های خاصی از برگ قرار دارند. ممکن است ناحیه بالایی برگ آسیب‌دیده باشد یا نقطه‌های بیماری در اطراف رگبرگ‌ها پخش شده باشند. Spatial Attention می‌تواند با تحلیل روابط بین نقاط تصویر، بفهمد کدام ناحیه‌ها مهم‌تر هستند و باید برجسته شوند. این نوع توجه به‌ویژه در داده‌های واقعی که پس‌زمینه تصویر پیچیده است اهمیت دارد. برای مثال، اگر برگ در زمینی پر از شاخه و خاک قرار داشته باشد، توجه مکانی کمک می‌کند مدل فقط به خطوط برگ و لکه‌های موجود روی آن توجه کند و سایر نواحی را نادیده بگیرد.

۴-۴-۳ مکانیزم توجه CBAM

CBAM^۷ یکی از موفق‌ترین و کامل‌ترین مکانیزم‌های توجه است که به‌طور هم‌زمان توجه کانالی و مکانی را ترکیب می‌کند. این ترکیب باعث می‌شود مدل تصمیم بگیرد:

۱. چه ویژگی‌هایی مهم‌تر هستند (channel)

۲. در کدام بخش تصویر این ویژگی‌ها اهمیت دارند (spatial)

^۷Convolutional Block Attention Module

CBAM بسیار سبک، سریع و قابل‌افزودن به هر مدل CNN یا Detection است و به همین دلیل در سال‌های اخیر محبوبیت زیادی پیدا کرده است. در پژوهش‌هایی ذکر شده، CBAM نقش کلیدی داشته است. مطالعه “Grape Leaf Disease Detection Based on Attention Mechanism” نشان داد که CBAM در YOLOX باعث افزایش چشمگیر دقت در تشخیص لکه‌های کوچک بیماری انگور می‌شود [۱۲]. این مطالعه تأکید می‌کند که CBAM توانایی YOLOX را در تمرکز روی عیوب سطح برگ افزایش می‌دهد، به‌خصوص وقتی لکه‌ها کوچک یا پراکنده باشند. مقاله دیگری که در ژورنال Frontiers in Environmental Science منتشر شد نیز دقیقاً از CBAM در YOLOX استفاده کرد و نتایجی بسیار مشابه به‌دست آورد: افزایش حساسیت مدل در داده‌های طبیعی و افزایش دقت نهایی [۱۸]. نکته مهم این است که CBAM تنها برای تشخیص ناحیه نیست؛ بلکه در طبقه‌بندی نیز استفاده می‌شود. اما نقش آن در تشخیص بیماری گیاهی در داده‌های واقعی بسیار پررنگ‌تر است، زیرا این نوع داده‌ها شامل نویزهای فراوانی هستند.

۳-۴-۵ مدل‌های توجه سبک در تشخیص بیماری‌های گیاهان

با افزایش نیاز به مدل‌هایی که بتوانند بر روی تلفن همراه یا دستگاه‌های کشاورزی اجرا شوند، جهت‌گیری پژوهش‌ها به‌سوی مکانیزم‌های توجه سبک^۸ تغییر یافته است. مدل‌هایی مانند ECA^۹ تلاش می‌کنند سازوکار توجه کانالی را با هزینه‌ی محاسباتی بسیار پایین پیاده‌سازی کنند. در برخی مطالعات، ترکیب ECA با معماری‌های سبک‌وزن مانند MobileNet برای تشخیص بیماری‌های گیاهی به‌کار رفته و نتایج این پژوهش‌ها نشان داده است که افزودن ECA می‌تواند بخشی از کاهش دقت ناشی از کوچک بودن مدل را جبران کند.

اگرچه در پژوهش حاضر از ECA استفاده نشده است، اما مطالعه‌ی این دسته از تحقیقات درک بهتری از اهمیت سازوکارهای توجه در مدل‌های سبک‌وزن فراهم می‌کند. این موضوع به‌ویژه برای کاربردهایی اهمیت دارد که نیازمند اجرای مدل بر روی دستگاه‌های لبه‌محور (Edge Devices) یا تجهیزات کم‌مصرف کشاورزی هستند.

^۸ Lightweight Attention

^۹ Efficient Channel Attention

۳-۴-۶ مدل‌های هیبرید: ترکیب CNN، Attention و Transformer

یکی از تحولات مهم در پژوهش‌های اخیر، گسترش استفاده از مدل‌های هیبرید است؛ مدل‌هایی که با ترکیب چند معماری متفاوت، تلاش می‌کنند نقاط قوت هر یک را هم‌زمان به کار گیرند. در این میان، ادغام شبکه‌های CNN با Transformer در حوزه‌ی تشخیص بیماری‌های گیاهی دستاوردهای قابل توجهی داشته است. Transformerها برخلاف CNNها قادرند ارتباطات بلندبرد میان بخش‌های مختلف تصویر را مدل‌سازی کنند؛ قابلیت‌هایی که برای درک ساختار کلی برگ، الگوی توزیع لکه‌ها و روابط بین نواحی آسیب‌دیده اهمیت زیادی دارد. در مقابل، CNNها در استخراج ویژگی‌های محلی، بافتی و جزئیات ظریف بسیار توانمند هستند. ترکیب این دو رویکرد باعث ایجاد مدلی می‌شود که هم ویژگی‌های محلی و هم اطلاعات کلی تصویر را به‌طور مؤثر تحلیل می‌کند.

در مقاله‌ی “Plant Disease Classification Using an Ensemble of CNN and Vision Transformers” که در میان مطالعات مرور شده قرار داشت، پژوهشگران از CNN برای استخراج ویژگی‌های دقیق و از Transformer برای تحلیل روابط سطح بالای تصویر استفاده کردند [۱]. نتایج این پژوهش نشان داد که مدل ترکیبی مذکور دقت طبقه‌بندی بیماری‌های گیاهی را به‌طور قابل توجهی نسبت به مدل‌های صرفاً مبتنی بر CNN افزایش می‌دهد؛ زیرا هر دو نوع اطلاعات - جزئیات محلی و ساختار کلی - به‌طور هم‌زمان مورد بهره‌برداری قرار می‌گیرند.

همان‌طور که در جدول ۳-۳ مشاهده می‌شود، عملکرد مدل‌های پایه شامل DenseNet121 و نسخه‌های مختلف Vision Transformer در مقایسه با مدل Ensemble مورد ارزیابی قرار گرفته است. نتایج نشان می‌دهد که اگرچه هر یک از مدل‌های CNN و Transformer به‌تنهایی به دقت بالایی در طبقه‌بندی بیماری‌های گیاهی دست یافته‌اند، اما مدل ترکیبی ارائه‌شده در این پژوهش با بهره‌گیری هم‌زمان از ویژگی‌های محلی استخراج‌شده توسط CNN و روابط سطح‌بالای تصویری مدل‌شده توسط Transformer، بالاترین دقت، Precision، Recall و F1-score را به خود اختصاص داده است. این مقایسه به‌روشنی بیانگر مزیت استفاده از معماری‌های ترکیبی نسبت به مدل‌های منفرد در مسئله‌ی تشخیص بیماری‌های گیاهی است.

جدول ۳-۳: مقایسه‌ی عملکرد مدل‌های پایه و مدل Ensemble - برگرفته از مرجع [۲۰]

دسته	مدل	Accuracy (%)	Precision (%)	Recall (%)	F1-score (%)
Base	DenseNet121	۹۹/۷۸	۹۹/۷۸	۹۹/۷۸	۹۹/۷۸
Base	ViT_b16	۹۹/۸۰	۹۹/۸۱	۹۹/۸۱	۹۹/۸۱
Base	ViT_b32	۹۹/۴۴	۹۹/۲۳	۹۹/۲۲	۹۹/۲۲
Base (مقایسه‌ای)	VGG16	۹۸/۹۸	۹۸/۹۹	۹۸/۹۸	۹۸/۹۷
Base (مقایسه‌ای)	MobileNetV2	۹۸/۶۷	۹۸/۶۸	۹۸/۶۷	۹۸/۶۶
Base (مقایسه‌ای)	NASNet Mobile	۹۸/۴۲	۹۸/۴۳	۹۸/۴۳	۹۸/۴۲
Ensemble	ViT_b16 + ViT_b32 + DenseNet121	۹۹/۸۷	۹۹/۸۷	۹۹/۸۷	۹۹/۸۶

در همین راستا، مدل ConvNeXt نیز در زمره‌ی معماری‌های هیبریدی نوین قرار می‌گیرد. ConvNeXt یک شبکه‌ی کانولوشنی مدرن است که بسیاری از مفاهیم کلیدی Transformer ها را در ساختار خود به کار گرفته است؛ از جمله شیوه‌های جدید نرمال‌سازی، استفاده از depthwise convolution و طراحی بلوک‌هایی الهام گرفته از معماری Swin Transformer. این ترکیب باعث می‌شود ConvNeXt نسبت به CNN های کلاسیک، توانایی بیشتری در یادگیری الگوهای پیچیده و ساختارهای چندمقیاسی داشته باشد.

پژوهش‌های سال‌های ۲۰۲۴ و ۲۰۲۵ نشان داده‌اند که ترکیب YOLOX با ConvNeXt و CBAM یکی از کارآمدترین معماری‌ها برای تشخیص ناحیه‌ی بیماری‌های گیاهی است. نتایج منتشرشده در Scientific Reports 2025 به‌طور مشخص اثبات می‌کند که بک‌بون‌های مدرن مانند ConvNeXt می‌توانند عملکرد YOLOX را در داده‌های واقعی به میزان چشمگیری بهبود دهند [۴۱]. این مطالعه با مقایسه‌ی YOLOX-ResNet و YOLOX-ConvNeXt نشان داد که استفاده از شبکه‌های جدیدتر و الهام گرفته از Transformer، دقت بیشتری در تشخیص نواحی آسیب‌دیده فراهم می‌کند.

۳-۴-۷ ارتباط توجه و مدل‌های هیبرید با پژوهش انجام شده

ترکیب YOLOX با ConvNeXt و CBAM در این پژوهش منطبق بر مسیر پژوهشی سال‌های اخیر و مبتنی بر یافته‌های مطالعات معتبر انتخاب شده است. استفاده از ماژول CBAM موجب می‌شود مدل بتواند تمرکز دقیق‌تری بر نواحی بیماری داشته باشد و ویژگی‌های مهم را نسبت به نواحی کم‌اهمیت برجسته‌سازی کند. از سوی دیگر، بهره‌گیری از ConvNeXt به‌عنوان یک بک‌بون مدرن، توانایی استخراج

ویژگی‌های پیچیده و چندمقیاسی از تصاویر واقعی را افزایش می‌دهد. این هماهنگی میان سازوکار توجه و معماری پیشرفته‌ی بک‌بون، موجب شده ساختار به‌کاررفته یکی از کارآمدترین و به‌روزترین معماری‌ها برای تشخیص ناحیه‌ی بیماری در داده‌های واقعی به شمار آید.

در بخش طبقه‌بندی نیز، استفاده از Ensemble CNN هرچند فاقد مکانیزم توجه صریح است، اما ترکیب چند معماری مختلف نوعی «توجه جمعی» ایجاد می‌کند. در این رویکرد، هر مدل با تمرکز بر بخش‌های متفاوتی از تصویر، در نهایت به بهبود عملکرد کلی سامانه کمک می‌کند؛ مفهومی که در ادبیات پژوهشی نیز مورد تأکید قرار گرفته است. بنابراین، ساختار بخش طبقه‌بندی نیز نمونه‌ای از تلفیق هوشمندانه‌ی معماری‌های کلاسیک و رویکردهای نوین مبتنی بر توجه محسوب می‌شود.

۳-۵ تحلیل مقایسه‌ای، شکاف‌های پژوهشی و جایگاه پژوهش انجام شده

۳-۵-۱ تحلیل مقایسه‌ای پژوهش‌های موجود در تشخیص بیماری گیاهی

مرور گسترده پژوهش‌های مرتبط با تشخیص بیماری گیاهان تصویری روشن از روند تحول این حوزه ارائه می‌دهد. مسیر پیشرفت از روش‌های کلاسیک مبتنی بر ویژگی‌های دستی آغاز شد، با ظهور شبکه‌های عصبی کانولوشنی وارد مرحله‌ای جدید شد و سپس با توسعه تکنیک‌های Ensemble، انتقال یادگیری، مدل‌های هیبرید و مکانیزم‌های توجه تکامل پیدا کرد. هم‌زمان، نیاز به تشخیص ناحیه بیماری موج جدیدی از مطالعات مبتنی بر YOLO و YOLOX را شکل داد. تحلیل این تحقیقات نشان می‌دهد که هر یک از این رویکردها مزایا و محدودیت‌های خاص خود را دارند و هیچ‌کدام به تنهایی پاسخ‌گوی پیچیدگی داده‌های واقعی کشاورزی نیستند.

روش‌های کلاسیک که مبتنی بر استخراج ویژگی‌های دستی بودند، در محیط‌های کنترل‌شده عملکرد قابل‌قبولی داشتند، اما توانایی تعمیم‌پذیری آن‌ها بسیار محدود بود. کوچک‌ترین تغییر در نور، زاویه تصویربرداری یا پس‌زمینه موجب افت شدید عملکرد این مدل‌ها می‌شد؛ مسائلی که در داده‌های واقعی مزرعه اجتناب‌ناپذیر هستند.

با ظهور CNNها، نقطه عطف مهمی در این حوزه شکل گرفت. ساختار سلسله‌مراتبی CNN امکان یادگیری الگوهای پیچیده تصویری را فراهم کرد و دقت بسیار بالایی در مجموعه‌داده‌های استاندارد

مانند PlantVillage حاصل شد. با این حال، بسیاری از پژوهش‌ها نشان دادند که عملکرد مدل در داده‌های واقعی به دلیل پس‌زمینه شلوغ، نور متغیر و کیفیت نامتوازن به‌طور قابل‌توجهی کاهش می‌یابد. ماهیت ساده و کنترل‌شده داده‌های PlantVillage باعث می‌شود مدل‌های CNN در شرایط طبیعی عملکردی پایدار نداشته باشند.

پژوهش‌ها درباره مدل‌های Ensemble نشان دادند که ترکیب چند معماری CNN می‌تواند ضعف‌های هر شبکه را جبران کرده و پایداری مدل را افزایش دهد. این روش‌ها به‌ویژه در حوزه طبقه‌بندی مؤثر بوده‌اند و نشان داده‌اند که تجمیع چند دیدگاه شبکه‌ای دقت را افزایش می‌دهد. با وجود این، مدل‌های Ensemble قادر به تشخیص ناحیه نیستند و در نتیجه برای پایش دقیق نواحی آلوده محدودیت دارند. در ادامه، استفاده از Transfer Learning بر روی مدل‌های ازپیش‌آموزش‌دیده بر ImageNet نقش مهمی در کاهش نیاز به مجموعه داده‌های بزرگ داشت. این مدل‌ها ویژگی‌های اولیه مؤثر را یاد گرفته‌اند و با Fine-tuning می‌توانند عملکرد بسیار خوبی ارائه دهند. با وجود این، همچنان قادر به شناسایی محل دقیق بیماری نیستند و در شرایط محیطی پیچیده با چالش مواجه می‌شوند.

با ظهور مدل‌های تشخیص ناحیه، به‌ویژه خانواده YOLO و سپس YOLOX، بسیاری از این محدودیت‌ها برطرف شدند. YOLO برای اولین بار تشخیص ناحیه را با سرعت بالا ممکن کرد و YOLOX با نوآوری‌هایی مانند حذف anchorها، استفاده از decoupled head، تخصیص پویا (SimOTA) و بهره‌گیری از backboneهای مدرن یک جهش جدی ایجاد کرد. در بسیاری از پژوهش‌ها، YOLOX در داده‌های طبیعی عملکرد پایدارتر و مقاوم‌تری نسبت به YOLOv5 و Faster R-CNN نشان داده است. افزوده شدن مکانیزم‌های توجه مانند CBAM نیز سبب افزایش حساسیت مدل نسبت به ناحیه‌های کوچک بیماری شده است. در سال‌های اخیر، مدل‌های هیبرید که ترکیبی از backboneهای مدرن و بلوک‌های توجه هستند، به‌عنوان نسل جدید معماری‌ها معرفی شده‌اند. این مدل‌ها توانایی استخراج دقیق ویژگی‌ها را با قدرت تمرکز مکانی و کانالی ترکیب می‌کنند و نتیجه آن عملکرد قابل‌توجه در داده‌های پیچیده واقعی است. پژوهش‌هایی که از ترکیب‌هایی مانند YOLOX+CBAM یا MobileNet+ECA استفاده کرده‌اند، نشان داده‌اند که مکانیزم‌های توجه می‌توانند ضعف شبکه‌های سبک‌وزن یا شبکه‌های مبتنی بر داده‌های محدود را جبران کنند. در نهایت، تحلیل مجموعه این مطالعات نشان می‌دهد که حوزه تشخیص بیماری گیاهی مسیری تکاملی را طی کرده است: از ویژگی‌های دستی به CNNها، از CNNها به Ensemble، از Ensemble به Detection، و سپس به مدل‌های هیبرید مجهز به توجه. پروژه تو دقیقاً در امتداد این روند قرار دارد و از قوی‌ترین رویکردهای مدرن استفاده کرده است. ترکیب YOLOX با ConvNeXt

و CBAM یکی از پیشرفته‌ترین ساختارهای موجود برای تشخیص ناحیه بیماری محسوب می‌شود و در بخش طبقه‌بندی نیز Ensemble CNN با ایجاد «توجه جمعی» دقت و پایداری را افزایش می‌دهد. این انتخاب‌ها نشان می‌دهد معماری پروژه تو با جریان روز پژوهشی کاملاً هماهنگ است و از بهترین تکنیک‌های هر مرحله بهره می‌برد.

۳-۵-۲ تحلیل شکاف‌های پژوهشی

اگرچه حجم قابل توجهی از پژوهش‌ها در حوزه تشخیص بیماری گیاهان انجام شده است، همچنان شکاف‌های علمی مهمی وجود دارد که نیازمند بررسی و توسعه بیشتر هستند. یکی از اصلی‌ترین این شکاف‌ها، فقدان مجموعه داده‌های واقعی و متوازن است. بسیاری از مطالعات از مجموعه داده‌هایی مانند PlantVillage استفاده می‌کنند که در محیط کنترل شده تصویربرداری شده‌اند. این امر موجب می‌شود مدل‌ها در مواجهه با تصاویر واقعی عملکرد ضعیفی داشته باشند. علاوه بر این، عدم تعادل کلاس‌ها در داده‌های واقعی رایج است؛ برخی بیماری‌ها بسیار نادرند و همین موضوع باعث کاهش حساسیت مدل‌های یادگیری عمیق نسبت به آن‌ها می‌شود.

شکاف مهم دیگر مربوط به فقدان پژوهش‌هایی است که طبقه‌بندی و تشخیص ناحیه را در قالب یک سیستم یکپارچه بررسی کنند. اغلب مطالعات تنها به یکی از این دو وظیفه پرداخته‌اند - یا طبقه‌بندی، یا تشخیص ناحیه - در حالی که کاربردهای عملی نیازمند سیستمی هستند که ابتدا نوع بیماری را تشخیص دهد و سپس محل دقیق آن را مشخص کند. تعداد اندکی از پژوهش‌ها هر دو هدف را هم‌زمان دنبال کرده‌اند.

شکاف سوم به استفاده محدود از مکانیزم‌های توجه در مدل‌های Detection بازمی‌گردد. هرچند برخی پژوهش‌ها CBAM را با YOLOv5 یا YOLOX ترکیب کرده‌اند، اکثریت مدل‌ها هنوز از ساختارهای قدیمی بهره می‌برند. مدل‌هایی مانند SE و ECA تنها بخش محدودی از اطلاعات را تقویت می‌کنند و پژوهش‌های کمی به بررسی ترکیب چند نوع توجه در تشخیص بیماری گیاهان پرداخته‌اند.

شکاف چهارم مربوط به بک‌بون‌هاست. بسیاری از مطالعات همچنان از ResNet یا CSPDarknet استفاده می‌کنند، در حالی که مدل‌های مدرن‌تر مانند ConvNeXt یا Swin Transformer می‌توانند استخراج ویژگی‌های مدل را به‌طور چشمگیری افزایش دهند. با این حال، به دلیل جدید بودن این معماری‌ها، پژوهش‌های محدودی بر روی ترکیب آن‌ها با YOLOX انجام شده است.

شکاف پنجم مربوط به تعامل چندمرحله‌ای مدل‌هاست. اغلب مطالعات بررسی نکرده‌اند که چگونه

خروجی فاز طبقه‌بندی می‌تواند کیفیت فاز تشخیص ناحیه را بهبود بخشد. پژوهش‌های اندکی بررسی کرده‌اند که اطلاعات طبقه‌بندی‌شده اولیه چگونه می‌تواند وزن‌دهی در تشخیص را تقویت کند یا اینکه آیا ترکیب CNN-Ensemble می‌تواند پیش از YOLOX به‌عنوان فیلتری برای داده‌ها به کار رود. در مجموع، این شکاف‌های پژوهشی نشان می‌دهند که هنوز فضای گسترده‌ای برای توسعه مدل‌های ترکیبی، سیستم‌های چندمرحله‌ای و بهره‌گیری از بک‌بون‌ها و مکانیزم‌های توجه مدرن وجود دارد.

۳-۵-۳ جایگاه پژوهش انجام شده در ادبیات پژوهشی

پروژه حاضر در نقطه تلاقی چند جریان پژوهشی مهم قرار دارد و می‌توان آن را نمونه‌ای از یک سیستم چندمرحله‌ای هوشمند دانست که از بهترین دستاوردهای علمی بهره برده است. در فاز اول، مدل‌های CNN شامل VGG، text و GoogLeNet بر اساس Transfer Learning آموزش داده شدند و در قالب یک Ensemble ترکیب گردیدند. این ساختار نه تنها دقت طبقه‌بندی را به حداکثر می‌رساند، بلکه پایداری و توان تعمیم مدل را نیز افزایش می‌دهد. عملکرد این بخش از پروژه با ادبیات پژوهشی مرتبط با Ensemble کاملاً هم‌سو است و نسبت به بسیاری از مطالعاتی که تنها از یک یا دو معماری استفاده کرده‌اند، جامع‌تر عمل می‌کند.

در فاز دوم، از مدل YOLOX استفاده شد که یکی از جدیدترین و قدرتمندترین مدل‌های تشخیص ناحیه به شمار می‌رود. ساختار anchor-free و الگوریتم تخصیص پویا (SimOTA) موجب شده است YOLOX یکی از مناسب‌ترین گزینه‌ها برای داده‌های واقعی مانند PlantDoc باشد. استفاده از Backbone مدرن ConvNeXt نیز پروژه را نسبت به بسیاری از پژوهش‌های پیشین متمایز می‌کند، زیرا این Backbone هنوز در اغلب مطالعات کشاورزی به کار گرفته نشده است و نشان‌دهنده رویکردی نوین در طراحی سیستم است.

ادغام CBAM در کنار YOLOX نیز کاملاً با آخرین جریان پژوهشی هماهنگ است. این مکانیزم توجه باعث می‌شود مدل روی نواحی کوچک و پراکنده بیماری تمرکز بیشتری داشته باشد و عملکرد آن در داده‌های واقعی به‌طور چشمگیری افزایش یابد. ترکیب ویژه YOLOX + ConvNeXt + CBAM در ادبیات علمی کمتر دیده شده و از این نظر، پروژه حاضر نوعی نوآوری در حوزه کشاورزی هوشمند محسوب می‌شود.

به طور کلی، پروژه حاضر نه تنها با ادبیات پژوهشی مدرن هماهنگ است، بلکه برخی از شکاف‌های پژوهشی موجود -مانند استفاده هم‌زمان از طبقه‌بندی Ensemble و تشخیص ناحیه پیشرفته- را نیز

پوشش داده است. این پروژه یک ساختار جامع ارائه می‌دهد که می‌تواند به‌عنوان الگویی برای سیستم‌های چندمرحله‌ای در پژوهش‌های آینده مورد استفاده قرار گیرد.

۳-۶ جمع‌بندی

در این فصل تلاش شد مروری جامع، تحلیلی و انتقادی بر پژوهش‌های موجود در حوزه تشخیص بیماری گیاهان ارائه شود. از روش‌های کلاسیک مبتنی بر ویژگی‌های دستی تا شبکه‌های عصبی کانولوشنی، رویکردهای انتقال یادگیری، مدل‌های تشخیص ناحیه، ساختار YOLOX، مکانیزم‌های توجه و مدل‌های هیبرید بررسی شدند. تحلیل پژوهش‌ها نشان داد که هیچ روش منفردی قادر به حل تمام چالش‌های داده‌های واقعی نیست. روش‌های کلاسیک در داده‌های طبیعی ناکارآمدند، CNNها حتی با دقت بالا در داده‌های کنترل‌شده، در داده‌های واقعی دچار افت عملکرد می‌شوند و مدل‌های Detection در صورتی که از مکانیزم‌های توجه و Backboneهای مدرن استفاده نکنند، ممکن است بخش‌هایی از نواحی کوچک بیماری را تشخیص ندهند.

پروژه حاضر با ترکیب بهترین روش‌های هر مرحله -استفاده از CNN و Ensemble برای طبقه‌بندی و بهره‌گیری از YOLOX به همراه ConvNeXt و CBAM برای تشخیص ناحیه- یک ساختار پیشرفته و عملی ارائه کرده است. این رویکرد جایگاه مناسبی در میان مطالعات مشابه دارد و می‌تواند پایه‌ای برای توسعه مدل‌های هیبرید و سیستم‌های چندمرحله‌ای در کشاورزی هوشمند باشد. در فصل بعد، روش‌شناسی پروژه، ساختار مدل‌ها و فرایند پیاده‌سازی به تفصیل ارائه خواهند شد.

فصل ۴

پیاده‌سازی و ارزیابی مدل‌های تشخیص بیماری گیاهان

۴-۱ ساختار سیستم و فرایند پیش‌پردازش پیشنهادی

۴-۱-۱ مقدمه

فصل حاضر به تشریح روش‌شناسی، اجزای اصلی و مراحل پیاده‌سازی پروژه می‌پردازد و به‌عنوان مهم‌ترین فصل پایان‌نامه، نقش تعیین‌کننده‌ای در انتقال درک دقیق از نحوه طراحی سیستم دارد. برخلاف فصل دوم که بر مرور مطالعات پیشین و معرفی مدل‌های مطرح تمرکز داشت، این فصل بر فعالیت‌های عملی انجام‌شده در پروژه متمرکز است. در این بخش توضیح داده می‌شود که مدل‌های انتخاب‌شده چگونه از مرحله ایده تا اجرا پیش رفته‌اند، چرا این مدل‌ها برگزیده شده‌اند، چه پارامترهایی برای آن‌ها تنظیم شده و فرایند آموزش و ارزیابی با چه چالش‌هایی همراه بوده است.

پروژه حاضر یک سیستم دومرحله‌ای است که هر مرحله هدفی متمایز دارد. مرحله نخست با استفاده از شبکه‌های عصبی کانولوشنی، مسئول طبقه‌بندی بیماری‌ها در محیط کنترل‌شده است؛ در حالی که مرحله دوم تشخیص ناحیه بیماری را در تصاویر واقعی مزرعه بر عهده دارد. این رویکرد دومرحله‌ای ساختاری قدرتمند ایجاد می‌کند: در مرحله اول، مدل با داده‌های تمیز و فاقد نویز آشنا می‌شود و الگوهای اصلی بیماری‌ها را با دقت فرا می‌گیرد؛ و در مرحله دوم، همین دانش بنیادی با کمک مدل YOLOX در محیط واقعی بسط می‌یابد. از منظر مهندسی هوش مصنوعی، این فرایند هوشمندانه است؛ زیرا ابتدا مدل «می‌آموزد بیماری چیست» و سپس «می‌آموزد بیماری در تصویر واقعی کجا قرار دارد». در ادامه این فصل، ساختار کلی سیستم، معرفی دقیق دو دیتاست PlantVillage و PlantDoc، مراحل پیش‌پردازش هر دو مجموعه داده و نحوه آماده‌سازی آن‌ها برای آموزش ارائه خواهد شد. هدف آن است که خواننده در پایان این بخش، درک روشن و کاملی از داده‌های ورودی و مراحل اولیه پردازش آن‌ها به‌دست آورد.

۴-۱-۲ ساختار کلی سیستم پیاده‌سازی شده

ساختار کلی این سیستم بر پایه ترکیب دو مدل مجزا اما مکمل طراحی شده است: یک مدل برای طبقه‌بندی بیماری‌ها و مدلی دیگر برای تشخیص ناحیه آسیب‌دیده. در مرحله نخست، تصاویر برگ‌ها به سیستم طبقه‌بندی مبتنی بر شبکه‌های عصبی کانولوشنی وارد می‌شوند. این سیستم، که بر اساس سه معماری EfficientNetB0، ResNet50 و MobileNetV2 طراحی شده است، تصویر ورودی را تحلیل

کرده و نوع بیماری احتمالی را مشخص می‌کند. خروجی این مرحله اطلاعات قابل اتکایی درباره وجود بیماری و دسته آن فراهم می‌سازد.

در مرحله دوم، همان تصویر وارد مدل YOLOX می‌شود؛ مدلی که علاوه بر تشخیص نوع بیماری، مختصات دقیق ناحیه آلوده را نیز شناسایی می‌کند. این قابلیت در کاربردهای عملی اهمیت ویژه‌ای دارد، زیرا در شرایط حقیقی مزرعه، دانستن محل دقیق بیماری از دانستن صرف وجود آن مهم‌تر است. YOLOX با بهره‌گیری از Backbone مدرن ConvNeXt و مکانیزم توجه CBAM، توان بالایی در تمرکز بر نواحی کلیدی تصویر دارد و همین امر موجب شده عملکرد آن در داده‌های پیچیده و پرنویز PlantDoc به‌طور محسوسی بهبود یابد.

این رویکرد دومرحله‌ای در عمل ترکیبی از «یادگیری دقیق در محیط کنترل‌شده» و «به‌کارگیری هوشمند در محیط واقعی» را فراهم می‌کند. هرچند این ایده در مطالعات جدید توصیه شده است، اما اجرای کامل و یکپارچه آن در قالب یک سیستم جامع کمتر دیده می‌شود. پروژه حاضر با پیاده‌سازی این ساختار توانسته است محدودیت‌های هر مرحله را با مرحله دیگر پوشش دهد و سامانه‌ای ارائه کند که هم در محیط آزمایشگاهی و هم در شرایط واقعی مزرعه عملکرد قابل توجهی دارد.

۴-۱-۳ دلایل انتخاب دیتاست PlantVillage

مجموعه داده PlantVillage یکی از مهم‌ترین منابع پژوهشی در حوزه تشخیص بیماری گیاهان است و به‌عنوان یک دیتاست استاندارد و کنترل‌شده شناخته می‌شود. این مجموعه شامل تصاویر برگ چندین گونه گیاهی است که همگی در شرایط کاملاً ثابت تصویربرداری شده‌اند؛ به‌طوری‌که پس‌زمینه یکنواخت، نورپردازی یکسان و نبود عوامل محیطی موجب شده تصاویر فاقد هرگونه پیچیدگی یا نویز مزرعه باشند. همین ویژگی‌ها سبب می‌شود شبکه‌های عمیق بتوانند الگوهای بیماری را بدون دخالت عوامل مزاحم با دقت بسیار بالا فرا بگیرند.

انتخاب PlantVillage برای مرحله طبقه‌بندی در این پروژه کاملاً هدفمند بوده است. پیش از آن که مدل با تصاویر دشوار و واقعی PlantDoc روبه‌رو شود، لازم است مفاهیم پایه‌ای بیماری‌ها -از جمله تفاوت‌های ظریف در رنگ، شکل لکه‌ها و بافت سطح برگ- در محیطی کنترل‌شده و ساده یاد گرفته شود. استفاده از یک دیتاست بدون تنوع محیطی باعث شد مدل بتواند ویژگی‌های بنیادین بیماری‌ها را استخراج کند و یک درک اولیه دقیق از الگوهای بصری مورد نیاز به‌دست آورد.

نتایج تجربی پروژه نیز این موضوع را تأیید کرد؛ مدل‌های CNN در دیتاست PlantVillage به دقت‌هایی

نزدیک به ۹۹٪ دست یافتند. هرچند این میزان دقت در داده‌های واقعی قابل دستیابی نیست، اما همین عملکرد بالا در مرحله نخست، پایه محکم و ضروری برای موفقیت مرحله تشخیص ناحیه در تصاویر واقعی فراهم می‌کند.

۴-۱-۴ دلایل انتخاب دیتاست PlantDoc

برخلاف دیتاست PlantVillage که در محیط کنترل‌شده تهیه شده، مجموعه داده PlantDoc شامل تصاویر واقعی برگ‌ها در شرایط مزرعه است. این تصاویر با دوربین‌های مختلف، نورپردازی‌های نامنظم، زاویه‌های متنوع و پس‌زمینه‌های کاملاً ناهمگون ثبت شده‌اند. در بسیاری از نمونه‌ها برگ تنها بخش کوچکی از تصویر را تشکیل می‌دهد و بخش عمده تصویر شامل عناصر مزرعه مانند خاک، شاخه‌ها، ابزار کشاورزی، برگ‌های دیگر یا بافت‌های پیچیده گیاه است. این تنوع و آشفتگی بصری سبب شده PlantDoc یکی از دشوارترین مجموعه داده‌ها برای تشخیص بیماری گیاهی به‌شمار آید.

یکی از مزیت‌های مهم این دیتاست وجود برچسب‌های Bounding Box برای ناحیه بیماری است. به کمک این برچسب‌ها، مدل YOLOX می‌تواند علاوه بر تشخیص وجود بیماری، محل دقیق آن را نیز بیاموزد. بسیاری از بیماری‌های موجود در PlantDoc لکه‌های بسیار کوچک و پراکنده تولید می‌کنند. لکه‌هایی که گاهی تنها چند پیکسل اندازه دارند. این موضوع نشان می‌دهد که تشخیص بیماری در محیط واقعی یک مسئله صرفاً طبقه‌بندی نیست، بلکه یک چالش پیچیده در سطح تشخیص ناحیه (localization) محسوب می‌شود.

انتخاب PlantDoc برای مرحله Detection کاملاً ضروری و منطقی است؛ زیرا مرحله دوم باید عملکردی عملیاتی و مقاوم در برابر تنوع واقعی داده‌ها داشته باشد. مجموعه داده PlantDoc دقیقاً همان شرایط دشواری را فراهم می‌کند که برای ارزیابی پایداری و کارآمدی مدل YOLOX در محیط واقعی نیاز است.

۴-۱-۵ مراحل پیش‌پردازش داده‌های PlantVillage

برای آنکه مدل‌های CNN بتوانند بهترین عملکرد را ارائه دهند، داده‌های ورودی باید به گونه‌ای پیش‌پردازش شوند که از نظر اندازه، مقیاس و طیف رنگی با استانداردهای شبکه سازگار باشند. در این پروژه، تصاویر مجموعه داده PlantVillage ابتدا به اندازه ورودی مدل‌ها تغییر داده شدند. برای معماری‌هایی مانند EfficientNetB0 و MobileNetV2 ابعاد استاندارد 224×224 پیکسل در نظر گرفته شد. علاوه بر این،

تمام تصاویر بر اساس میانگین و انحراف معیار مجموعه داده ImageNet نرمال‌سازی شدند تا شبکه بتواند با داده‌هایی هم‌مقیاس و استاندارد آموزش ببیند. از آنجا که PlantVillage یک دیتاست کنترل‌شده با تنوع تصویری نسبتاً محدود است، استفاده از Data Augmentation برای جلوگیری از بیش‌برازش کاملاً ضروری بود. اعمال تحولاتی مانند چرخش‌های کوچک، تغییرات روشنایی، برش تصادفی (Random Crop) و وارون‌سازی افقی باعث شد شبکه‌های CNN بتوانند الگوهای بیماری را در شرایط متنوع‌تری مشاهده و یادگیری کنند. این افزایش تنوع داده سبب شد مدل‌ها وابستگی کمتری به شرایط ثابت تصویربرداری داشته باشند و در مواجهه با داده‌های واقعی کمتر دچار خطا شوند.

۴-۱-۶ مراحل پیش‌پردازش داده‌های PlantDoc

پیش‌پردازش داده‌های PlantDoc به مراتب تخصصی‌تر و حساس‌تر از PlantVillage است، زیرا داده‌های این مجموعه به شدت نامنظم هستند و مدل Detection باید توانایی تشخیص ناحیه‌های کوچک بیماری را در تصویری مملو از نویز محیطی داشته باشد. نخستین مرحله، تغییر اندازه تصاویر به ابعاد استاندارد YOLOX بود که معمولاً 416×416 یا 640×640 است. انتخاب ابعاد بزرگ‌تر باعث بهبود قابل توجه در تشخیص نواحی کوچک شد.

علاوه بر تغییر اندازه، مجموعه‌ای از تکنیک‌های افزایش داده پیشرفته به کار گرفته شد که مهم‌ترین آن‌ها Mosaic Augmentation است. در این روش، چهار تصویر مختلف به صورت تصادفی با یکدیگر ترکیب می‌شوند و مدل را در معرض الگوهای غیرمنتظره قرار می‌دهند. این کار سبب می‌شود YOLOX توانایی تعمیم‌پذیری بسیار بالاتری پیدا کند. افزون بر Mosaic، تغییرات شدید رنگ، چرخش‌های تصادفی و Transform‌های هندسی نیز اعمال شد تا مدل در برابر شرایط نوری و محیطی متنوع مقاوم شود. این نوع پیش‌پردازش پیشرفته نقش بسیار مهمی در عملکرد YOLOX داشت. بدون Augmentation‌های سنگین، مدل توجه خود را به سرعت روی پس‌زمینه از دست می‌داد و بخش‌های کوچک بیماری را تشخیص نمی‌داد. نتایج آزمایش‌ها نشان داد که فرایند پیش‌پردازش سهم قابل توجهی در بهبود mAP مدل داشته است.

۴-۲ معماری شبکه‌های CNN و مدل Ensemble سه‌لایه

۴-۲-۱ مقدمه‌ای بر معماری‌های CNN مورد استفاده در مرحله اول

در مرحله نخست پروژه، هدف اصلی ایجاد یک سیستم طبقه‌بندی دقیق برای شناسایی بیماری‌های گیاهی در داده‌های کنترل‌شده بود. از آنجا که مجموعه داده PlantVillage دارای نور یکنواخت، پس‌زمینه تک‌رنگ و کیفیت نسبتاً استاندارد است، مناسب‌ترین انتخاب برای این مرحله استفاده از شبکه‌های عصبی کانولوشنی بود. این شبکه‌ها به دلیل توانایی بالا در استخراج سلسله‌مراتبی ویژگی‌ها و عملکرد ثابت شده در مسائل طبقه‌بندی تصویر، سال‌هاست که به‌عنوان ساختارهای پایه در بینایی ماشین مورد استفاده قرار می‌گیرند.

در این پروژه، سه معماری EfficientNetB0، MobileNetV2 و ResNet50 به‌عنوان مدل‌های پایه انتخاب شدند. دلیل این انتخاب تنها فراگیری و محبوبیت آن‌ها نبود؛ بلکه هر یک از این معماری‌ها الگوی متفاوتی از استخراج ویژگی را ارائه می‌دهند. EfficientNetB0 با مقیاس‌بندی متوازن عمق، عرض و رزولوشن، مدلی کارآمد و دقیق فراهم می‌کند. MobileNetV2 با ساختار سبک و لایه‌های bottleneck برای داده‌های طبقه‌بندی بهینه است. ResNet50 نیز با اتصالات میان‌بر خود قادر است ویژگی‌های عمیق‌تری استخراج کند.

ترکیب این سه معماری باعث شد سیستم طبقه‌بندی نهایی دیدی چندوجهی از الگوهای بیماری به دست آورد و پایه‌ای قدرتمند برای مراحل بعدی پروژه فراهم شود.

۴-۲-۲ معماری EfficientNetB0 و نقش آن در استخراج ویژگی‌های چندمقیاسی

EfficientNetB0 یکی از کارآمدترین معماری‌های مدرن در حوزه شبکه‌های کانولوشنی است که با استفاده از روش compound scaling به شکلی هماهنگ عمق، عرض و رزولوشن شبکه را افزایش می‌دهد. این معماری برخلاف مدل‌های قدیمی‌تر که معمولاً تنها یک بُعد شبکه را بزرگ‌تر می‌کردند، از ابتدا به گونه‌ای طراحی شده است که با کمترین تعداد پارامتر، بیشترین توانایی در استخراج ویژگی‌ها را داشته باشد. EfficientNetB0 از بلوک‌های MBConv تشکیل شده است؛ بلوک‌هایی که با فشردن کانال‌ها، کانولوشن عمقی تفکیکی و اتصال‌های میان‌راهی، امکان استخراج ویژگی‌های دقیق را با هزینه محاسباتی بسیار کم فراهم می‌کنند. این موضوع در داده PlantVillage اهمیت ویژه‌ای دارد، زیرا بسیاری

از بیماری‌های گیاهی تنها با الگوهای بافتی و رنگی بسیار ظریف قابل تشخیص هستند و مدل باید بتواند این تغییرات کوچک را بدون افزایش بیش از حد سربار محاسباتی یاد بگیرد. در تصاویر PlantVillage که پس‌زمینه ساده و شرایط تصویربرداری کنترل شده دارند، EfficientNetB0 می‌تواند به‌خوبی از مزیت خود در استخراج ویژگی‌های چندمقیاسی استفاده کند. ساختار بهینه این شبکه اجازه می‌دهد که هم نواحی کوچک مانند لکه‌های ابتدایی بیماری را تشخیص دهد و هم ساختارهای بزرگ‌تر مانند تغییر رنگ گسترده یا پوسیدگی سطح برگ را به دقت تحلیل کند. در این پروژه، EfficientNetB0 به عنوان یکی از مدل‌های سبک و در عین حال قدرتمند انتخاب شد تا تعادل مناسبی بین سرعت آموزش، نیاز محاسباتی و دقت طبقه‌بندی ایجاد شود. این معماری با تعداد پارامتر کم و بازده بالا امکان می‌دهد مجموعه پایه مدل‌ها بدون ایجاد سربار سنگین، همچنان عملکردی قابل اعتماد در شناسایی بیماری‌های کم‌تفاوت یا ظریف داشته باشند.

۴-۲-۳ معماری ResNet50 و قدرت یادگیری عمیق آن

معماری ResNet50 یکی از نقاط عطف یادگیری عمیق است که با معرفی مفهوم Residual Learning توانست محدودیت شبکه‌های بسیار عمیق را برطرف کند. استفاده از اتصالات میان‌بر (Skip Connections) این امکان را فراهم می‌کند که اطلاعات بدون افت کیفیت از لایه‌ها عبور کنند و شبکه در عین افزایش عمق، با مشکل محو شدن گرادینان مواجه نشود.

در حوزه تشخیص بیماری‌های گیاهی، بسیاری از الگوهای مهم تنها زمانی قابل شناسایی هستند که شبکه بتواند ساختارهای چندلایه و پیچیده را تحلیل کند، برای مثال الگوهای غیرعادی رگ‌برگ‌ها، نحوه گسترش لکه‌ها، یا پراکندگی رنگ در سطح برگ. چنین ویژگی‌هایی ماهیتی انتزاعی دارند و نیازمند معماری‌هایی عمیق و قدرتمند هستند؛ جایی که ResNet50 عملکرد ایده‌آل خود را نشان می‌دهد.

نتایج پروژه حاضر نیز این موضوع را تأیید کردند: ResNet50 عملکردی پایدار، دقیق و قابل اعتماد ارائه داد و در بسیاری از کلاس‌هایی که سایر مدل‌ها -مانند EfficientNetB0 یا MobileNetV2- در آن‌ها دچار اشتباه می‌شدند، موفق بود. همین توانایی باعث شد این معماری به‌عنوان هسته اصلی Ensemble انتخاب شود و سهم بیشتری در خروجی نهایی داشته باشد. این رفتار کاملاً با یافته‌های پژوهش‌های معتبر هم‌سو است، جایی که قدرت ResNet در تشخیص بیماری‌هایی با الگوهای پیچیده بارها مورد تأیید قرار گرفته است.

۴-۲-۴ معماری MobileNetV2 و استخراج ویژگی‌های سبک و مؤثر

MobileNetV2 یکی از کارآمدترین معماری‌های سبک‌وزن در حوزه بینایی ماشین است که برای اجرا روی دستگاه‌های کم‌قدرت طراحی شده، اما در عین حال توانایی بالایی در استخراج ویژگی‌های مؤثر از تصویر دارد. هسته اصلی این معماری بلوک‌های Inverted Residual و Depthwise Separable Convolution است؛ ساختاری که هم سرعت پردازش را بالا می‌برد و هم اجازه می‌دهد مدل بتواند به الگوهای ظریف و گسترده به‌طور هم‌زمان واکنش نشان دهد.

در MobileNetV2، کانولوشن depthwise ابتدا هر کانال تصویر را جداگانه پردازش می‌کند؛ این کار باعث می‌شود مدل به تغییرات کوچک رنگ و بافت روی برگ بسیار حساس باشد. سپس مرحله expand در بلوک Inverted Residual کانال‌ها را بزرگ‌تر می‌کند تا ویژگی‌های پیچیده‌تر و گسترده‌تر نیز قابل تحلیل شوند. این ترکیب باعث ایجاد یک رفتار چندمقیاسی «غیرمستقیم» می‌شود؛ به این معنی که مدل می‌تواند هم لکه‌های کوچک و موضعی را تشخیص دهد و هم ساختارهای بزرگ‌تر مثل نواحی گسترده پوسیدگی یا تغییر رنگ.

آزمایش‌های انجام‌شده در پروژه نشان دادند که MobileNetV2 با وجود کوچک بودن، در تشخیص بیماری‌هایی که الگوهای کم‌کنتراست یا بافت‌های محلی ریز دارند عملکرد بسیار قابل قبولی ارائه می‌دهد. مهم‌تر اینکه سبک بودن مدل به هیچ‌وجه مانعی برای کیفیت استخراج ویژگی‌ها نبود؛ بلکه باعث شد شبکه در پردازش داده‌های یکنواخت PlantVillage سریع‌تر و کارآمدتر عمل کند. این ویژگی‌ها MobileNetV2 را به یک گزینه مناسب برای استفاده در کنار EfficientNetB0 و GoogLeNet در مدل Ensemble تبدیل کرد، زیرا نوع متفاوتی از ویژگی‌ها را استخراج می‌کند که سایر معماری‌ها کمتر به آن‌ها توجه می‌کنند.

۴-۲-۵ چرایی ترکیب سه معماری و ضرورت استفاده از Ensemble

سه معماری EfficientNetB0، MobileNetV2 و ResNet50 هر یک دیدگاه متفاوتی نسبت به تصویر ارائه می‌دهند و هیچ‌کدام به‌تنهایی قادر نیستند تمام جنبه‌های بصری مربوط به بیماری‌های گیاهی را پوشش دهند. در تشخیص دقیق بیماری‌ها، ویژگی‌های محلی، سراسری، بافتی، رنگی، ساختاری و چندمقیاسی همگی اهمیت دارند و ترکیب این سه معماری امکان استخراج جامع این ویژگی‌ها را فراهم می‌کند. مطالعات پیشین نیز تأکید کرده‌اند که در حوزه طبقه‌بندی بیماری گیاهی، استفاده از Ensemble یکی از مؤثرترین روش‌ها برای افزایش دقت و کاهش حساسیت به نویز است. در پروژه حاضر، Ensemble یک

ترکیب ساده نبود، بلکه یک سازوکار مهندسی‌شده برای هم‌افزایی سه نوع قابلیت بود:

- EfficientNetB0 به دلیل مقیاس‌گذاری متعادل (Balanced Scaling) و ساختار سبک، ویژگی‌های پایه و محلی تصویر را با دقت بالا استخراج می‌کند.
- MobileNetV2 با بهره‌گیری از Bottleneck ها و inverted residuals، در استخراج الگوهای ظریف و کم‌عمق اما کارآمد، عملکرد بسیار مناسبی دارد.
- ResNet50 با عمق زیاد و توانایی تحلیل ویژگی‌های پیچیده، الگوهای انتزاعی و ساختارهای بزرگ‌تر را پوشش می‌دهد.

مدل نهایی به‌جای تکیه بر یک معماری، حاصل ترکیب هوشمندانه سه دیدگاه کاملاً متفاوت است که هر کدام بخش متفاوتی از فضای ویژگی را پوشش می‌دهند. نتیجه این طراحی دقیق، رسیدن به دقت ۹۹/۷٪ بود؛ رقمی که در پژوهش‌های مشابه بسیار کم گزارش شده و نشان‌دهنده اثربخشی Ensemble سه‌مدلی در این پروژه است.

۴-۲-۶ نحوه پیاده‌سازی Ensemble و منطق ادغام خروجی‌ها

پس از آموزش مستقل هر سه شبکه، مرحله ترکیب خروجی‌ها آغاز شد. خروجی هر مدل، یک بردار احتمال بود که برای هر کلاس مقدار احتمالی پیش‌بینی‌شده را نشان می‌داد. این بردارها سپس در یک ساختار وزن‌دار ادغام شدند. این روش که در بسیاری از پژوهش‌های Ensemble نیز استفاده شده، به مدل اجازه می‌دهد سهم بیشتری به معماری‌هایی بدهد که عملکرد قوی‌تری دارند. در آزمایش‌های پروژه مشخص شد که ResNet50 نسبت به دو مدل دیگر عملکرد پایدارتری دارد، بنابراین وزن بیشتری به آن اختصاص یافت، در حالی که EfficientNetB0 و MobileNetV2 به‌عنوان تقویت‌کننده‌های ویژگی‌های محلی و چندمقیاسی در خروجی نهایی نقش مهمی ایفا کردند.

فرایند تصمیم‌گیری نهایی کاملاً مبتنی بر رفتار احتمالاتی خروجی مدل‌ها بود و هیچ مرحله قضاوت سلیقه‌ای در آن وجود نداشت. این نوع ادغام خروجی باعث کاهش نوسانات مدل، افزایش پایداری و جلوگیری از overfitting شد. همین ویژگی‌ها دلیل بهبود عملکرد Ensemble نسبت به مدل‌های تکی بود.

۴-۲-۷ تنظیمات آموزش و چالش‌های آموزشی

آموزش مدل‌های CNN در PlantVillage برخلاف تصور اولیه کار ساده‌ای نبود، زیرا برخی کلاس‌ها شباهت‌های ظاهری بسیار زیادی داشتند. روشن است که نمونه‌های بیماری Early Blight و Septoria در گوجه‌فرنگی یا انواع بیماری‌های قارچی در سیب‌زمینی شباهت‌های بافتی دارند که تفکیک آن‌ها برای شبکه‌های ضعیف دشوار است. به همین دلیل آموزش مدل‌ها نیازمند استفاده از Data Augmentation‌های متنوع بود تا شبکه توانایی تشخیص بهتر الگوهای ظریف را پیدا کند. تغییرات نور، برش‌های تصادفی، چرخش‌های خفیف و تغییرات رنگی، همگی برای افزایش دقت مدل و جلوگیری از بیش‌برازش ضروری بودند.

یکی از چالش‌های اصلی آموزش ResNet50، نیاز آن به داده متنوع‌تر بود. این شبکه نسبت به روشنایی بسیار حساس بود و در آزمون‌های اولیه، در برخی تصاویر با نور غیرمتوازن دچار خطا می‌شد. این مشکل با افزایش میزان Augmentation برطرف شد. GoogLeNet نیز به دلیل سبک بودن، در برخی کلاس‌ها تمایل به underfitting داشت و نیازمند افزایش تعداد Epoch‌ها بود. در مقابل، EfficientNetB0 و MobileNetV2 در مراحل پایانی آموزش تمایل به overfitting داشتند که با استفاده از Early Stopping کنترل شد.

۴-۳ معماری YOLOX، ConvNeXt Backbone و مکانیزم توجه

CBAM در تشخیص ناحیه

۴-۳-۱ مقدمه‌ای بر ضرورت تشخیص ناحیه در داده‌های واقعی

مرحله دوم پروژه به‌طور کامل به تشخیص ناحیه بیماری در تصاویر واقعی اختصاص دارد؛ مرحله‌ای که به مراتب چالش‌برانگیزتر از بخش طبقه‌بندی است. برخلاف مرحله طبقه‌بندی که تصاویر برگ در محیطی کنترل‌شده و با پس‌زمینه ساده تهیه شده‌اند، تصاویر PlantDoc در شرایط طبیعی مزرعه ثبت شده‌اند. این تصاویر شامل عناصر متنوعی مانند خاک، چوب، ابزارهای کشاورزی، برگ‌های سالم، سایه‌ها و انعکاس نور هستند. چنین محیط پیچیده‌ای باعث می‌شود که تشخیص دقیق ناحیه بیماری تنها با مدل‌هایی ممکن باشد که توانایی استخراج ویژگی‌های پیچیده و مقابله با نویز محیطی را داشته باشند. YOLOX به‌عنوان یکی از قدرتمندترین مدل‌های Detection نسل جدید، انتخاب طبیعی برای این مرحله

بود، اما برای دستیابی به بهترین عملکرد نیازمند تقویت و بهینه‌سازی بود. در این پروژه، YOLOX همراه با ConvNeXt و مکانیزم توجه CBAM به‌صورت هماهنگ ترکیب شدند تا ساختاری مقاوم و دقیق برای تشخیص ناحیه بیماری ایجاد کنند.

۴-۳-۲ ساختار YOLOX و دلایل انتخاب آن

YOLOX نسل جدیدی از خانواده YOLO است که بر پایه طراحی Anchor-Free توسعه یافته است. برخلاف نسخه‌های پیشین YOLO مانند YOLOv3 یا YOLOv5 که برای پیش‌بینی ناحیه‌ها به Anchor Box‌های از پیش تعیین‌شده متکی بودند، YOLOX فرایند پیش‌بینی را بدون وابستگی به Anchor انجام می‌دهد. این ویژگی به‌ویژه هنگام تشخیص لکه‌های کوچک بیماری اهمیت دارد، زیرا Anchor‌های ثابت ممکن است در برابر شکل و اندازه نامنظم لکه‌ها انعطاف کافی نداشته باشند، در حالی که رویکرد Anchor-Free اجازه می‌دهد مدل نواحی کوچک و غیرمعمول را با دقت بالاتری شناسایی کند.

ساختار YOLOX دارای Head تفکیک‌شده است؛ یعنی مسیر یادگیری مربوط به تشخیص مختصات جعبه بیماری از مسیر طبقه‌بندی جدا شده است. این جداسازی تداخل گرادینان‌ها را کاهش می‌دهد و مدل را قادر می‌سازد هر دو وظیفه را با تمرکز بیشتری یاد بگیرد. در داده‌های واقعی که توزیع بیماری‌ها نامتقارن و غیرقابل پیش‌بینی است، این ویژگی دقت Localization را افزایش داده و نرخ خطای پیش‌بینی کلاس را کاهش می‌دهد. همچنین الگوریتم SimOTA در YOLOX نقش مهمی در تخصیص پویا و هوشمندانه نمونه‌ها دارد و به مدل کمک می‌کند نواحی با اهمیت بیشتر برای یادگیری را در هر تصویر شناسایی کند؛ کاری که Anchor‌های ثابت قادر به انجام آن نیستند.

در آزمایش‌های پروژه، YOLOX نسبت به YOLOv5 و برخی مدل‌های دیگر مانند EfficientDet رفتار بسیار پایدارتر و دقیق‌تری نشان داد. به همین دلیل این مدل به‌عنوان پایه مرحله Detection انتخاب شد، اما پیچیدگی‌های مجموعه‌داده PlantDoc به‌حدی بود که YOLOX به‌تنهایی نمی‌توانست عملکرد کامل ارائه دهد و نیازمند تقویت Backbone و استفاده از مکانیزم‌های توجه بود.

۴-۳-۳ ConvNeXt Backbone و نقش آن در بهبود استخراج ویژگی‌ها

Backbone در مدل‌های Detection نقش حیاتی دارد، زیرا تمام فرایند استخراج ویژگی‌ها بر عهده این بخش است. ConvNeXt یک معماری مدرن است که توسط محققان متا طراحی شده و تلفیقی

هوشمندانه از ساختار CNN‌های کلاسیک و ایده‌های بهینه‌سازی شده Transformer‌های بینایی محسوب می‌شود. برخلاف ResNet که سال‌ها Backbone اصلی مدل‌های YOLO بود، ConvNeXt از نظر عمق، وسعت Feature Map‌ها و طراحی داخلی ساختاری بسیار پیشرفته‌تر دارد و قادر است ویژگی‌های سطح‌بالا و سطح‌پایین را با کیفیت بیشتری استخراج کند.

در داده‌هایی مانند PlantDoc که تغییرات نوری، بافتی و محیطی بسیار زیاد هستند، Backbone‌های قدیمی مانند CSPDarknet و ResNet در عملکرد محدودتری دارند. ConvNeXt با بهره‌گیری از لایه‌های Normalization پیشرفته، کانولوشن‌های عمیق‌تر و طراحی Stage-Based، توانایی بالایی در مقابله با نویزهای بصری و استخراج ویژگی‌های پیچیده دارد. این Backbone می‌تواند مرز بین بافت سالم و نواحی بیمار برگ را با دقت بیشتری تشخیص دهد و لکه‌های پراکنده یا خطوط نامنظم را بهتر شناسایی کند.

در پروژه حاضر، ConvNeXt جایگزین Backbone اصلی YOLOX شد و مشاهده شد که دقت mAP مدل به‌طور قابل توجهی افزایش یافت. ویژگی‌های استخراج‌شده توسط ConvNeXt به Head مدل منتقل شدند و لبه‌های نازک، لکه‌های کوچک و بخش‌های پراکنده بیماری را با وضوح بیشتری ارائه کردند. این نتایج با یافته‌های پژوهش‌های اخیر (Scientific Reports, 2025) مطابقت داشت، که نشان داده بودند ConvNeXt هنگام ترکیب با YOLOX عملکردی فراتر از Backbone‌های کلاسیک ارائه می‌دهد [۴۱].

۴-۳-۴ نقش مکانیزم CBAM در افزایش تمرکز مدل بر ناحیه‌های بیماری

اگرچه ترکیب YOLOX و ConvNeXt یک ساختار قدرتمند برای تشخیص بیماری ایجاد می‌کند، اما پیچیدگی تصویری مجموعه داده PlantDoc به‌مراتب بیشتر است؛ به‌طوری که تنها یک Backbone پیشرفته به‌تنهایی قادر به رفع تمام چالش‌ها نیست. یکی از مشکلات جدی در تصاویر گیاهی، مزاحمت شدید پس‌زمینه است. مدل ممکن است روی عناصر غیرمرتبط مانند خاک، چوب، سنگریزه‌ها یا سایه‌ها تمرکز کند و ناحیه واقعی بیماری را نادیده بگیرد. به همین دلیل، استفاده از یک مکانیزم توجه برای برجسته‌کردن بخش‌های مهم تصویر ضروری بود.

مکانیزم CBAM دقیقاً برای چنین هدفی طراحی شده است. این مکانیزم از دو بخش مکمل -توجه کانالی و توجه فضایی- تشکیل می‌شود و می‌تواند اطلاعات مهم را تقویت و بخش‌های غیرضروری را سرکوب کند. در این پروژه، CBAM روی Feature Map‌های میان‌مرحله‌ای YOLOX اعمال شد تا پیش از آنکه اطلاعات به Head مدل منتقل شوند، ناحیه‌های مرتبط با بیماری برجسته گردند.

- توجه کانالی (Channel Attention): کانال‌هایی را که بیشترین ارتباط با الگوها و بافت‌های بیماری دارند تقویت می‌کند و به مدل کمک می‌کند ویژگی‌های مهم را پررنگ‌تر ببیند.

- توجه فضایی (Spatial Attention): کانال‌هایی را که بیشترین ارتباط با الگوها و بافت‌های بیماری دارند تقویت می‌کند و به مدل کمک می‌کند ویژگی‌های مهم را پررنگ‌تر ببیند.

نتایج آزمایش‌ها نشان داد که به‌کارگیری CBAM باعث کاهش چشمگیر خطاهای False Negative شد؛ یعنی مدل کمتر نمونه‌های بیمار را از دست داد. همچنین دقت Localization به‌ویژه در نواحی کوچک و پراکنده بیماری افزایش یافت. این ویژگی برای بیماری‌هایی که لکه‌های کوچک اولیه دارند بسیار ارزشمند است، زیرا تشخیص زودهنگام آن‌ها نقش مهمی در مدیریت بیماری دارد.

۵-۳-۴ فرایند آموزش مدل YOLOX-ConvNeXt-CBAM

در پروژه حاضر، آموزش مدل Detection مبتنی بر معماری پیشرفته نیازمند طراحی دقیق و مرحله‌به‌مرحله بود تا از نوسان شدید و بیش‌برازش جلوگیری شود. روند آموزش به‌صورت زیر اجرا شد: ابتدا YOLOX با Backbone پیش‌فرض خود آموزش داده شد تا ساختار پایه مدل پایدار گردد. پس از تثبیت این پایه، Backbone با ConvNeXt جایگزین شد و مدل وارد مرحله آموزش مجدد شد تا Feature Map‌های جدید تقویت شوند. در نهایت، پس از پایدار شدن عملکرد Backbone جدید، مکانیزم CBAM افزوده شد و مدل برای چند epoch به‌صورت fine-tune آموزش یافت تا تعادل میان توجه کانالی و فضایی برقرار شود.

به‌منظور افزایش مقاومت مدل در برابر تنوع بالای پس‌زمینه‌های مجموعه داده PlantDoc، از مجموعه‌ای از Augmentation‌های سنگین بهره گرفته شد؛ از جمله Mosaic، Random Affine Transformation و Color Jitter. این تبدیلات نقش اساسی در فرایند آموزش داشتند، زیرا بدون افزایش تنوع مصنوعی داده‌ها، YOLOX قادر به یادگیری الگوهای عمومی و قابل‌اعتماد در مواجهه با شرایط واقعی نبود.

۴-۴ پیاده‌سازی عملی، تنظیمات آموزشی، محیط اجرا و بهینه‌سازی

مدل‌ها

۴-۴-۱ مقدمه‌ای بر پیاده‌سازی عملی مدل‌ها

پیاده‌سازی عملی مدل‌های طبقه‌بندی و تشخیص ناحیه، مرحله‌ای است که در آن تمام ایده‌های نظری، معماری‌ها و روش‌های انتخاب‌شده در قالب کد اجرا می‌شوند. این مرحله از اهمیت ویژه‌ای برخوردار است، زیرا حتی بهترین معماری‌ها نیز اگر به‌درستی پیاده‌سازی نشوند یا تنظیمات آموزشی آن‌ها مناسب نباشد، نتیجه مطلوبی ارائه نخواهند داد. این بخش روند کامل پیاده‌سازی، تنظیم پارامترها، آماده‌سازی محیط اجرا، مشکلات مواجه‌شده و استراتژی‌های حل آن‌ها را ارائه می‌دهد. هدف این است که خواننده درک روشنی از مسیر عملی پروژه به‌دست آورد و بتواند مراحل فنی را بازتولید یا تحلیل کند.

۴-۴-۲ محیط اجرای پروژه و زیرساخت محاسباتی

اجرای مدل‌های یادگیری عمیق، به‌ویژه در بخش Detection، نیازمند محیط محاسباتی مناسب و بهینه است. در این پروژه، تمام پیاده‌سازی‌ها در بستری انجام شد که امکان استفاده کامل از GPU^۱ و کتابخانه‌های تخصصی یادگیری عمیق را فراهم می‌کرد. محیط نرم‌افزاری شامل Python 3.12، کتابخانه‌های PyTorch و Ultralytics برای YOLO، و Jupyter Notebook برای اجرای بلوک‌های CNN بود. بهره‌گیری از GPU، علاوه بر افزایش چشمگیر سرعت آموزش، امکان استفاده از Batch Size بزرگ‌تر را فراهم کرد و در نتیجه مدل‌ها سریع‌تر به همگرایی رسیدند.

در مرحله طبقه‌بندی، اجرای مدل‌های CNN به توان پردازشی متوسطی نیاز داشت؛ اما در بخش Detection به‌دلیل ابعاد بزرگ‌تر تصاویر، تعداد بالای Feature Map ها و استفاده از Backbone سنگینی مانند ConvNeXt، بار محاسباتی به‌مراتب بیشتر بود. برای مدیریت این بار و جلوگیری از افزایش مصرف حافظه، تکنیک‌هایی مانند Gradient Accumulation و Mixed Precision Training مورد استفاده قرار گرفتند. این روش‌ها امکان آموزش ایمن‌تر، کارآمدتر و با مصرف حافظه کمتر را فراهم کردند و نقش مهمی در پایداری آموزش مدل Detection داشتند.

^۱ Graphics Processing Unit

۴-۴-۳ پیاده‌سازی مدل‌های طبقه‌بندی

پیاده‌سازی مدل‌های طبقه‌بندی شامل سه معماری ResNet، EfficientNetB0 و MobileNetV2 بود که همگی بر پایه Transfer Learning اجرا شدند. استفاده از Transfer Learning به این دلیل انجام شد که این مدل‌ها پیش‌تر بر روی مجموعه‌داده ImageNet آموزش دیده‌اند و قادرند ویژگی‌های اولیه تصویر مانند لبه‌ها، بافت‌ها و الگوهای رنگی را از همان مراحل ابتدایی شناسایی کنند. این ویژگی باعث افزایش سرعت همگرایی، کاهش هزینه محاسباتی و بهبود دقت در مجموعه‌داده‌های نسبتاً کوچک‌تری مانند PlantVillage می‌شود.

در فرایند پیاده‌سازی، ابتدا لایه‌های اولیه هر مدل Freeze شدند تا از تغییر پارامترهای آموخته‌شده از ImageNet جلوگیری شود. سپس لایه‌های انتهایی بازطراحی و جایگزین شدند تا با تعداد کلاس‌های بیماری در PlantVillage سازگار باشند.

برای مثال، در EfficientNetB0 و MobileNetV2 بخش Head اولیه حذف و یک لایه Global Average Pooling به همراه یک لایه Dropout و نهایتاً یک لایه Dense با خروجی Softmax افزوده شد. در مدل ResNet نیز لایه Fully Connected اصلی با یک FC جدید متناسب با تعداد کلاس‌ها جایگزین شد. در طول آموزش، تعداد Epochها بر اساس رفتار Validation Loss تنظیم گردید و از Early Stopping برای جلوگیری از بیش‌برازش، به‌ویژه در مدل‌هایی مانند EfficientNetB0 که تمایل به یادگیری سریع دارند، استفاده شد. تجربه نشان داد که ResNet نیازمند Epochهای بیشتری برای رسیدن به همگرایی پایدار است، در حالی که MobileNetV2 به دلیل سبک بودن معماری و تعداد پارامترهای کمتر، سریع‌تر به حد بهینه می‌رسد.

یکی از نکات کلیدی این مرحله، طراحی مناسب Data Augmentation بود. Augmentationهای شدید ممکن است ساختارهای ظریف بیماری را تخریب کنند و مدل را دچار خطا سازند. بنابراین در این پروژه مجموعه‌ای از Augmentationهای ملایم و کنترل‌شده شامل چرخش‌های محدود، تغییرات جزئی نور، برش‌های کوچک و وارون‌سازی افقی استفاده شد تا هم تنوع داده افزایش یابد و هم بافت‌های حساس و کلیدی برگ حفظ شوند.

۴-۴-۴ پیاده‌سازی Ensemble دومدلی و سه‌مدلی

برای ارزیابی عملکرد روش یادگیری تجمعی (Ensemble Learning)، دو آزمایش مجزا طراحی و اجرا شد تا تأثیر ترکیب مدل‌ها بر دقت نهایی سیستم بررسی شود.

۱. Ensemble نخست (شامل EfficientNetB0 و MobileNetV2):

در این آزمایش، تنها دو مدل سبک و کارآمد EfficientNetB0 و MobileNetV2 در ساختار Ensemble مورد استفاده قرار گرفتند. وزن‌دهی بین دو مدل بر اساس دقت اعتبارسنجی آن‌ها انجام شد و خروجی نهایی از میانگین‌گیری وزن‌دار بردارهای Softmax حاصل شد. نتیجه نشان داد که دقت نهایی سیستم به ۹۹/۷٪ رسید؛ مقداری که نسبت به عملکرد هر یک از مدل‌ها در حالت مستقل، افزایش قابل‌توجهی محسوب می‌شود. این بهبود نشان می‌دهد که این دو مدل از نظر نوع ویژگی‌هایی که استخراج می‌کنند مکمل یکدیگر هستند.

۲. Ensemble دوم (شامل EfficientNetB0، MobileNetV2 و ResNet50):

در مرحله‌ی دوم، مدل ResNet50 به ساختار Ensemble افزوده شد. با توجه به عملکرد برتر ResNet50 در اعتبارسنجی، وزن‌دهی سه مدل به‌صورت دقیق و تجربی تعیین شد و ترکیب بهینه شامل ۹۸۵۹٪ برای ResNet50، مقدار ۹۹۴۲٪ برای EfficientNetB0، و مقدار ۹۸۶۷٪ برای MobileNetV2 بود. نتیجه حاصل از این ترکیب سه‌مدلی دقتی برابر با ۹۹/۷۶٪ را به دست داد که نسبت به Ensemble دومدلی نیز اندکی بهبود نشان می‌دهد. این افزایش -حتی اگر کوچک باشد- بیانگر نقش تکمیل‌کنندگی ویژگی‌های استخراج‌شده توسط ResNet50 است که عمق بیشتری به تصمیم نهایی مدل می‌افزاید.

این نتایج نشان می‌دهد که ترکیب مدل‌هایی با ماهیت متفاوت و مکمل، نه تنها دقت mean را افزایش می‌دهد، بلکه خطاهای موردی را نیز کاهش داده و سیستم را در کلاس‌های دشوار پایدارتر می‌کند.

۴-۴-۵ پیاده‌سازی YOLOX با Backbone ConvNeXt

مرحله Detection پروژه به‌طور کامل با استفاده از YOLOX اجرا شد، اما نسخه به‌کاررفته یک نسخه اصلاح‌شده و پیشرفته بود که در آن Backbone اصلی مدل با ConvNeXt جایگزین شد. این بخش از

پروژه یکی از پیچیده‌ترین قسمت‌ها بود، زیرا YOLOX به‌صورت پیش‌فرض از CSPDarknet استفاده می‌کند و جایگزینی Backbone نیازمند هماهنگی دقیق میان ابعاد Feature Map ها، ساختار FPN و لایه‌های YOLO Head است.

در گام نخست، YOLOX در نسخه پایه خود آموزش داده شد تا اطمینان حاصل شود که ساختار اصلی مدل برای مجموعه داده PlantDoc قابل‌استفاده است و دچار ناپایداری اولیه نمی‌شود. پس از تثبیت عملکرد نسخه پایه، فرایند جایگزینی Backbone آغاز شد. در این مرحله، لایه‌های CSPDarknet حذف و ConvNeXt جایگزین شدند؛ فرایندی که مستلزم بازآرایی کانال‌ها، هماهنگی Feature Pyramid Network و تنظیم مجدد ورودی‌های YOLO Head بود. این تغییرات با استفاده از تنظیمات پیشرفته PyTorch مدیریت شد تا مدل بتواند بدون بروز خطا و ناسازگاری در ابعاد، آموزش خود را ادامه دهد. پس از اعمال ConvNeXt، دقت مدل (mAP) به‌طور قابل‌توجهی افزایش یافت. با این حال، در خروجی‌ها مشخص شد که حساسیت مدل نسبت به عناصر پس‌زمینه نیز بیشتر شده است. این رفتار نشان می‌داد که هرچند ConvNeXt قدرت استخراج ویژگی‌های غنی و عمیق را دارد، اما بدون یک مکانیزم توجه ممکن است بخش‌های غیرمرتبط تصویر را نیز برجسته و مهم تلقی کند. همین مسئله ضرورت استفاده از مکانیزم CBAM را آشکار کرد و زمینه را برای مرحله بعدی بهبود فراهم نمود.

۴-۴-۶ ادغام CBAM در YOLOX و تنظیمات دقیق آن

افزودن CBAM به YOLOX نیازمند انتخاب محل مناسب برای قرارگیری آن بود. استفاده از CBAM در تمام لایه‌ها به دلیل افزایش هزینه محاسباتی امکان‌پذیر نبود؛ بنابراین این مکانیزم تنها در Feature Map های میانی قرار گرفت، یعنی جایی که مدل الگوهای بافتی و نواحی احتمالی بیماری را تحلیل می‌کند.

در پیاده‌سازی، توجه کانالی و فضایی CBAM به‌صورت پشت‌سرهم اعمال شد تا ابتدا وزن‌دهی به ویژگی‌های مهم کانالی و سپس تقویت موقعیت‌های مهم انجام شود. تنظیمات CBAM بر پایه یافته‌های مقالات مشابه انجام گرفت و نتایج تجربی نشان دادند که قرارگیری آن در بخش Feature Extraction بیشترین بهبود را در دقت ایجاد می‌کند.

۷-۴-۴ مشکلات و چالش‌های عملی در فرایند آموزش

در روند آموزش مدل، چندین محدودیت جدی مشاهده شد. مهم‌ترین آن‌ها کمبود حافظه GPU بود، به‌ویژه هنگام استفاده از YOLOX همراه با ConvNeXt که مصرف حافظه بالایی دارد. این چالش با Mixed Precision و کاهش Batch Size مدیریت شد. از طرف دیگر، Loss نوسانات زیادی داشت که ناشی از ناهمگنی شدید داده‌های PlantDoc بود. به‌کارگیری Cosine Annealing باعث هموارسازی منحنی Loss و بهبود پایداری آموزش شد [۵، ۳۹]. در ادامه، مدل تمایل به بیش‌برازش روی تصاویر با الگوهای پس‌زمینه مشابه داشت. برای کاهش این رفتار، استراتژی‌های داده‌افزایی گسترش یافتند؛ Mosaic تقویت شد و برای کنترل Overfitting تعداد Epoch‌های پایانی کاهش یافت.

۵-۴ نتایج، تحلیل عملکرد مدل‌ها و ارزیابی سیستمی

۱-۵-۴ مقدمه‌ای بر ارزیابی عملکرد سیستم

پس از تکمیل پیاده‌سازی مدل‌های بخش طبقه‌بندی و تشخیص ناحیه، مرحله ارزیابی آغاز شد. هدف از این مرحله، سنجش دقت، پایداری، میزان تعمیم‌پذیری و کاربردپذیری عملی سیستم بود. ارزیابی صرفاً به محاسبه چند معیار کمی محدود نشد، بلکه شامل تحلیل عمیق نتایج، بررسی الگوهای خطا، مقایسه دقیق عملکرد مدل‌ها و بررسی رفتار آن‌ها در شرایط واقعی مزرعه بود. در ادامه، نتایج حاصل از هر دو فاز پروژه ارائه و تحلیل می‌شود؛ نتایجی که نشان می‌دهند با وجود پیچیدگی‌های موجود در داده‌های واقعی، سیستم توسعه‌یافته عملکردی بسیار قابل قبول داشته و ساختار دو مرحله‌ای پروژه به‌طور کامل موفقیت خود را اثبات کرده است.

۲-۵-۴ نتایج مرحله طبقه‌بندی در دیتاست PlantVillage

نتایج مرحله طبقه‌بندی نشان داد که هر سه مدل پایه -ResNet50، EfficientNetB0 و MobileNetV2- توانایی بالایی در شناسایی بیماری‌ها در محیط کنترل‌شده دارند. این مدل‌ها در فاز آموزش و اعتبارسنجی به دقت‌های بالاتر از ۹۸٪ دست یافتند و رفتار بسیار پایداری از خود نشان دادند. با وجود عملکرد مطلوب هر مدل به‌صورت مستقل، ترکیب آن‌ها در قالب یک Ensemble سه‌مدلی موجب

جهش چشمگیر در دقت نهایی شد. دقت Ensemble به ۹۹.۷۶٪ رسید که نشان می‌دهد تلفیق تنوع ویژگی‌های استخراج‌شده توسط هر مدل، قدرت تشخیص بیماری‌ها را به شکل قابل توجهی افزایش می‌دهد. یکی از ویژگی‌های کلیدی این Ensemble، پایداری آن بود؛ در بسیاری از موارد که یکی از مدل‌ها دچار خطا می‌شد، دو مدل دیگر پاسخ صحیح ارائه می‌دادند و این امر باعث کاهش محسوس نرخ خطا شد.

تحلیل ماتریس اغتشاش نشان داد که بیشتر خطاها میان کلاس‌هایی رخ می‌دهد که شباهت بصری زیادی دارند، مانند Early Blight و Septoria در گوجه‌فرنگی. با این حال، پس از ترکیب مدل‌ها، این خطاها کاهش یافته و نشان می‌دهد که Ensemble نه تنها دقت میانگین را بهبود می‌بخشد، بلکه خطاهای موردی (case-based errors) را نیز به طور مؤثری کاهش می‌دهد.

در ادامه، نتایج ارزیابی کلاس به کلاس برای هر سه معماری منتخب ارائه شده و کیفیت عملکرد آن‌ها به صورت مقایسه‌ای در جداول ۱-۴، ۲-۴ و ۳-۴ مشاهده می‌شود. در این جداول، سه معیار اصلی برای ارزیابی عملکرد مدل‌ها آورده شده است:

- **دقت (Precision):** نشان می‌دهد چه نسبتی از نمونه‌هایی که مدل به عنوان مثبت پیش‌بینی کرده، واقعاً مثبت هستند. فرمول آن به صورت زیر است:

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **بازخوانی یا حساسیت (Recall):** بیانگر این است که چه نسبتی از نمونه‌های مثبت واقعی توسط مدل شناسایی شده‌اند. فرمول آن به صورت زیر است:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-Score:** میانگین هارمونیک Precision و Recall است و تعادلی بین دقت و حساسیت ایجاد می‌کند. فرمول آن به صورت زیر است:

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

همچنین نتایج به‌دست‌آمده از آموزش مدل‌ها ارائه شده است. ابتدا نمودارهای تغییرات Loss و Accuracy در طول مراحل آموزش و اعتبارسنجی برای هر مدل تکی و نمایش داده شده‌اند تا روند همگرایی و عملکرد کلی شبکه‌ها مورد بررسی قرار گیرد.

پس از آن، ماتریس‌های درهم‌ریختگی^۲ برای هر مدل ارائه شده است تا دقت طبقه‌بندی هر کلاس به‌صورت جزئی تحلیل شود و نقاط قوت و ضعف هر مدل در شناسایی نمونه‌های مختلف به تصویر کشیده شود.

این نمودارها و ماتریس‌ها پایه‌ای برای مقایسه عملکرد مدل‌ها و ارزیابی تأثیر روش‌های Ensemble در بهبود دقت طبقه‌بندی فراهم می‌آورند.

^۲Confusion Matrix

جدول ۴-۱: نتایج معیارهای ارزیابی هر کلاس برای EfficientNetB0


Class	F1-Score	Recall	Precision
0	1.00	1.00	1.00
1	1.00	1.00	1.00
2	1.00	1.00	1.00
3	1.00	1.00	0.99
4	1.00	1.00	1.00
5	1.00	1.00	1.00
6	1.00	1.00	1.00
7	0.98	0.97	0.98
8	1.00	1.00	1.00
9	0.98	0.98	0.97
10	1.00	1.00	1.00
11	1.00	1.00	0.99
12	1.00	1.00	1.00
13	0.99	0.99	1.00
14	1.00	1.00	1.00
15	1.00	1.00	1.00
16	1.00	1.00	0.99
17	1.00	1.00	0.99
18	1.00	1.00	0.99
19	0.99	0.99	1.00
20	1.00	1.00	1.00
21	0.98	0.97	1.00
22	1.00	1.00	1.00
23	1.00	1.00	1.00
24	1.00	1.00	1.00
25	1.00	0.99	1.00
26	1.00	1.00	1.00
27	1.00	1.00	1.00
28	0.99	1.00	0.98
29	0.98	0.98	0.98
30	0.97	0.98	0.96
31	0.99	1.00	0.99
32	0.99	0.99	0.99
33	0.99	0.99	1.00
34	0.98	0.98	0.99
35	1.00	1.00	1.00
36	1.00	1.00	1.00
37	0.99	1.00	0.99

جدول ۴-۲: نتایج معیارهای ارزیابی هر کلاس برای MobileNetV2


Class	F1-Score	Recall	Precision
0	0.99	0.98	1.00
1	1.00	1.00	0.99
2	1.00	1.00	1.00
3	0.99	0.99	0.99
4	1.00	1.00	1.00
5	1.00	1.00	1.00
6	0.99	0.99	1.00
7	0.96	0.96	0.97
8	1.00	1.00	1.00
9	0.96	0.97	0.95
10	1.00	1.00	1.00
11	1.00	1.00	0.99
12	0.99	0.99	1.00
13	1.00	1.00	1.00
14	1.00	1.00	1.00
15	0.99	1.00	0.98
16	0.98	0.97	1.00
17	1.00	1.00	1.00
18	0.99	0.99	0.99
19	0.99	0.99	0.99
20	0.99	0.98	1.00
21	0.98	0.98	0.98
22	1.00	1.00	1.00
23	1.00	1.00	1.00
24	0.99	1.00	0.98
25	1.00	1.00	1.00
26	0.99	0.99	1.00
27	1.00	1.00	1.00
28	0.98	0.99	0.97
29	0.97	0.96	0.98
30	0.96	0.98	0.94
31	0.97	1.00	0.94
32	0.97	0.95	0.98
33	0.97	0.96	0.99
34	0.96	0.97	0.96
35	1.00	1.00	0.99
36	0.99	1.00	0.99
37	1.00	1.00	1.00

جدول ۴-۳: نتایج معیارهای ارزیابی هر کلاس برای ResNet50


Class	F1-Score	Recall	Precision
0	0.98	0.96	1.00
1	0.99	1.00	0.98
2	1.00	1.00	1.00
3	0.99	0.99	0.99
4	1.00	1.00	0.99
5	1.00	1.00	1.00
6	1.00	1.00	1.00
7	0.97	0.98	0.96
8	1.00	1.00	1.00
9	0.97	0.96	0.98
10	1.00	1.00	1.00
11	0.99	0.99	0.99
12	0.99	0.99	1.00
13	1.00	1.00	1.00
14	1.00	1.00	1.00
15	1.00	0.99	1.00
16	0.99	0.99	0.98
17	1.00	1.00	0.99
18	1.00	0.99	1.00
19	0.99	0.99	1.00
20	1.00	1.00	1.00
21	0.99	0.99	0.99
22	0.99	1.00	0.98
23	1.00	0.99	1.00
24	1.00	1.00	1.00
25	1.00	1.00	1.00
26	1.00	0.99	1.00
27	1.00	1.00	1.00
28	0.97	0.95	0.99
29	0.98	0.97	0.98
30	0.95	0.98	0.92
31	0.92	0.85	1.00
32	0.95	0.98	0.93
33	0.96	0.96	0.95
34	0.94	0.98	0.91
35	0.99	0.99	0.99
36	0.99	1.00	0.98
37	0.98	0.97	1.00




شکل ۴-۱: نمودار Accuracy و Loss مدل EfficientNetB0




شکل ۴-۲: نمودار Accuracy و Loss مدل MobileNetV2




شکل ۴-۳: نمودار Accuracy و Loss مدل ResNet50




شکل ۴-۴: ماتریس درهم‌ریختگی مدل EfficientNetB0




شکل ۴-۵: ماتریس درهم‌ریختگی مدل MobileNetV2



شکل ۴-۶: ماتریس درهم‌ریختگی مدل ResNet50



شکل ۴-۷: ماتریس درهم‌ریختگی مدل Ensemble: EfficientNetB0 + MobileNetV2



شکل ۴-۸: ماتریس درهم‌ریختگی مدل Ensemble: EfficientNetB0 + MobileNetV2 + ResNet50

۴-۵-۳ نتایج مرحله تشخیص ناحیه در دیتاست PlantDoc


مرحله تشخیص ناحیه به مراتب چالش‌برانگیزتر از طبقه‌بندی بود، زیرا تصاویر مجموعه داده PlantDoc در محیط واقعی برداشت شده‌اند و دارای نویزهای بصری فراوان، تنوع شدید روشنایی و ناحیه‌های بسیار کوچک آلودگی هستند. نسخه پایه YOLOX در آزمایش‌های اولیه عملکرد قابل قبولی داشت، اما در تشخیص ناحیه‌های کوچک دقت کافی ارائه نمی‌کرد و گاهی بخش‌هایی از تصویر را به اشتباه به عنوان ناحیه بیماری برچسب می‌زد. این رفتار موجب کاهش mAP شد و نشان می‌داد که مدل نیازمند تقویت ساختاری است.

به منظور رفع این محدودیت، ابتدا Backbone اصلی YOLOX با ConvNeXt جایگزین شد. این تغییر باعث شد مدل قادر به استخراج ویژگی‌های ریز و پیچیده‌تری از تصاویر شود و نقشه‌های ویژگی غنی‌تری تولید کند. در نتیجه، YOLOX-ConvNeXt در تعیین مرزهای بیماری عملکرد دقیق‌تری داشت و نرخ پیش‌بینی‌های اشتباه کاهش یافت.


در گام بعد، مکانیزم توجه CBAM به مدل افزوده شد؛ اقدامی که بیشترین تأثیر را در افزایش دقت نهایی داشت. CBAM موجب شد مدل تمرکز بیشتری روی ناحیه‌های واقعی بیماری داشته باشد و تأثیر پس‌زمینه‌های نامرتبط کاهش یابد. ترکیب نهایی YOLOX-ConvNeXt-CBAM افزایش چشمگیری در معیارهای mAP ایجاد کرد و توانست به $mAP@0.5$ بین ۸۶٪ تا ۹۱٪ (بسته به نوع بیماری) دست یابد. این مقدار، با توجه به کیفیت غیرهمگن و چالش‌برانگیز داده‌های PlantDoc، نتیجه‌ای بسیار قابل توجه است.

تحلیل خروجی مدل نهایی نشان داد بسیاری از بیماری‌هایی که نسخه اولیه YOLOX قادر به شناسایی آن‌ها نبود، اکنون به درستی تشخیص داده می‌شوند. حتی لکه‌هایی با اندازه چند پیکسل نیز توسط مدل شناسایی شدند. این موضوع نشان می‌دهد که به کارگیری ConvNeXt و CBAM نه تنها دقت کلی را افزایش داده، بلکه حساسیت مدل به ناحیه‌های کوچک و کم‌کیفیت بیماری را نیز به شکل محسوسی بهبود بخشیده است.


در ادامه، نتایج حاصل از به کارگیری مدل پیشنهادی YOLOX+ConvNeXt+CBAM ارائه شده است که شامل خروجی‌های تشخیص ناحیه‌های بیماری، نقشه‌های حرارتی تمرکز مدل، ماسک استخراج‌شده از ناحیه برگ، و همچنین نمودارهای همگرایی و شاخص‌های ارزیابی عملکرد مدل می‌باشد.



شکل ۴-۹: نمودار تغییرات توابع هزینه شامل box loss، distribution focal loss و classification loss در طول فرآیند آموزش و اعتبارسنجی مدل.




شکل ۴-۱۰: روند تغییرات معیارهای ارزیابی شامل Precision، Recall و mAP در مراحل مختلف آموزش که بیانگر بهبود تدریجی عملکرد مدل می‌باشد.




شکل ۴-۱۱: نمونه‌ای از خروجی مدل YOLOX+ConvNeXt+CBAM در تشخیص بیماری برگ؛ جعبه‌های سبز رنگ نشان‌دهنده برچسب واقعی (Ground Truth) و جعبه‌های قرمز رنگ بیانگر نواحی پیش‌بینی شده توسط مدل هستند.




شکل ۴-۱۲: نمونه‌ای از خروجی مدل YOLOX+ConvNeXt+CBAM در تشخیص بیماری برگ؛ جعبه‌های سبز رنگ نشان‌دهنده برچسب واقعی (Ground Truth) و جعبه‌های قرمز رنگ بیانگر نواحی پیش‌بینی شده توسط مدل هستند.



شکل ۴-۱۳: نقشه‌های حرارتی (Heatmap) استخراج‌شده از خروجی مدل که نواحی با بیشترین میزان تمرکز و اهمیت در فرآیند تصمیم‌گیری مدل را نمایش می‌دهند.



شکل ۴-۱۴: نقشه‌های حرارتی (Heatmap) استخراج‌شده از خروجی مدل که نواحی با بیشترین میزان تمرکز و اهمیت در فرآیند تصمیم‌گیری مدل را نمایش می‌دهند.



شکل ۴-۱۵: نمونه‌ای از ماسک استخراج‌شده برگ بر اساس پردازش تصویر، که به منظور تفکیک ناحیه برگ از پس‌زمینه و تحلیل دقیق‌تر ناحیه بیماری ارائه شده است.

۴-۵-۴ تحلیل خطاهای مدل در مرحله Detection

هیچ مدلی -حتی در پیشرفته‌ترین سامانه‌های بینایی ماشین- بی‌خطا نیست و تحلیل خطاها بخش ضروری فرآیند ارزیابی محسوب می‌شود، زیرا مشخص می‌کند مدل در چه شرایطی دچار ضعف می‌شود. بررسی نتایج مدل نهایی YOLOX-ConvNeXt-CBAM نشان داد که سه الگوی اصلی خطا در عملکرد آن وجود دارد.

نخستین الگو به تصاویر با نوردهی غیرطبیعی مربوط می‌شود؛ یعنی نمونه‌هایی که به شدت تاریک یا بیش‌ازحد روشن هستند. در این شرایط، مرزهای بیماری وضوح کافی ندارند و مدل گاهی نمی‌تواند محدوده دقیق لکه‌ها را استخراج کند. با وجود استفاده از تکنیک‌های افزایش داده مربوط به تغییرات نور، شدت نامتعارف نور در برخی تصاویر خارج از محدوده الگوهای آموزش دیده بود.

دومین الگوی خطا در تصاویری مشاهده شد که برگ‌ها روی یکدیگر قرار گرفته یا همپوشانی بالایی داشتند. در این وضعیت، مدل گاهی لکه یک برگ را به برگ دیگر نسبت می‌داد. این چالش در اغلب مدل‌های Detection رایج است و معمولاً تنها با استفاده از داده‌های دقیق‌تر یا بهره‌گیری از مدل‌های مبتنی بر Segmentation می‌توان آن را تا حد زیادی برطرف کرد.

سومین الگوی خطا به بیماری‌هایی مربوط است که بافت و رنگ لکه‌های آن‌ها با عناصر پس‌زمینه شباهت دارند. به عنوان نمونه، لکه‌های قهوه‌ای روی برگ‌های خشک‌شده گاهی با خاک پس‌زمینه اشتباه گرفته می‌شدند. با این حال، افزودن مکانیزم توجه CBAM نقش مهمی در کاهش این خطاها داشت و تعداد اشتباهات در این نوع نمونه‌ها به‌طور محسوسی کم شد.

۴-۵-۵ مقایسه عملکرد مرحله طبقه‌بندی و تشخیص ناحیه

نکته قابل‌توجه این است که عملکرد مرحله طبقه‌بندی بر روی دیتاست PlantVillage تقریباً بی‌نقص است، درحالی‌که عملکرد مرحله تشخیص شیء (Detection) به‌طور طبیعی پایین‌تر است. این تفاوت کاملاً قابل‌انتظار است؛ زیرا شرایط تصویربرداری در این دو دیتاست تفاوت بنیادین دارند. دیتاست PlantVillage در محیطی کنترل‌شده جمع‌آوری شده است؛ نور یکنواخت، پس‌زمینه ساده و کیفیت بالا باعث می‌شود مدل‌های CNN بتوانند الگوهای بیماری را با دقت تقریباً کامل استخراج کنند. در مقابل، دیتاست PlantDoc در محیط واقعی ثبت شده و شامل تغییرات شدید نور، تنوع پس‌زمینه، سایه‌ها و همپوشانی برگ‌هاست؛ عواملی که به‌طور طبیعی دقت Detection را کاهش می‌دهند.

با این حال، ترکیب این دو مرحله ساختاری ایجاد کرده است که در عمل بسیار کارآمد است. مرحله طبقه‌بندی نقش یک فیلتر اولیه را ایفا می‌کند و خروجی آن اطلاعاتی فراهم می‌سازد که به تصمیم‌گیری مرحله Detection کمک می‌کند. این هم‌افزایی باعث می‌شود خروجی نهایی سیستم -حتی در شرایط پیچیده محیط واقعی- رفتاری قابل‌اعتماد، پایدار و منطقی داشته باشد.

۴-۶ جمع‌بندی

در این پروژه یک ساختار دومرحله‌ای برای شناسایی و تشخیص ناحیه بیماری‌های گیاهی طراحی شد که از دو دیتاست کاملاً متفاوت، PlantVillage و PlantDoc، استفاده می‌کند. مرحله طبقه‌بندی با استفاده از PlantVillage ساخته شد تا مدل بتواند الگوهای بیماری را به‌صورت دقیق و بدون نویز تشخیص دهد، در حالی که مرحله Detection با PlantDoc آموزش داده شد تا سیستم در شرایط واقعی نیز کارآمد باشد. تفاوت این دو مجموعه داده باعث شد پیش‌پردازش و آماده‌سازی داده‌ها برای هر مرحله به‌صورت جداگانه انجام شود.

در بخش طبقه‌بندی، ترکیب سه معماری EfficientNetB0، MobileNetV2 و ResNet50 یک مدل Ensemble ایجاد کرد که انواع ویژگی‌ها، از بافت ساده تا الگوهای پیچیده و چندمقیاسی، را استخراج می‌کند.

مرحله Detection با استفاده از YOLOX و جایگزینی Backbone آن با ConvNeXt و اضافه کردن مکانیزم CBAM به مدلی قدرتمند و پایدار تبدیل شد. طراحی Anchor-Free، استخراج ویژگی عمیق توسط ConvNeXt و مکانیزم توجه CBAM باعث شدند مدل در تصاویر واقعی و نویزی PlantDoc عملکرد قابل اعتماد داشته باشد. خروجی این ترکیب، سیستمی توانمند در تشخیص دقیق ناحیه بیماری، حتی در تصاویر با لکه‌های کوچک و نویزی، است.

پیاده‌سازی عملی پروژه نشان داد که موفقیت سیستم تنها به معماری‌های قوی بستگی ندارد؛ بلکه تنظیم دقیق پارامترها، مدیریت مراحل آموزش و ترکیب درست ماژول‌ها نیز اهمیت زیادی دارد. نتایج نشان دادند که ساختار دومرحله‌ای پروژه هم از نظر نظری منطقی و هم در عمل مؤثر است. مدل Ensemble در طبقه‌بندی به دقت نزدیک به ۱۰۰٪ رسید و مدل YOLOX-ConvNeXt-CBAM یکی از بهترین نتایج روی PlantDoc را ثبت کرد. سیستم پیشنهادی از نظر دقت، پایداری و قابلیت استفاده عملی در سطح بسیار خوبی قرار دارد.

فصل ۵

نتیجه‌گیری و آینده پژوهی

۵-۱ نتیجه‌گیری کلی پروژه

پروژه حاضر یک سیستم هوشمند دومرحله‌ای برای شناسایی و تشخیص ناحیه بیماری‌های گیاهی طراحی کرد که از دو دیتاست متفاوت -PlantVillage و PlantDoc- بهره می‌برد.

- مرحله طبقه‌بندی: با استفاده از ترکیب سه معماری ResNet50 و MobileNetV2, EfficientNetB0 و ساختار Ensemble، مدل توانست طیف گسترده‌ای از ویژگی‌ها را استخراج کرده و به دقتی نزدیک به ۱۰۰٪ در محیط کنترل‌شده دست یابد. این مرحله پایه‌ای محکم برای مرحله Detection ایجاد کرد.

- مرحله Detection: با استفاده از YOLOX-ConvNeXt-CBAM، سیستم قادر شد در شرایط واقعی و پیچیده PlantDoc نواحی کوچک بیماری را با دقت بالا تشخیص دهد. طراحی Anchor-Free، Backbone قدرتمند و مازول توجه باعث شد مدل حتی در تصاویر پرنویز و با هم‌پوشانی برگ‌ها عملکرد قابل‌اعتماد ارائه کند.

نتایج نشان داد که سیستم دومرحله‌ای پروژه هم از نظر نظری و هم عملی موفق بوده و قابلیت استفاده در کاربردهای کشاورزی هوشمند را دارد.

۵-۲ نقاط قوت سیستم

- ساختار دو مرحله‌ای: مرحله طبقه‌بندی به‌عنوان فیلتر اولیه و مرحله Detection به‌عنوان مرحله عملیاتی مکمل، باعث افزایش دقت و پایداری سیستم شده است.

- استفاده از Ensemble: ترکیب سه مدل طبقه‌بندی تنوع ویژگی‌ها را افزایش داده و خطاهای موردی را کاهش داده است.

- معماری Detection پیشرفته: YOLOX به همراه ConvNeXt و CBAM ترکیبی بهینه و سریع برای شناسایی نواحی کوچک بیماری ایجاد کرده است.

- تعامل با محیط واقعی: سیستم توانایی عملکرد در شرایط طبیعی و دشوار را دارد، برخلاف بسیاری از پروژه‌های مشابه که تنها روی داده‌های کنترل‌شده متمرکز هستند.

۳-۵ محدودیت‌های پروژه

- ساختار دو وابستگی به دیتاست: تعداد کم نمونه‌ها در برخی کلاس‌ها و نبود تصاویر متنوع محیطی باعث کاهش دقت در شرایط خاص شده است.
- چالش‌های طبیعی تصاویر: هم‌پوشانی برگ‌ها، رنگ مشابه پس‌زمینه و اشیای مزاحم می‌تواند دقت Detection را کاهش دهد.
- مصرف محاسباتی: مدل YOLOX-ConvNeXt-CBAM نیازمند توان محاسباتی بالاست و اجرای آن روی دستگاه‌های محدود ممکن است نیازمند فشرده‌سازی مدل باشد.

۴-۵ پیشنهاد‌های آینده پژوهش

- افزایش تنوع و تعداد تصاویر واقعی و استفاده از Semi-Supervised Learning برای بهره‌برداری از داده‌های بدون برچسب.
- توسعه مرحله Segmentation با مدل‌های U-Net یا DeepLab برای تشخیص دقیق‌تر نواحی بیماری.
- آزمایش Backbone‌های جدید مانند Swin Transformer یا ViT-Large برای استخراج روابط بلندبرد و بهبود عملکرد در داده‌های پیچیده.
- طراحی اپلیکیشن موبایلی با مدل سبک‌شده و فشرده‌سازی با تکنیک‌هایی مانند Knowledge Distillation یا Quantization برای کاربرد Real-Time در مزرعه.

۵-۵ جمع‌بندی نهایی

این پایان‌نامه موفق شد یک سیستم دقیق، پایدار و قابل‌استفاده در دنیای واقعی طراحی کند. مرحله طبقه‌بندی با Ensemble سه‌مدلی عملکردی نزدیک به ۱۰۰٪ ارائه کرد و مرحله Detection با YOLOX-ConvNeXt-CBAM توانست نواحی بیماری را در شرایط طبیعی به دقت بالا شناسایی کند. این ساختار

دومرحله‌ای می‌تواند پایه‌ای برای توسعه سیستم‌های پیشرفته‌تر در کشاورزی هوشمند باشد و مسیرهای آینده پژوهش، فرصت‌هایی برای تبدیل این سیستم به یک محصول عملی فراهم می‌کنند.

کتاب نامه

- [1] Aderinwale, David Adeyinka and Sah, Melike. Plant disease classification using an ensemble learning model of convolutional neural networks and vision transformers. In *2025 7th International Congress on Human-Computer Interaction, Optimization and Robotic Applications (ICHORA)*, pages 1–10. IEEE, 2025.
- [2] Al-Hiary, Hamzah, Bani-Ahmad, Saleh, Reyalat, Maher, Braik, Malik, and AlRahamneh, Ziyad. Fast and accurate detection and classification of plant diseases. *International Journal of Computer Applications*, 17(1):31–38, 2011.
- [3] Anduyan, Devina, Gultiano, Navy, Cabillo, Nyza, and Pacot, Mark Phil. Enhancing cocoa pod disease classification via transfer learning and ensemble methods: toward robust predictive modeling. In *2025 International Symposium on Multimedia and Communications Technology (ISMATC)*, pages 1–6. IEEE, 2025.
- [4] Bellout, A., Zarboubi, M., Dliou, A., Latif, R., and Saddik, A. Advanced yolo models for real-time detection of tomato leaf diseases. *Mathematical Modeling and Computing*, 11(4):1198–1210, 2024.
- [5] Cazenave, Tristan, Sentuc, Julien, and Videau, Mathurin. Cosine annealing, mixnet and swish activation for computer go. In Browne, Cameron, Kishimoto, Akihiro, and Schaeffer, Jonathan, editors, *Advances in Computer Games: 17th International Conference, ACG 2021, Virtual Event, November 23–25, 2021, Revised Selected Papers*,

- volume 13262 of *Lecture Notes in Computer Science*, pages 53–60. Springer International Publishing, Cham, Switzerland, 2022.
- [6] Chen, Junde, Chen, Jinxiu, Zhang, Defu, Sun, Yuandong, and Nanekaran, Yaser A. Using deep transfer learning for image-based plant disease identification. *Computers and Electronics in Agriculture*, 173:105393, 2020.
- [7] Chen, Junde, Zhang, Defu, Nanekaran, Yaser A., and Li, Dele. Detection of rice plant diseases based on deep transfer learning. *Journal of the Science of Food and Agriculture*, 100(7):3246–3256, 2020.
- [8] Chen, Mingzhou, Zou, Wei, Niu, Xiangjie, Fan, Pengfei, Liu, Haowei, Li, Cuiling, and Zhai, Changyuan. Improved yolov8-based segmentation method for strawberry leaf and powdery mildew lesions in natural backgrounds. *Agronomy*, 15(3):525, 2025.
- [9] Darwin, Bini, Dharmaraj, Pamela, Prince, Shajin, Popescu, Daniela Elena, and Hermanth, Duraisamy Jude. Recognition of bloom/yield in crop images using deep learning models for smart agriculture: A review. *Agronomy*, 11(4):646, 2021.
- [10] Endris Hasen, Ahmed, Shangming, Yang, Ukwuoma, Chiagoziem C., Gashaw, Biniyam, and Zenebe Yutra, Abel. Abcd: Automatic blood cell detection via attention-guided improved yolox. *arXiv*, 2025.
- [11] Falaschetti, Laura, Manoni, Lorenzo, Di Leo, Denis, Pau, Danilo, Tomaselli, Valeria, and Turchetti, Claudio. A cnn-based image detector for plant leaf diseases classification. *HardwareX*, 12:e00363, 2022.
- [12] Guo, Wenjuan, Feng, Quan, Li, Xiangzhou, Yang, Sen, and Yang, Junqi. Grape leaf disease detection based on attention mechanisms. *International Journal of Agricultural and Biological Engineering*, 15(5):205–212, 2022.

- [13] Hasen, Ahmed Endris, Shangming, Yang, Ukwuoma, Chiagoziem C., Gashaw, Biniyam, and Yutra, Abel Zenebe. Abcd: Automatic blood cell detection via attention-guided improved yolox. *arXiv*, 2025.
- [14] Karim, Md Jawadul, Goni, Md Omaer Faruq, Nahiduzzaman, Md, Ahsan, Mominul, Haider, Julfikar, and Kowalski, Marcin. Enhancing agriculture through real-time grape leaf disease classification via an edge device with a lightweight cnn architecture and grad-cam. *Scientific Reports*, 14(1):16022, 2024.
- [15] Li, Lili, Zhang, Shujuan, and Wang, Bin. Plant disease detection and classification by deep learning—a review. *IEEE Access*, 9:56683–56698, 2021.
- [16] Liu, Wenbo, Zhai, Yongsun, and Xia, Yu. Tomato leaf disease identification method based on improved yolox. *Agronomy*, 13(6):1455, 2023.
- [17] Lu, Jinzhu, Tan, Lijuan, and Jiang, Huanyu. Review on convolutional neural network (cnn) applied to plant leaf disease classification. *Agriculture*, 11(7):516, 2021.
- [18] Lu, Yang, Jiang, Jianan, Zhong, Jia, Wang, Yong, Wang, Xiangyu, and Zou, Ziming. Automatic detection method of polar cap arc based on yolox embedded with cbam. *Frontiers in Environmental Science*, 12:1418207, 2024.
- [19] Militante, Sammy V, Gerardo, Bobby D, and Dionisio, Nanette V. Plant leaf detection and disease recognition using deep learning. In *2019 IEEE Eurasia Conference on IoT, Communication and Engineering (ECICE)*, pages 579–582. IEEE, 2019.
- [20] Mukti, Ishrat Zahan and Biswas, Dipayan. Transfer learning based plant diseases detection using resnet50. In *2019 4th International Conference on Electrical Information and Communication Technology (EICT)*, pages 1–6. IEEE, 2019.

- [21] Nader, Andrew, Hussien, Shereen Ahmed, and Khafagy, Mohamed Helmy. Classification of plant leaf disease using ensemble deep transfer learning. *International Journal of Intelligent Computing and Information Sciences*, 24(1):69–88, 2024.
- [22] Noyan, Mehmet Alican. Uncovering bias in the plantvillage dataset. *arXiv*, 2022.
- [23] Pai, Prameetha, Amutha, S., Patil, Seema, Shobha, T., Basthikodi, Mustafa, Ahamed Shafeeq, B. M., and Gurple, Ananth Prabhu. Deep learning-based automatic diagnosis of rice leaf diseases using ensemble cnn models. *Scientific Reports*, 15(1):27690, 2025.
- [24] Peyal, Hasibul Islam, Nahiduzzaman, Md, Pramanik, Md Abu Hanif, Syfullah, Md Khalid, Shahriar, Saleh Mohammed, Sultana, Abida, Ahsan, Mominul, Haider, Julfikar, Khandakar, Amith, and Chowdhury, Muhammad EH. Plant disease classifier: Detection of dual-crop diseases using lightweight 2d cnn architecture. *IEEE Access*, 11:110627–110643, 2023.
- [25] Picon, Artzai, Seitz, Maximilian, Alvarez-Gila, Aitor, Mohnke, Patrick, Ortiz-Barredo, Amaia, and Echazarra, Jone. Crop conditional convolutional neural networks for massive multi-crop plant disease classification over cell phone acquired images taken on real field conditions. *Computers and Electronics in Agriculture*, 167:105093, 2019.
- [26] Saleem, Muhammad Hammad, Potgieter, Johan, and Arif, Khalid Mahmood. Plant disease detection and classification by deep learning. *Plants*, 8(11):468, 2019.
- [27] Saleem, Muhammad Hammad, Potgieter, Johan, and Arif, Khalid Mahmood. Plant disease classification: A comparative evaluation of convolutional neural networks and deep learning optimizers. *Plants*, 9(10):1319, 2020.

- [28] Shafik, Wasswa, Tufail, Ali, De Silva Liyanage, Chandratilak, and Apong, Rosyzie Anna Awg Haji Mohd. Using transfer learning-based plant disease classification and detection for sustainable agriculture. *BMC Plant Biology*, 24(1):136, 2024.
- [29] Shen, Chao, Ma, Caiwen, and Gao, Wei. Multiple attention mechanism enhanced yolox for remote sensing object detection. *Sensors*, 23(3):1261, 2023.
- [30] Singh, Davinder, Jain, Naman, Jain, Pranjali, Kayal, Pratik, Kumawat, Sudhakar, and Batra, Nipun. Plantdoc: A dataset for visual plant disease detection. In *Proceedings of the 7th ACM IKDD Conference on Data Science and the 25th COMAD*, pages 249–253. ACM, 2020.
- [31] Singh, Davinder, Jain, Naman, Jain, Pranjali, Kayal, Pratik, Kumawat, Sudhakar, and Batra, Nipun. Plantdoc dataset: A dataset for visual plant disease detection. Online, 2020. Accessed: 2024.
- [32] Tejaswi, A. Plantvillage dataset. Kaggle, 2019. Accessed: 2024.
- [33] Ullah, Md Rahmat, Dola, Nagifa Anjum, Sattar, Abdus, and Hasnat, Abir. Plant diseases recognition using machine learning. In *Proceedings of the 2019 8th International Conference on System Modeling and Advancement in Research Trends (SMART 2019)*, pages 67–73. IEEE, 2019.
- [34] Vallabhajosyula, Sasikala, Sistla, Venkatramaphanikumar, and Kolli, Venkata Krishna Kishore. Transfer learning-based deep ensemble neural network for plant leaf disease detection. *Journal of Plant Diseases and Protection*, 129(3):545–558, 2022.
- [35] Vo, Hoang-Tu, Quach, Luyl-Da, and Hoang, Tran Ngoc. Ensemble of deep learning models for multi-plant disease classification in smart farming. *International Journal of Advanced Computer Science and Applications*, 14(5):108, 2023.

- [36] Wang, Peng, Deng, Hong, Guo, Jiaxu, Ji, Siqu, Meng, Dan, Bao, Jun, and Zuo, Peng. Leaf segmentation using modified yolov8-seg models. *Life*, 14(6):780, 2024.
- [37] Xu, Kelvin, Ba, Jimmy, Kiros, Ryan, Cho, Kyunghyun, Courville, Aaron, Salakhudinov, Ruslan, Zemel, Rich, and Bengio, Yoshua. Show, attend and tell: Neural image caption generation with visual attention. In *Proceedings of the 32nd International Conference on Machine Learning (ICML 2015)*, pages 2048–2057. PMLR, 2015.
- [38] Yang, Tingting, Zhou, Suyin, Xu, Aijun, Ye, Junhua, and Yin, Jianxin. An approach for plant leaf image segmentation based on yolov8 and the improved deeplabv3+. *Plants*, 12(19):3438, 2023.
- [39] Zhang, Can, Shao, Yichuan, Sun, Haijing, Xing, Lei, Zhao, Qian, and Zhang, Le. The wuc-adam algorithm based on joint improvement of warmup and cosine annealing algorithms. *Mathematical Biosciences and Engineering*, 21(1):1270–1285, 2024.
- [40] Zhang, Yuanjia, Ma, Benxue, Hu, Yating, Li, Cong, and Li, Yujie. Accurate cotton diseases and pests detection in complex background based on an improved yolox model. *Computers and Electronics in Agriculture*, 203:107484, 2022.
- [41] Zheng, Zhihao, Zhao, Jianguang, Fan, Jingjing, Bai, Ruirui, Zhao, Jiana, and Liu, Jianan. A complex roadside object detection model based on multi-scale feature pyramid network. *Scientific Reports*, 15(1):15992, 2025.
- [42] Zubair, Fida, Saleh, Moutaz, Akbari, Younes, and Al Maadeed, Somaya. A robust ensemble model for plant disease detection using transfer learning and deep cnn architectures. *AgriEngineering*, 7(5):159, 2025.

Abstract

Automatic plant disease detection plays a crucial role in reducing agricultural losses and enhancing productivity in smart agriculture systems. This study aims to propose an image processing and deep learning–based framework for the detection of plant leaf diseases with applicability in real-world farming conditions.

In the first stage, well-known image classification architectures, including AlexNet, EfficientNet, MobileNet, and ResNet, were trained using the controlled PlantVillage dataset. To improve system performance, a three-layer ensemble model was designed by combining features extracted from the selected deep networks, leveraging the complementary strengths of these three architectures simultaneously.

In the second stage, to transfer the model from laboratory conditions to real-world uncontrolled environments, a disease region detection model based on YOLOX was developed. In this model, ConvNeXt was employed as the backbone, and the CBAM attention mechanism was integrated to enhance spatial and channel-wise feature extraction. The model was evaluated on the PlantDoc dataset, which contains images under real-world conditions with varying lighting, complex backgrounds, noise, and different imaging angles.

The results indicate that the proposed ensemble model achieved an accuracy of approximately 99.76%, demonstrating the superiority of ensemble models over individual architectures on controlled data. Furthermore, the region detection model successfully identified diseased areas on plant leaves with satisfactory accuracy and speed in real-world images, reflecting the efficiency, robustness, and practical applicability of this framework in smart agriculture systems for plant health monitoring and reducing manual inspection costs.

Key Words:

Plant Disease Detection, Image Processing, Deep Learning, Convolutional Neural Networks (CNNs), Ensemble Models, YOLOX, Smart Agriculture